本科毕业设计（论文）

基于扩散模型的脑 MRI 肿瘤检测与定位研究

学　　院：生命科学与技术学院

专　　业：生物医学工程

班　　级：医电 2203

学生姓名：万子豪

学　　号：2223612465

指导教师：谢琳

2026 年 01 月

摘　要

脑部肿瘤作为一种高致死率的中枢神经系统疾病，其早期精准诊断对治疗方案的制定至关重要。磁共振成像（Magnetic Resonance Imaging, MRI）因其优异的软组织对比度而成为临床诊断的金标准。然而，现有的基于监督学习的自动检测方法高度依赖大规模像素级专家标注，且难以识别长尾分布的罕见病灶。针对上述问题，本文提出一种基于文本引导潜在扩散模型（Latent Diffusion Models, LDM）的脑部 MRI 无监督异常检测与定位算法，利用“以正推异”的重构范式，在仅使用健康数据训练的情况下实现对病灶的精准捕捉。本文的主要研究内容如下：

首先，针对单纯文本引导在图像重构中容易丢失解剖结构细节的问题，设计了基于领域掩码网络的空间特征条件建模方法。该模块采用混合架构，利用卷积神经网络（Convolutional Neural Networks, CNN）提取 T2 加权液体衰减反转恢复（T2-weighted Fluid Attenuated Inversion Recovery, T2-FLAIR）模态的局部纹理特征，并引入特征级领域掩码策略，随机遮蔽部分特征以防止模型产生恒等映射。在此基础上，应用 Transformer 捕获像素间的长距离依赖关系，生成具备全局解剖布局感知的空间特征向量，为扩散模型的生成过程提供强几何约束，确保重构图像严格遵循正常脑组织的拓扑结构。

其次，为了增强模型对医学细粒度语义的理解，提出了基于视觉-语言模型（Vision-Language Models, VLM）的语义引导机制。通过构建包含解剖学先验的专家提示工程（Expert Prompt Engineering），利用预训练 VLM 生成描述正常脑部特征（如脑室、脑沟回）的文本嵌入向量。该向量通过交叉注意力机制注入去噪网络，协同空间特征共同指导潜在空间的去噪过程，有效解决了传统无监督方法中的语义漂移问题。

最后，在 BraTS 2021 数据集上构建了 One-Class 异常检测实验基准。利用训练好的条件扩散模型对测试图像进行“加噪-去噪”重构，迫使潜在的肿瘤区域恢复为健康组织，并通过计算原始图像与重构图像的残差生成异常热力图。实验结果表明，该方法在图像级异常检测（Image-AUC）上达到了 **[在此处填入您的数据]**%，在像素级定位（Pixel-AUC）上达到了 **[在此处填入您的数据]**%。与自动编码器（AutoEncoder, AE）及生成对抗网络（Generative Adversarial Networks, GAN）等主流基线方法相比，本文方法显著提升了检测精度与定位的鲁棒性，展现了在辅助临床诊断方面的应用潜力。

关键词：脑肿瘤检测；无监督异常检测；潜在扩散模型；视觉-语言模型；领域掩码网络

ABSTRACT

Brain tumors are severe central nervous system diseases with high mortality rates, making early and accurate diagnosis crucial for treatment planning. Magnetic Resonance Imaging (MRI) is the clinical gold standard due to its superior soft-tissue contrast. However, existing supervised learning methods rely heavily on large-scale, pixel-level expert annotations and struggle to identify rare anomalies with long-tail distributions. To address these challenges, this thesis proposes an unsupervised anomaly detection and localization algorithm for brain MRI based on Text-Guided Latent Diffusion Models (LDM). Utilizing a reconstruction-based paradigm, the model is trained exclusively on healthy data to precisely identify pathological lesions. The main contributions of this study are as follows:

First, to address the loss of anatomical structural details in purely text-guided reconstruction, a Spatial Feature Condition Modeling method based on Domain Masked Networks is designed. This module employs a hybrid architecture, utilizing Convolutional Neural Networks (CNN) to extract local texture features from T2-weighted Fluid Attenuated Inversion Recovery (T2-FLAIR) modalities. A feature-level Domain Masked strategy is introduced to randomly mask parts of the features, preventing the model from learning identity mappings. Subsequently, a Transformer is applied to capture long-range inter-pixel dependencies, generating spatial feature vectors with global anatomical layout awareness. These features provide strong geometric constraints for the diffusion generation process, ensuring the reconstructed images strictly adhere to normal brain topology.

Second, to enhance the model's understanding of fine-grained medical semantics, a semantic guidance mechanism based on Vision-Language Models (VLM) is proposed. By constructing Expert Prompt Engineering incorporating anatomical priors, text embedding vectors describing normal brain features (e.g., ventricles, sulci) are generated using pre-trained VLMs. These vectors are injected into the denoising network via cross-attention mechanisms, collaborating with spatial features to guide the denoising process in the latent space, effectively resolving the semantic drift issue common in traditional unsupervised methods.

Finally, a One-Class anomaly detection benchmark is established on the BraTS 2021 dataset. The trained conditional diffusion model reconstructs test images through a "noise-denoise" process, forcing potential tumor regions to revert to healthy tissue. Anomaly heatmaps are generated by calculating the residuals between the original and reconstructed images. Experimental results demonstrate that the proposed method achieves an Image-AUC of **[Fill Data Here]**% and a Pixel-AUC of **[Fill Data Here]**%. Compared with mainstream baselines such as AutoEncoders (AE) and Generative Adversarial Networks (GAN), this method significantly

improves detection accuracy and localization robustness, demonstrating great potential for assisting clinical diagnosis.

KEY WORDS： Brain Tumor Detection; Unsupervised Anomaly Detection; Latent Diffusion Models; Vision-Language Models; Domain Masked Networks

目 录

1 绪论 1
1.1 研究背景与意义 1
1.2 国内外研究现状 2
1.2.1 基于 U-Net 神经网络的有监督分割方法 3
1.2.2 基于生成式的无监督重构方法 3
1.2.3 视觉-语言模型（VLM）在医学影像中的前沿探索 6
1.3 研究内容和研究目标 7
2 基于领域掩码网络的空间特征条件建模 9
2.1 基于 CNN 的多尺度局部特征编码 9
2.2 邻域屏蔽机制与掩码矩阵构建 11
2.3 基于 Transformer 的全局上下文聚合 12
2.4 本章小结 14
3 基于 VLM 的细粒度医学语义文本生成 15
3.1 医学专家提示工程与正常解剖描述生成 15
3.2 基于多头交叉注意力的语义条件注入机制 16
3.3 基于 CFG Drop 的鲁棒推理与异常评分策略 18
3.4 本章小结 18
4 多条件引导下的潜在扩散重构模型构建与训练 20
4.1 基于 VAE 的潜在空间映射与感知压缩 20
4.2 融合双重条件的 U-Net 去噪网络架构 21
4.3 扩散模型训练参数设置与训练结果（待补充） 22
4.4 基于残差的无监督异常推理与精确定位机制 23
4.5 本章小结 25
5 结论与未来展望 26
5.1 本文结论 26
5.2 未来展望 26
致谢 29
参考文献 31
附录 A 外文原文 32
附录 B 外文翻译 41
附录 C 程序代码 50

1 绪论

1.1 研究背景与意义

脑部肿瘤作为中枢神经系统最常见的病变之一，严重威胁着人类的生命健康与生活质量。其中，脑胶质瘤（Glioma）具有极高的致死率、致残率以及术后复发率，在原发性恶性脑肿瘤中占比极高。据相关临床统计，恶性胶质瘤患者的平均中位生存期往往不足两年，因此，实现肿瘤的早期发现、精准分级与精确定位，对于制定有效的手术规划及后续的放化疗方案至关重要。

目前，磁共振成像（Magnetic Resonance Imaging, MRI）凭借其无电离辐射、多参数多序列成像以及对软组织极高的高分辨能力，已全面取代传统的影像手段，成为临床脑部疾病诊断的“金标准”。

如图 1-1 所示，现代医用超导 MRI 设备是一个高度精密的系统，主要由主磁体、梯度线圈、射频传输系统及计算机重建系统组成。其核心物理原理是将人体置于均匀的强静磁场中（临床常用 1.5T 或 3.0T），利用特定频率的射频脉冲激发人体组织内的氢原子核发生核磁共振现象。在射频脉冲停止后，接收线圈采集原子核恢复到平衡状态过程中释放的弛豫信号，最后经由计算机进行傅里叶变换等复杂的数学运算，重建出人体内部精细的断层图像。

图 1-1 典型的医用超导磁共振成像（MRI）扫描设备外观示意图

尽管 X 射线计算机断层扫描（Computed Tomography, CT）因其成像速度快、成本低，在急性脑出血和颅骨骨折的急诊排查中应用广泛，但在脑肿瘤等软组织病变的诊断上，MRI 具有不可替代的优势。如图 1-2 所示，CT 成像基于组织对 X 射线的电子密度衰减差异，导致其对脑灰质、白质及肿瘤组织的对比度较低。相比之下，MRI 利用质子在不同组织环境中的 T1（纵向弛豫）和 T2（横向弛豫）特性，能够清晰呈现脑沟回的解剖结构。特别是 T2 加权液体衰减反转恢复（T2-weighted Fluid Attenuated Inversion Recovery, T2-FLAIR）序列，能够有效抑制脑脊液信号，使病灶周围的血管源性水肿呈

现高亮信号，从而极大地提高了肿瘤检出的灵敏度。因此，MRI，尤其是 T2-FLAIR 模态，是本课题数据来源的首选。

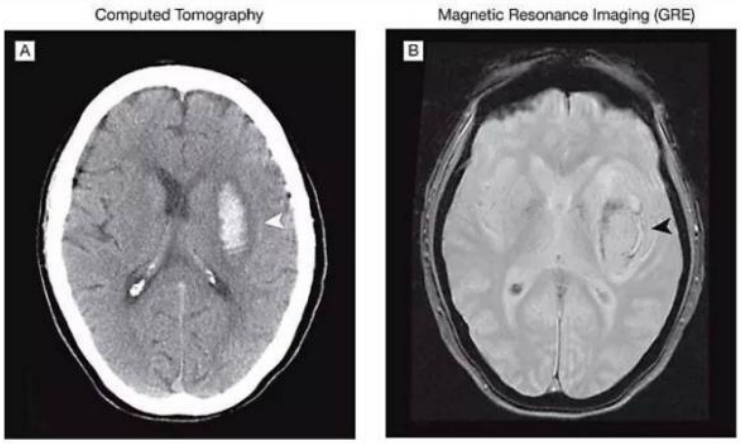

图 1-2　脑部同层面 CT 与 MRI 成像效果对比。CT 图像对脑实质的灰白质对比度较差，病灶显示不清；MRI 图像具有极高的软组织分辨率，能够清晰呈现解剖细节与病理特征。

然而，随着现代医疗影像设备的普及，产生的影像数据量呈爆炸式增长。传统的诊断模式完全依赖放射科医生进行人工阅片，这不仅耗时费力，导致诊断效率难以满足日益增长的临床需求，且极易受医生主观经验、疲劳程度及视觉局限性的影响，存在漏诊误诊的风险。虽然近年来以卷积神经网络（Convolutional Neural Networks, CNN）为代表的深度学习技术发展迅速，但主流的有监督学习方法（如经典的 U-Net 分割网络）在临床落地中面临两大痛点：第一，数据标注成本高昂。有监督模型高度依赖于海量且带有像素级精细标注的“图像-掩膜”对，获取这些标注需要资深放射科医生投入大量时间逐层勾画，成本极高且难以扩展。第二，泛化能力受限。脑部病灶的形态、大小、位置及纹理极具异质性，且部分罕见病变数据稀缺，构成了典型的长尾分布。有监督模型往往难以识别训练集中未曾出现的异常类型，导致在面对未知或罕见病变时容易失效（即“闭集”限制）。

针对上述问题，本课题提出基于扩散模型（Diffusion Models）的无监督异常检测（Unsupervised Anomaly Detection, UAD）研究方案。其核心采用“以正推异”的逆向思维：仅利用易于获取的大量健康人脑 MRI 数据训练模型，使其充分掌握正常脑组织的解剖规律与纹理分布。在推理阶段，模型会将输入的潜在病变图像强制“修复”为健康形态，通过比较修复前后的差异（即残差图）即可自动定位肿瘤区域。这种方法从根本上解决了对大规模病灶标注数据的依赖，大幅降低了算法开发的边际成本，并显著提升了模型对未见异常类型的泛化捕捉能力。

1.2　国内外研究现状

脑部 MRI 异常检测主要面临数据标注稀缺与病灶形态多变的双重挑战。针对这一难题，基于“仅利用健康数据训练”的无监督异常检测范式已成为当前研究的主流。纵观近年来的发展，相关技术路线经历了从有监督学习（Supervised Learning）的 U-Net

网络，到基于自动编码器（AutoEncoder,AE）和生成对抗网络（Generative Adversarial Networks, GAN）的传统生成模型，向基于去噪扩散概率模型（DDPM）的演进，并正逐步向融合视觉-语言模型（VLM）的多模态方向发展。

1.2.1 基于 U-Net 神经网络的有监督分割方法

在深度学习应用于医学影像分析的早期阶段，有监督学习（Supervised Learning）占据了绝对的主导地位。2015 年，Ronneberger 等人提出了 **U-Net** 网络架构，凭借其独特的对称编解码结构，成为了医学图像分割与重构领域的“里程碑”式工作[1]。

U-Net 及其衍生变体（如 3D U-Net, V-Net, nnU-Net）的核心优势在于其巧妙的架构设计：由收缩路径（Contracting Path，即编码器）和扩张路径（Expanding Path，即解码器）组成。编码器通过连续的卷积和池化操作提取图像的高维语义特征，捕获上下文信息（Context）；而解码器则通过上采样操作逐步恢复图像的空间分辨率，实现像素级的精确定位。更为关键的是，U-Net 引入了跳跃连接（Skip Connections）机制，将编码器深层的低分辨率特征与解码器对应层的高分辨率特征进行拼接（Concatenation）。这种机制有效地解决了深层网络中的梯度消失问题，并弥补了下采样过程中丢失的空间位置信息，使得模型在边缘分割和微小病灶重构上表现出卓越的性能。

在脑部肿瘤检测领域，基于 U-Net 的全监督方法长期占据着 BraTS（Brain Tumor Segmentation）等权威挑战赛的榜首。2016 年，Milletari 等人针对医学图像中前景与背景极度不平衡的问题，提出了 V-Net 模型，并引入了基于 Dice 系数的损失函数，显著提升了体积分割的精度[2]。随后于 2021 年，Isensee 等人提出了 **nnU-Net**（no-new-Net）框架，通过自适应地配置预处理、网络拓扑及训练策略，证明了在拥有充足标注数据的情况下，标准的 U-Net 架构足以击败各种复杂的魔改模型，被公认为当前有监督医学分割的 SOTA（State-of-the-Art）基准[3]。

尽管基于 U-Net 的有监督方法在特定任务上达到了极高的精度，但其在临床大规模推广中面临着两个难以逾越的障碍，这也正是本课题转向无监督研究的根本原因：

首先是“标注瓶颈（Annotation Bottleneck）”。有监督模型不仅需要海量的训练数据，更依赖于高质量的像素级专家标注（Pixel-level Annotation）。在脑部 MRI 中，勾画一个胶质瘤的三维体积往往需要资深放射科医生耗费数小时，这使得构建大规模、全覆盖的标注数据集成本极其高昂且不可持续。

其次是“闭集限制（Closed-set Limitation）”。有监督模型只能识别训练集中预先定义好的病变类别（如特定的神经胶质瘤）。面对临床环境中可能出现的罕见病变（如非典型脑膜瘤、转移瘤）或具有未知形态的新发病灶，模型往往会将其误判为背景，即缺乏对“未知异常”的发现能力。相比之下，本课题所采用的基于重构的无监督范式，通过学习健康数据的分布来识别所有偏离正常的“异类”，从原理上突破了有监督方法的类别限制。

1.2.2 基于生成式的无监督重构方法

1）基于自动编码器（AE）的重构异常检测

自动编码器及其变体，对抗自编码器 AE 是早期无监督异常检测领域的主流方法。

其基本架构包含编码器（Encoder）和解码器（Decoder）两部分：编码器将高维输入图像 x 映射为低维潜在向量 z，迫使模型捕捉数据中的核心语义特征；解码器则尝试从 z 中重构出原始图像 $\hat{x}$。

在脑部 MRI 异常检测任务中，AE 类方法遵循“仅在健康数据上训练（One-Class Training）”的范式。其核心假设基于流形学习理论（Manifold Learning Theory）：健康脑部解剖结构在潜在空间中形成紧凑的流形分布，而肿瘤等异常区域不属于该分布。因此，当模型输入包含病灶的测试图像时，由于潜在空间缺乏对异常模式的表达能力，解码器理论上无法正确还原病灶区域，从而在重构图像与原始图像之间产生显著的残差（Residual）。2018 年，Baur 等人系统性地验证了深层自动编码器在脑部 MRI 异常分割中的有效性，通过设定阈值对残差图进行分割，实现了初步的异常定位[4]。

为了进一步规范潜在空间的分布特性，2013 年，Kingma 等人提出了变分自编码器（Variational AutoEncoder, VAE），引入概率图模型思想，将潜在变量建模为高斯分布，并通过优化证据下界（ELBO）来平衡重构误差与 KL 散度[5]。这使得潜在空间更加连续平滑，避免了过拟合。

然而，基于 AE 的方法在实际应用中面临著名的“泛化性悖论（Generalization Paradox）”。由于卷积神经网络（CNN）具有强大的特征拟合能力，且主要关注图像的高频纹理而非全局语义，模型往往倾向于学习“恒等映射（Identity Mapping）”。这意味着即便模型从未见过肿瘤，它也能通过纹理复制的方式“完美重构”出异常区域，导致残差图中缺乏明显的异常信号，从而造成漏检。针对这一问题，后续研究提出了多种改进策略。例如，2019 年，Gong 等人提出了记忆增强自动编码器（Memory-augmented AutoEncoder, MemAE），引入了一个由正常解剖模式构成的记忆矩阵（Memory Bank）。在推理阶段，模型不直接使用编码器的输出，而是从记忆矩阵中检索最相似的“正常”特征项进行线性组合。这种机制强制解码器仅使用“健康零件”来组装图像，从而显著抑制了异常区域的重构能力[6]。尽管如此，AE 类方法通常使用 L2 损失函数（均方误差 MSE），这导致其生成的图像在边缘和纹理细节上往往较为模糊，限制了其在精细脑部 MRI 分析中的应用上限。

2）基于生成对抗网络（GAN）的对抗异常检测

为了解决 AE 生成图像模糊的问题，2014 年，Goodfellow 等人首次提出了生成对抗网络（GAN），通过引入对抗训练机制，利用生成器（Generator）与判别器（Discriminator）之间的极小极大博弈（Minimax Game），能够生成具有高频细节的逼真图像。

在该领域的应用方面，2017 年，Schlegl 等人发表了开创性的 AnoGAN 模型，建立了一种基于逆映射的检测范式。与 AE 的直接推断不同，AnoGAN 在测试阶段将异常检测视为一个迭代优化问题：对于给定的测试图像，固定预训练好的生成器参数，通过反向传播迭代更新输入噪声向量 z，试图在潜在空间中找到最能生成该测试图像的“最佳潜码”。最终的异常评分由像素空间的重构损失（Residual Loss）和判别器特征空间的判别损失（Discrimination Loss）加权构成[7]。虽然 AnoGAN 显著提升了图像清晰度，但其推理过程需要对每张图片进行数百次迭代优化，耗时极长，无法满足临床实时诊断的需求。针对这一缺陷，2018 年，Akcay 等人提出了 GANomaly，采用了“编码器-解码器-编码器”的独特架构，通过比较输入图像的潜在特征与重构图像的潜在

特征之间的距离来判定异常，进一步提升了检测的鲁棒性[8]。2019 年，Schlegl 等人又提出了改进版 f-AnoGAN，引入了一个额外的编码器网络将图像直接映射到潜在空间，将迭代搜索过程转化为一次性的前向推断，大幅提升了检测速度[9]。

尽管基于 GAN 的方法在视觉质量上优于 AE，但其在医学影像分析中仍存在难以克服的局限性：首先是训练的不稳定性。生成器与判别器的平衡难以把控，容易导致梯度消失或梯度爆炸，使得模型难以收敛。其次是“模式崩塌（Mode Collapse）”问题。在训练过程中，模型可能仅学会生成部分常见的脑部解剖结构，而忽略了数据分布中的多样性（如不同年龄段的脑室大小差异），导致对某些正常变异的误报。最后是“幻觉（Hallucination）”风险。由于 GAN 具有强大的创造力，它偶尔会在重构的健康脑部图像中生成原本不存在的解剖结构（如虚假的脑沟或血管），这严重干扰了基于残差的异常定位准确性。

3）基于扩散模型的分布建模与异常修复

近年来，去噪扩散概率模型（Denoising Diffusion Probabilistic Models, DDPM）凭借其卓越的分布建模能力、训练稳定性和生成样本的高保真度，逐渐取代 GAN 成为生成式人工智能领域的新基准（State-of-the-Art）。与 GAN 的对抗博弈机制不同，扩散模型受非平衡热力学的启发，通过定义一个逐步施加高斯噪声的正向扩散过程（Forward Process）和一个通过神经网络学习去噪的逆向生成过程（Reverse Process）来模拟数据分布[?]。

在无监督异常检测（UAD）领域，基于扩散模型的方法主要遵循“重构修复”范式，其核心假设在于：扩散模型仅在健康数据上进行训练，因此学习到了正常解剖结构的先验分布（Prior Distribution）。当面对包含病灶的测试图像时，模型将其视为带有“噪声”或“损坏”的样本，倾向于将其投影回学习到的健康流形（Healthy Manifold）上。具体的实现路径主要分为以下两类：

基于加噪-去噪的隐式修复策略。这一策略利用扩散模型的正向过程作为一种受控的信息破坏手段。对于待测 MRI 图像，首先向其添加特定强度的噪声，使其部分破坏原始的像素分布，尤其是破坏异常病灶的高频纹理特征；随后，利用预训练的去噪网络预测并去除噪声。由于网络从未见过肿瘤特征，它倾向于利用学习到的健康解剖上下文（Context）来填补被噪声破坏的区域，从而将肿瘤区域“修复”为健康组织。Mousakhan 等人提出的 DDAD（Denoising Diffusion Anomaly Detection）框架是该领域的代表性工作，通过调整加噪的时间步（Timestep）t，在保留原始图像大尺度语义结构与去除局部异常纹理之间寻找平衡[10]。然而，医学 MRI 具有高度的结构相关性，普通的高斯噪声容易破坏脑沟回等解剖边缘。对此，Kumar 等人创新性地引入单纯形噪声（Simplex Noise），这种噪声在空间上具有连续性，能迫使模型学习更鲁棒的长距离上下文依赖，从而显著提升了对微小病灶的敏感度[11]。

基于潜在扩散模型（LDM）的高效重构。尽管像素级扩散模型（Pixel-space Diffusion）生成效果细腻，但其计算开销巨大，推理速度极慢，难以满足临床实时处理的需求。Rombach 等人提出的潜在扩散模型（Latent Diffusion Models, LDM）通过引入感知压缩（Perceptual Compression）技术，利用预训练的变分自编码器（VAE）将高维图像空间映射到低维潜在空间（Latent Space），在保留核心语义信息的同时大幅降低

了计算复杂度[?]。

在本课题所关注的脑部 MRI 场景中，LDM 展现出了独特的优势。Pinaya 等人首次将 LDM 应用于脑部异常检测，利用 VAE 的压缩特性过滤掉部分异常的高频信息，再通过扩散过程在潜在空间进行分布校正。这种方法不仅大幅提升了推理速度，还能利用潜在空间的抽象语义特征，缓解传统方法中常见的“结构漂移（Structure Drift）”问题——即模型在修复病灶时错误地改变了正常脑组织的解剖走向，导致虚假残差的产生。如何在高压缩率下保持细粒度的病灶定位能力，同时利用条件引导（Conditioning）机制约束生成过程，是当前该领域研究的热点。

1.2.3 视觉-语言模型（VLM）在医学影像中的前沿探索

随着 CLIP（Contrastive Language-Image Pre-training）、Qwen-VL 等大规模视觉-语言模型（Vision-Language Models, VLM）的爆发，利用自然语言辅助视觉任务成为人工智能领域的新范式。VLM 通过在海量图文对（Image-Text Pairs）上进行对比学习预训练，成功建立了视觉特征空间与文本特征空间之间的语义对齐（Semantic Alignment）。这一突破使得模型能够通过文本提示（Prompt）来理解图像内容，展现出惊人的零样本（Zero-shot）迁移能力。

在异常检测领域，VLM 的引入旨在解决纯视觉模型“语义盲目”的问题。传统的无监督方法仅依赖像素统计规律，缺乏对图像内容的显式理解。而 VLM 允许引入人类知识作为先验。例如，WinCLIP 方法通过构建包含“完美物体”与“受损物体”描述的文本提示模版，直接计算图像与不同文本描述的相似度来实现异常分类，无需任何训练样本[?]。

具体到生成式异常检测中，VLM 主要扮演“语义引导者”的角色：

1）文本引导的生成与修复：Hicsonmez 等人提出的 VLMDiff 将 VLM 生成的图像描述作为语义条件注入扩散模型。通过输入如“一张健康的物体图片”等文本提示，利用交叉注意力机制（Cross-Attention）引导去噪过程向正常语义收敛，有效减少了纯视觉模型因纹理模糊而产生的语义歧义[12]。

2）细粒度语义对齐：针对 CLIP 模型直接用于异常检测时粒度过粗的问题（主要关注中心物体而忽略局部缺陷），Cao 等人提出的 AdaCLIP 设计了混合可学习提示（Hybrid Learnable Prompts），通过优化提示词向量来适应不同的工业缺陷检测场景[13]。在医学领域，Fan 等人提出的 FineGrainedAD 针对医学影像的特殊性，尝试利用多层级文本描述来辅助定位微小病灶[14]。

尽管上述工作展示了 VLM 的巨大潜力，但直接将其迁移至脑部 MRI 异常检测仍面临巨大的“领域鸿沟（Domain Gap）”：首先，通用的 VLM（如 CLIP）主要在自然图像（如 ImageNet、LAION）上训练，缺乏对医学专业术语（如“脑室”、“T2-FLAIR 高信号”）的理解能力。其次，现有的文本引导方法大多未能充分考虑脑部复杂的解剖拓扑结构。简单的文本描述（如“正常的大脑”）无法提供精确的空间约束，导致生成模型在修复过程中容易丢失解剖细节。这正是本课题的研究切入点：即如何设计包含解剖学先验的“专家提示工程（Expert Prompt Engineering）”，并结合空间结构约束，将 VLM 的通用语义理解能力转化为对特定医学病灶的精准定位能力。

1.3 研究内容和研究目标

本课题旨在构建一种基于潜在扩散模型（Latent Diffusion Models, LDM）的脑部MRI无监督异常检测与定位算法。LDM通过在低维潜在空间进行扩散过程，大幅降低了计算复杂度。本研究的具体目标包括：建立基于BraTS 2021数据集的One-Class实验基准；提出融合空间结构与语义信息双重引导的条件机制，解决重构过程中的结构漂移问题；最终实现对脑胶质瘤的像素级精准定位。如图 1-3所示为本课题的核心研究目标概览。

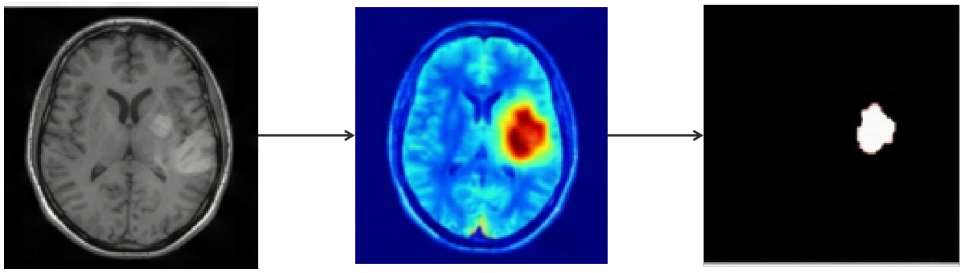

图 1-3 课题研究核心目标图

为了实现上述目标，本论文将围绕以下三个核心层面展开深入研究：

1. **基于领域掩码网络的空间特征条件建模：**针对纯生成模型在重构过程中容易丢失原始解剖结构细节的问题，研究构建混合架构的空间特征提取模块。该模块首先利用卷积神经网络（CNN）提取T2-FLAIR图像具有平移不变性的局部纹理特征。为了增强模型对上下文信息的推断能力并防止模型在训练阶段发生“死记硬背”（即恒等映射），引入领域掩码（Masked）策略，随机遮蔽部分特征块。随后，应用Transformer架构处理未被遮蔽的特征序列，通过自注意力机制捕获像素间的长距离依赖关系，最终生成具备全局解剖布局感知的空间特征向量。该特征将作为强几何约束，确保模型生成的图像严格遵循原始脑部的拓扑结构。

2. **基于VLM的细粒度医学语义文本生成：**研究视觉-语言模型（如CLIP, Qwen-VL等）在医学影像中的跨模态对齐与迁移能力。针对传统提示词过于笼统的问题，设计包含解剖学先验的专家提示工程（Expert Prompt Engineering），例如详细描述脑室的形状、脑沟回的纹理等正常形态。利用预训练的VLM对训练集中的健康切片进行批量推理，生成包含全局模态信息与局部纹理细节的文本描述，并利用文本编码器将其编码为高维语义向量。这一过程旨在将人类医学知识注入到纯视觉模型中，提升模型对“正常解剖”的语义理解。

3. **多条件引导下的潜在扩散重构模型构建：**为了降低高分辨率医学图像的计算开销，研究基于变分自编码器（VAE）的感知压缩技术，将图像映射至低维潜在空间。在此基础上，搭建U-Net结构的去噪网络。本部分重点研究如何将前述两部分特征进行有效融合：即，将领域掩码网络提取的全局空间结构特征（内容一）作为额外的条件通道（Conditional Channel）嵌入模型，同时通过交叉注意力（Cross-Attention）机制注入由VLM生成的细粒度语义文本向量（内容二）。通过这种“空间 + 语义”的双重引导机制，指导去噪过程严格向“正常解剖结构”收敛，防止正常组织被误改。最后，从图

像级别（Image-level）和像素级别（Pixel-level）综合评估模型的异常检测性能，并设计基于 L1 距离的异常评分机制，生成高精度的异常热力图，实现对脑肿瘤的自动定位。

2　基于领域掩码网络的空间特征条件建模

2.1　基于 CNN 的多尺度局部特征编码

在构建基于领域掩码网络的空间特征条件建模模块时，首要任务是将输入的原始磁共振影像（MRI）转化为富含语义信息的高维特征表示。尽管 Transformer 架构在捕捉全局长距离依赖方面表现卓越，但其在处理底层视觉信号时缺乏归纳偏置（Inductive Bias），即对图像局部性（Locality）和平移不变性（Translation Invariance）的先天假设。对于脑部 T2-FLAIR 模态影像而言，病灶的边缘、脑沟回的纹理以及灰白质的界限等关键解剖信息均蕴含在局部像素邻域内。若直接将原始像素展平输入 Transformer，不仅会带来巨大的计算开销，且模型难以有效地聚焦于这些细微的底层视觉特征。

因此，本研究设计了一个基于卷积神经网络（Convolutional Neural Networks, CNN）的深层局部特征提取器。该模块作为“视觉词法分析器（Visual Tokenizer）”，负责在进入 Transformer 全局建模之前，对图像进行多尺度的空间下采样与通道维度的语义升维，为后续的掩码建模提供紧凑且富有表现力的“视觉 Token”。

为了在保留关键解剖细节的同时实现特征的空间压缩，本研究构建了一个多级级联的卷积编码网络 $\mathcal{E}_{cnn}$。如图 2-1 所示，该网络摒弃了传统的大卷积核设计，转而采用堆叠的小尺寸卷积核（3×3）策略，旨在通过增加网络深度来获得更大的有效感受野（Effective Receptive Field），同时控制参数量。

待补充：CNN 编码器的详细层级结构图（展示特征图尺寸变化 $H \to H/2 \to H/4 \to H/8$ 及通道数变化 $1 \to 16 \to 256$）

图 2-1　多尺度局部特征编码器 $\mathcal{E}_{cnn}$ 的网络拓扑结构示意图

具体而言，对于输入的单通道 T2-FLAIR 切片 $x \in \mathbb{R}^{H \times W \times 1}$，编码过程可以形式化地描述为一系列卷积操作 $\mathcal{F}_{conv}$ 与非线性激活 σ 的复合函数。我们设计的网络包含四个主要的特征提取阶段（Stage），每个阶段内部包含特征提取层与下采样层：

1. 浅层特征提取阶段（Stage 1）：输入图像首先经过两层连续的卷积操作。第一层卷积负责将单通道图像映射到特征空间（$C_{in} = 1 \to C_{out} = 16$），第二层卷积在保持分辨率不变的情况下进一步提炼纹理特征。此阶段的卷积步长（Stride）设定为 1，填

充（Padding）设定为 1，以保证特征图的空间尺寸与原图一致。数学表达如下：

$$F_1 = \sigma(W_2\sigma(W_1x + b_1) + b_2) \tag{2-1}$$

其中，w 表示二维卷积运算，W_k 和 b_k 分别表示第 k 层的卷积核权重与偏置。此阶段提取的特征主要对应于图像中的边缘、角点等高频信息。

2. 语义抽象与空间降维阶段（Stage 2 - Stage 4）：随后的三个阶段构成了特征编码的核心。每个阶段的起始层均采用步长为 2 的卷积操作（Stride=2 Convolution）代替传统的最大池化（Max Pooling）。这种设计允许网络在下采样的过程中通过学习权重来自适应地选择保留哪些信息，避免了池化操作可能带来的细节丢失。随着网络深度的增加，我们依照“空间换通道（Space-for-Channel）”的设计原则，逐步增加特征通道数。具体变化路径为：$16 \to 32$（Stage 2），$32 \to 96$（Stage 3），$96 \to 256$（Stage 4）。最终输出的特征图 F_{local} 的维度为 $256 \times (H/8) \times (W/8)$。

这一层次化的通道扩张设计具有深刻的理论依据：在浅层，特征图分辨率高，主要编码几何纹理；在深层，分辨率降低，为了能够区分复杂的解剖结构（如区分肿瘤核心与水肿带），需要更高维度的特征空间来承载丰富的语义组合。最终的 256 维特征向量不再代表单一的像素强度，而是对应于原图中 8×8 区域内的高度抽象的解剖概念。

在激活函数采用了 SiLU（Sigmoid Linear Unit，又称为 Swish）激活函数。SiLU 函数定义为输入与其 Sigmoid 函数的乘积：

$$\mathrm{SiLU}(x) = x \cdot \sigma(x) = x \cdot \frac{1}{1 + e^{-x}} \tag{2-2}$$

卷积神经网络的核心属性在于其感受野（Receptive Field, RF）。为了确保最终生成的每一个特征 Token 都能充分感知到足够的解剖上下文，我们必须严格计算编码器的有效感受野。

对于第 l 层卷积，其感受野 r_l 与上一层感受野 r_{l-1} 的关系满足递归公式：

$$r_l = r_{l-1} + (k_l - 1) \times j_{l-1} \tag{2-3}$$

其中，k_l 为卷积核大小（本研究中固定为 3），j_{l-1} 为累积步长（Cumulative Stride）。由于我们在 Stage 2, 3, 4 分别进行了步长为 2 的下采样，累积步长呈指数级增长：$j_{out} = 2 \times 2 \times 2 = 8$。

经过 8 层 3×3 卷积的堆叠，理论感受野涵盖了输入图像中相当大的区域。这意味着，特征图 F_{local} 中的每一个点 $f_{i,j}$，虽然在空间上仅占据 1×1 的位置，但其数值实际上聚合了原图中超过 30×30 像素范围内的上下文信息。

这种多尺度信息的聚合对于后续的“领域掩码”操作至关重要。我们在后续章节中实施的掩码操作是基于特征图进行的。由于特征图的一个点已经包含了原图的一个局部块（Patch）的信息，在特征图上进行 1×1 的掩码，等效于在原图上遮挡了一个 8×8 的连续区域。这保证了掩码操作具有足够的“破坏力”，能够彻底抹除潜在病灶的局部纹理，迫使模型必须依赖远距离的全局上下文（如脑部的对称性）来进行重构，从而完美契合了“以正推异”的异常检测逻辑。

综上所述，基于 CNN 的多尺度局部特征编码模块不仅完成了从像素空间到特征空

间的映射，更通过层级化的下采样和通道扩张，实现了视觉信息的语义压缩。它生成的特征图 F_{local} 兼具高频纹理细节与中层解剖语义，为后续基于 Transformer 的全局关联建模提供了高质量的输入基元。

2.2 邻域屏蔽机制与掩码矩阵构建

在无监督异常检测的图像重构任务中，模型面临着一个根本性的矛盾：即“强大的重构能力”与“对异常的敏感性”之间的权衡。传统的卷积神经网络（CNN）由于其卷积核的局部共享特性，具有极强的纹理拟合能力。当输入包含肿瘤的脑部 MRI 图像时，模型往往倾向于寻找一条“捷径（Shortcut）”，即直接利用感受野内的局部高频纹理信息，通过像素级的恒等映射（Identity Mapping）来完美还原输入。这种“死记硬背”式的重构会导致病灶区域被原样保留，使得输入图像与重构图像之间的残差极小，从而导致异常检测算法的失效（漏检）。为了从根本上阻断这种局部信息的直接泄露，本研究提出了一种基于确定性邻域屏蔽（Neighborhood Masking）的注意力偏置策略。该策略的核心思想是“由远及近”的逆向推断：强制模型在推断特征图中任意位置的语义表示时，对其空间邻域内的所有信息视而不见，仅允许利用图像中远距离的全局上下文信息（如脑组织的对称性、宏观解剖布局）进行重构。

为了在数学上严格定义这一屏蔽机制，首先需要构建特征空间中的邻域拓扑结构。假设经由前端卷积编码器提取的特征图为 $F \in \mathbb{R}^{h\times w\times d}$，我们将特征图展平为长度为 $L = h \times w$ 的节点序列。对于序列中的任意一个查询节点（Query Node）u，其对应的二维空间坐标记为 (i_u, j_u)。我们定义节点 u 的邻域集合 $\mathcal{N}_u$ 为以该点为中心、空间窗口大小为 $K \times K$ 的矩形区域内所有特征点的集合。这里引入切比雪夫距离（Chebyshev Distance，即 L_∞ 范数）来形式化描述这一空间约束：

$$\mathcal{N}_u = \left\{ v \in \{1, \ldots, L\} \mid \max(|i_u - i_v|, |j_u - j_v|) \le \lfloor \frac{K}{2} \rfloor \right\} \tag{2-4}$$

其中，K 对应于超参数 $neighbor_size$ 领域掩码的范围。尽管该邻域在下采样后的特征图上仅覆盖局部区域，但考虑到卷积神经网络层级累积的有效感受野（Effective Receptive Field），该区域在原始分辨率图像上实际上对应着包含潜在病灶及其周边水肿带的较大解剖范围。屏蔽该区域意味着切断了病灶自身纹理信息向特征表达传播的物理路径。

基于上述邻域定义，我们构建了一个与自注意力图（Attention Map）尺寸严格对应的掩码偏置矩阵 $M \in \mathbb{R}^{L\times L}$。不同于自然语言处理中常用的上三角因果掩码，本研究设计的掩码矩阵具有特殊的带状稀疏结构。矩阵中的每一个元素 $M_{u,v}$ 代表了查询节点 u 与键值节点 v 之间的可访问性偏置。其赋值规则如下：

$$M_{u,v} = \begin{cases} -\infty, & \text{if } v \in \mathcal{N}_u \quad (\text{即} v \text{ 位于} u \text{ 的屏蔽邻域内}) \\ 0, & \text{otherwise} \quad (\text{即} v \text{ 位于} u \text{ 的全局背景区域}) \end{cases} \tag{2-5}$$

该矩阵的物理意义在于构建一道“信息防火墙”。如图 2-2 所示，在矩阵的可视

化热力图中，对角线及其附近的带状区域呈现为深色（代表负无穷大），而远离对角线的区域呈现为浅色（代表零）。当该矩阵被注入到后续 Transformer 的 Softmax 计算环节时，根据公式 $\lim_{x\to-\infty} e^x = 0$，所有落入屏蔽邻域 $\mathcal{N}_u$ 内的键值对的注意力权重将被强制归零。

待补充图片：邻域屏蔽掩码矩阵的构建原理与可视化
左图：特征图空间示意，展示中心点（红色）及其 $K \times K$ 邻域（灰色阴影）；
右图：对应的 $L \times L$ 掩码矩阵热力图，展示对角线附近的“盲区”带状结构。

图 2-2　邻域屏蔽掩码矩阵构建示意图。左图展示了基于切比雪夫距离的空间邻域定义；右图展示了对应的注意力偏置矩阵，其中深色区域（$-\infty$）阻断了局部信息的流动，迫使模型仅关注远距离的全局上下文。

这种机制将异常检测转化为一种特殊的“盲点修复（Blind-spot Inpainting）”任务。对于特征图上的每一个点，模型都处于“灯下黑”的状态，无法看见该点及其周边的原始像素。因此，为了生成该点的特征表示，模型被迫去寻找与该点具有长程相关性的健康区域。例如，在处理左脑半球的潜在肿瘤区域时，由于局部信息被屏蔽，模型会自发地利用右脑半球对称位置的健康特征，结合脑室、颅骨等宏观解剖地标的相对位置关系，来推断该区域应有的健康形态。这种强制性的全局上下文依赖，不仅有效抑制了对异常纹理的重构，还使得生成的特征图蕴含了丰富的健康解剖先验，为后续扩散模型的去噪过程提供了强有力的结构引导。

2.3　基于 Transformer 的全局上下文聚合

在经由前述卷积神经网络提取得到局部特征图，并构建了基于邻域屏蔽的注意力掩码矩阵之后，本研究的核心任务转变为如何利用这些离散的、被屏蔽了局部信息的特征点，重构出具有全局解剖一致性的空间条件向量。为此，我们引入了基于 Transformer 的全局上下文聚合模块。与 CNN 受限于局部感受野不同，Transformer 凭借其自注意力机制（Self-Attention Mechanism），能够直接建立图像中任意两个位置之间的依赖关系，从而捕获跨越整个脑部的长距离语义关联（Long-range Dependencies）。这一特性对于“以正推异”的异常检测至关重要，因为它允许模型利用远离病灶区域的健康脑组织（如对侧脑半球的对称结构）来推断并修复潜在的异常区域。

由于 Transformer 的输入必须是二维序列而非三维张量，我们首先通过重排操作（Rearrange）将尺寸为 $B \times C \times H \times W$ 的特征图展平为长度为 $L = H \times W$ 的视觉序列

（Visual Tokens）。然而，这一展平过程不可避免地破坏了特征点在原始图像中的二维拓扑结构信息。在医学脑部影像中，解剖结构的绝对位置（例如，脑室位于中央，皮层位于边缘）包含着极强的先验信息，对于判断结构的合理性至关重要。为了弥补这一空间信息的缺失，我们在进入注意力层之前，引入了显式的二维正弦位置编码（2D Sinusoidal Position Embedding）。该编码策略通过不同频率的正弦和余弦函数，为每一个特征 Token 赋予唯一的空间坐标标识。

$$P_{(pos,2i)} = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right), \quad P_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right) \tag{2-6}$$

具体而言，对于特征图上的任意位置 (x, y)，我们分别计算其横坐标和纵坐标的位置向量，并将两者拼接或叠加，生成最终的位置嵌入 $P_{xy} \in \mathbb{R}^C$。该位置向量与视觉特征序列相加后输入编码器，确保了模型在后续的全局交互中始终“知晓”每个特征点在解剖空间中的确切方位，从而维持脑部结构的整体几何布局稳定性。

全局上下文聚合的核心计算过程发生在多层堆叠的 Transformer 编码器中，其关键在于将前一节构建的邻域屏蔽掩码矩阵 M 深度融入自注意力运算。形式化地，设第 l 层的输入序列为 $Z^{(l-1)}$，通过线性投影矩阵 W_Q, W_K, W_V 映射得到查询（Query）、键（Key）和值（Value）矩阵。标准的缩放点积注意力公式在此被修正为：

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}} + M\right)V \tag{2-7}$$

在此公式中，掩码矩阵 M 发挥了物理阻断作用。对于任意查询节点 u，由于其邻域 $\mathcal{N}_u$ 内对应位置在 M 中的值为负无穷（$-\infty$），经过 Softmax 指数归一化后，这些位置的注意力权重 $\alpha_{u,v}$ 恒等于零。这意味着，模型在更新节点 u 的特征表示时，被强制禁止“偷看”其周围 $K \times K$ 范围内的原始纹理信息。相反，输出特征 z_u 只能由邻域之外的远距离特征点加权聚合而成。这种机制在特征空间内实现了一种隐式的“上下文修复（Contextual Inpainting）”：即便输入图像在位置 u 存在高信号的肿瘤病灶，由于模型无法感知该位置及其周边的异常纹理，它只能根据全脑的解剖上下文（如利用左右脑对称性、脑沟回的宏观走向），“猜测”并生成该位置在健康状态下应有的特征表示。

经过 N 层编码器的深度交互，输出的特征序列不仅去除了局部的异常细节，还高度融合了全脑的健康解剖先验。最后，我们执行逆向的重排操作，将序列还原为二维空间特征图 $F_{spatial} \in \mathbb{R}^{B\times C\times H\times W}$。该特征图不再是对输入图像的简单复制，而是一张经由健康流形投影后的“解剖蓝图”。当这张蓝图作为条件控制信号（Control Signal）注入后续的扩散模型时，它将提供强有力的几何约束，指导去噪网络在生成逼真纹理的同时，严格遵循正常脑组织的拓扑结构，从而有效解决了传统生成模型中常见的结构漂移问题，为实现高精度的像素级肿瘤定位奠定了坚实基础。

待补充图片：基于 Transformer 的全局上下文聚合与特征重构流程图

图 2-3　Transformer 全局聚合过程示意图。通过位置编码注入空间信息，并利用掩码注意力机制聚合远距离特征，最终重构出仅包含健康解剖先验的空间条件图。

2.4　本章小结

本章聚焦于解决无监督异常检测中重构模型容易产生恒等映射从而导致“死记硬背”的核心难题，提出了一种基于领域掩码网络的空间特征条件建模方法。

首先，针对原始像素空间维度过高且语义稀疏的问题，本章构建了基于卷积神经网络的多尺度局部特征编码器。该模块作为视觉词法分析器，有效地提取了 T2-FLAIR 图像中包含边缘、纹理等高频信息的底层视觉特征，将其压缩为紧凑的特征 Token，为后续的全局建模奠定了基础。

其次，为了阻断模型利用局部纹理直接复制病灶的“捷径”，本章创新性地设计了邻域屏蔽机制。通过构建基于切比雪夫距离的掩码矩阵，物理上阻断了特征点与其周围局部邻域的信息交互，迫使模型在重构过程中无法依赖病灶本身的像素信息，只能寻求远距离的上下文线索。

最后，本章引入了基于 Transformer 的全局上下文聚合模块。利用自注意力机制捕获脑部解剖结构的长距离依赖关系（如对称性），在被屏蔽的特征空间内实现了隐式的“健康修复”。这一过程生成了仅包含健康解剖先验的空间条件特征，为后续扩散模型的去噪过程提供了强有力的几何结构约束，有效防止了结构漂移现象的发生。

3 基于 VLM 的细粒度医学语义文本生成

尽管前述章节构建的基于领域掩码网络的空间特征模块能够通过物理屏蔽手段有效地捕捉脑部的几何解剖布局，但纯视觉的卷积神经网络或 Transformer 架构依然存在一个本质的局限性——“语义盲目性（Semantic Blindness）”。具体而言，视觉模型虽然能够通过像素统计规律恢复出“具有某种灰度分布的形状”，但它并不能真正理解该结构在医学影像学上对应的是“侧脑室”、“基底节”还是“脑沟”。这种对高层语义理解的匮乏，使得模型在处理外观相似但解剖意义截然不同的区域时，容易产生结构漂移或伪影，难以建立起真正的“健康脑部”概念。

为了赋予模型对正常脑部解剖结构的深层认知能力，本研究引入了当前自然语言处理与多模态学习领域的 SOTA 模型——**Qwen3-30B**。利用其高达 300 亿参数的庞大知识库以及在海量多模态医学数据上的指令微调（Instruction Tuning）能力，我们旨在搭建一座桥梁，将人类放射科专家的隐式医学知识转化为显式的、细粒度的文本描述。这一过程不再依赖于简单的人工标签，而是通过生成式人工智能自发产生的详尽诊断报告，为异常检测模型提供强有力的语义条件引导。

3.1 医学专家提示工程与正常解剖描述生成

为了赋予纯视觉模型对正常脑部解剖结构的深层认知能力，解决其在医学语义理解上的匮乏，本研究利用 Qwen3-30B 强大的多模态理解与生成能力，构建了医学专家提示工程（Medical Expert Prompt Engineering）。该模块的核心目标是将隐含在图像像素中的解剖学信息转化为显式的、细粒度的自然语言描述。不同于以往方法中仅使用简单的类别标签，本节旨在生成包含丰富解剖细节的稠密描述（Dense Caption），从而为后续的特征对齐提供高信息量的语义锚点。

尽管通用的视觉-语言模型具备广泛的知识，但在面对 T2-FLAIR MRI 这种特定医学模态时，必须通过精确的指令（Instruction）来激活其专业领域的潜在知识。为了确保生成的文本能够精准描述健康脑部的解剖特征，我们设计了一套系统级的全英文指令策略。该策略摒弃了传统诊断中“寻找病灶”的逻辑，转而采用“正向解剖描述（Positive Anatomical Description）”范式，要求模型聚焦于正常组织的形态学特征。具体使用的提示词（Prompt）设计如下：

> **Role:** Senior Neuroradiologist.
> **Task:** Analyze this axial T2-FLAIR brain MRI of a healthy subject. Generate a concise anatomical report of normal features.
> **Focus Requirements:** Please systematically evaluate the following regions: First, observe the **Ventricles**, noting their symmetry, shape, and characteristic hypointense signal; Second, examine the **Parenchyma** for homogeneity and distinct grey-white matter differentiation; Third, check the **Sulci/Gyri** to ensure normal folding patterns without effacement; Finally, confirm the **Overall** bilateral symmetry of

hemispheric structures.
Constraint: Output only healthy attributes suitable for medical reporting. Do not generate hallucinations or describe potential pathologies.

上述提示工程的设计蕴含了三个层面的深层医学逻辑。首先是**角色设定（Role Assignment）**，通过设定“资深神经放射科医生”的上下文，有效诱导模型使用如“低信号（hypointense）”、“脑实质（parenchyma）”等专业术语，而非通俗的自然语言。其次是**先验植入（Prior Injection）**，明确告知模型输入图像来自“健康受试者”，强制模型挖掘图像中支持“健康”结论的视觉证据，从源头上抑制了大模型常见的幻觉问题（Hallucination）。最后是**关注点引导（Attention Guidance）**，通过在文本中显式列出脑室、脑实质、脑沟回等解剖结构，强迫模型的视觉注意力机制（Attention Map）遍历整个脑部区域，避免模型仅关注图像中心而忽略边缘细节。

利用上述提示工程，我们对训练集中所有的健康脑部 MRI 切片进行了批量推理，生成了高质量的稠密文本描述。例如，模型针对某张训练图像生成的典型描述为：*”The axial T2-FLAIR image demonstrates a normal brain anatomy. The bilateral lateral ventricles are symmetrical in size and shape, presenting with characteristic low signal intensity consistent with clear cerebrospinal fluid. The grey-white matter interface is well-preserved and distinct throughout both hemispheres...”*。这段生成的文本具有极高的利用价值，其中包含的”symmetrical”（对称）、”distinct”（清晰）、”homogeneous”（均匀）等形容词，在经过后续的文本编码器处理后，将转化为高维特征空间中的强约束向量。它们定义了“正常的纹理”和“合理的结构”标准，能够有效指导扩散模型在去噪过程中抑制异常伪影的生成，确保重构图像严格遵循健康解剖学规律。

3.2 基于多头交叉注意力的语义条件注入机制

在前一阶段，我们通过医学专家提示工程获得了富含解剖学先验的文本描述，并利用预训练文本编码器将其转化为高维语义嵌入序列 C_{sem}。然而，如何将这种非结构化的语义序列有效地融合进二维的视觉生成过程中，是本算法的核心难点。简单的特征拼接（Concatenation）无法处理跨模态数据的维度不匹配问题，且难以捕捉复杂的语义对应关系。为此，本研究在扩散模型的 U-Net 主干网络中设计了基于空间转换器（Spatial Transformer）的语义注入模块。该模块利用多头交叉注意力（Multi-Head Cross-Attention, MHCA）机制，在潜在特征空间内动态建立视觉像素与医学文本描述之间的深层逻辑关联，实现从“语义理解”到“视觉重构”的精准映射。

视觉-语义特征空间的维度对齐。在 U-Net 的去噪过程中，不同层级的中间特征图 $\phi(z_t) \in \mathbb{R}^{H\times W\times C}$ 包含了不同粒度的图像信息。为了引入文本条件，首先需要解决模态间的维度差异。我们将二维的视觉特征图在空间维度上展平，转化为视觉序列 $X_{vis} \in \mathbb{R}^{L\times C}$，其中 $L = H \times W$ 为视觉标记（Token）的数量。与此同时，文本编码器输出的语义条件为 $C_{sem} \in \mathbb{R}^{M\times D}$，其中 M 为文本序列长度，D 为语义特征维度。由于 C 与 D 通常并不一致，我们引入可学习的 1×1 卷积层对视觉特征进行通道变换，使其投影到与文本特征相同的潜在交互维度 d_{model}，从而为后续的注意力计算构建统一的

度量空间。

多头交叉注意力机制的数学建模。为了捕捉视觉区域与多种解剖概念（如形状、纹理、位置）之间的复杂依赖，本研究采用多头机制代替标准的单头注意力。具体而言，我们将投影后的视觉序列作为查询（Query），将文本语义序列作为键（Key）和值（Value）。这一设计蕴含了明确的导向性逻辑：即“视觉图像主动向文本知识库查询其应有的健康形态”。对于第 i 个注意力头（Head i），其计算过程定义如下：

$$Q_i = X_{vis} \cdot W_Q^{(i)}, \quad K_i = C_{sem} \cdot W_K^{(i)}, \quad V_i = C_{sem} \cdot W_V^{(i)} \tag{3-1}$$

其中，$W_Q^{(i)}, W_K^{(i)}, W_V^{(i)} \in \mathbb{R}^{d_{model} \times d_{head}}$ 为第 i 个头的独立线性投影矩阵，$d_{head} = d_{model}/N_h$ 为每个头的维度，N_h 为头数。随后，利用缩放点积（Scaled Dot-Product）计算视觉与语义的相关性权重，并加权聚合文本信息：

$$\text{Head}_i = \text{Softmax}\left(\frac{Q_i K_i^T}{\sqrt{d_{head}}}\right) V_i \tag{3-2}$$

在此公式中，Softmax 生成的注意力图（Attention Map）起到了关键的“语义导航”作用。例如，当 Q_i 对应于图像中的脑室区域时，它会与 K_i 中代表“低信号”、“对称”等描述词的向量产生高响应，进而抽取对应的 V_i 向量。最终，多头注意力的输出通过拼接与线性变换融合：

$$\text{MHCA}(X_{vis}, C_{sem}) = \text{Concat}(\text{Head}_1, \ldots, \text{Head}_{N_h}) \cdot W_O \tag{3-3}$$

前馈网络与残差融合。单纯的注意力机制仅能捕捉线性相关性，为了增强模型的非线性表达能力并防止梯度消失，我们将 MHCA 嵌入到一个完整的 Transformer 块中。该块包含层归一化（Layer Normalization, LN）和前馈神经网络（Feed-Forward Network, FFN）。FFN 由两个线性层和 GELU 激活函数组成，用于对聚合后的特征进行进一步的语义提炼。整个注入过程采用残差连接（Residual Connection）方式：

$$X'_{vis} = \text{LN}(X_{vis} + \text{MHCA}(X_{vis}, C_{sem})) \tag{3-4}$$

$$X_{out} = \text{LN}(X'_{vis} + \text{FFN}(X'_{vis})) \tag{3-5}$$

最后，利用重排操作（Rearrange）将输出序列 X_{out} 还原为二维特征图 $\mathbb{R}^{H \times W \times C}$，继续参与 U-Net 的后续卷积运算。

基于语义引导的异常修正机制。上述机制在异常检测任务中扮演了“纠错器”的角色。当输入图像包含肿瘤（即异常的高信号区域）时，其生成的视觉查询向量 $Q_{anomaly}$ 与描述健康脑组织的文本键向量 $K_{healthy}$ 存在显著的语义冲突（例如，肿瘤的“高亮不规则”特征无法匹配文本中的“均匀低信号”描述）。在这种情况下，交叉注意力机制会强制模型关注最接近的健康语义描述（如“正常脑实质”），并利用对应的 Value 向量重构该区域。这种强制性的语义对齐导致重构出的图像在该区域表现为健康的组织纹理，从而与原始输入产生巨大的像素差异（残差），不仅实现了对肿瘤的抑制，更为后续的异常热力图生成提供了高对比度的差分信号。

3.3 基于 CFG Drop 的鲁棒推理与异常评分策略

训练阶段使用的是针对单张图像生成的稠密描述（Dense Caption），其中包含了该图像特有的解剖细节；而在推理阶段，如果继续使用对测试图像（可能包含肿瘤）生成的详细描述，文本信息可能会意外泄露病灶的存在（例如描述中出现“高信号区域”），导致模型“忠实”地重构出肿瘤，从而使异常检测失效。为了解决这一训练与推理之间的信息不对称问题，并增强模型对“健康”语义的强制约束力，本研究提出了结合条件丢弃（Condition Drop）训练与无分类器引导（Classifier-Free Guidance, CFG）推理的鲁棒策略。

基于贝努力掩码的随机条件丢弃训练。为了防止扩散模型在训练过程中过度拟合文本条件 C_{sem}，从而退化为简单的文本到图像的映射工具，我们在训练循环中引入了随机条件掩码机制。假设训练样本的文本嵌入为 C_{sem}，我们定义一个服从贝努力分布的随机变量 $b \sim \text{Bernoulli}(1 - p_{drop})$，其中 p_{drop} 为丢弃概率（本研究设定为 0.1）。在每一次训练迭代中，实际输入网络的条件 C_{train} 根据下式确定：

$$C_{train} = b \cdot C_{sem} + (1 - b) \cdot \emptyset \tag{3-6}$$

其中，$\emptyset \in \mathbb{R}^{M \times D}$ 是一个可学习的空嵌入向量（Null Embedding），代表语义信息的完全缺失。这种训练策略迫使 U-Net 去噪网络同时学习两个互补的任务：一是在给定详细医学文本时的“条件生成分布”$p(x|C_{sem})$，二是在没有任何语义提示时的“无条件生成分布”$p(x|\emptyset)$。这种双重优化机制使得模型在潜在空间中建立的健康流形更加稳健，能够自适应地处理不同强度的语义引导。

基于通用提示词的 CFG 推理机制。在测试阶段，为了规避潜在的病灶信息泄露，我们不再使用图像特定的稠密描述，而是采用一个全局通用的类别级提示词（Class-level Prompt）：*”A T2-FLAIR MRI scan of a healthy brain”*。该提示词充当了“健康锚点”，旨在激活模型中关于正常脑部解剖的全局先验。为了放大这一健康先验的约束力，我们采用无分类器引导（CFG）采样策略。在逆向扩散的每一步 t，模型预测的最终噪声 $\tilde{\epsilon}_\theta$ 由无条件预测项和有条件预测项线性组合而成：

$$\tilde{\epsilon}_\theta(z_t, c_{generic}) = \epsilon_\theta(z_t, t, \emptyset) + s \cdot \left[\epsilon_\theta(z_t, t, c_{generic}) - \epsilon_\theta(z_t, t, \emptyset)\right] \tag{3-7}$$

在此公式中，s 被称为引导尺度（Guidance Scale）。当 $s > 1$ 时，模型生成的方向将被强制推向文本 $c_{generic}$ 所描述的“健康语义中心”，并远离无条件的平均分布。在物理意义上，这意味着即使输入图像 z_t 中隐含了肿瘤的特征，强大的引导尺度 s 也会迫使去噪过程忽略这些异常信号，转而利用通用提示词中的“健康”概念来填补和修复该区域。这种机制显著增强了模型对异常区域的“纠错”能力。

3.4 本章小结

本章针对传统无监督异常检测方法中存在的“语义盲目性”与“结构漂移”问题，深入探讨了如何利用视觉-语言模型（VLM）为潜在扩散模型引入细粒度的医学语义引导。

首先，本章提出了一种基于 Qwen3-30B 的医学专家提示工程策略。通过设计包含角色设定、先验植入与关注点引导的系统级指令，成功地将难以量化的脑部 MRI 图像特征转化为显式的、包含丰富解剖学细节的自然语言描述，从而构建了高质量的健康语义先验库。这一步骤有效地打破了纯视觉模型在理解复杂医学解剖结构时的认知局限。

其次，针对多模态特征融合的难点，本章构建了基于多头交叉注意力（MHCA）的语义条件注入机制。该机制通过在 U-Net 的潜在空间内建立视觉查询与文本键值之间的动态映射，实现了从抽象语义到具体像素重构的精准控制。这种设计不仅解决了跨模态数据的维度对齐问题，更赋予了模型利用语义信息修正视觉缺陷的能力。

最后，为了解决训练与推理阶段的条件不一致性，并强化模型对“健康”分布的依从性，本章设计了结合随机条件丢弃（Condition Drop）与无分类器引导（CFG）的鲁棒推理策略。通过在推理阶段引入通用的类别级提示词并放大引导尺度，强制模型忽略输入图像中的病灶信号，将其“修复”为符合解剖学规律的健康组织。

4 多条件引导下的潜在扩散重构模型构建与训练

在前两章中，我们分别构建了基于领域掩码网络的空间特征提取模块，以及基于视觉-语言模型（VLM）的医学语义条件生成模块。这两个模块分别从几何拓扑结构和高层解剖语义两个维度，为“健康的脑部应该是什么样”提供了强有力的先验知识。本章的核心任务是将这两种不同模态、不同维度的条件特征进行有效融合，并嵌入到去噪扩散概率模型的生成过程中。为了解决高分辨率医学图像带来的巨大计算开销，本研究采用潜在扩散模型（Latent Diffusion Models, LDM）架构，在低维潜在空间中完成受控的“加噪-去噪”过程，并最终基于重构残差实现对脑肿瘤的像素级定位。

4.1 基于 VAE 的潜在空间映射与感知压缩

传统的扩散模型（如 DDPM）直接在像素空间（Pixel Space）进行操作。对于临床中常见的高分辨率脑部 MRI 切片（例如 256×256 或更大），在包含数万甚至数十万像素的空间中逐时间步地预测噪声，不仅极大地消耗了显存与算力，而且导致推理速度极慢，无法满足临床实际应用的需求。为了打破这一计算瓶颈，本研究引入了感知压缩（Perceptual Compression）技术，利用预训练的变分自编码器（Variational AutoEncoder, VAE）将高维像素数据映射到一个低维的、语义密集的潜在空间（Latent Space）中进行扩散操作。

如图 4-1 所示，感知压缩机制由一个编码器 $\mathcal{E}$ 和一个解码器 $\mathcal{D}$ 组成。对于输入的原始 T2-FLAIR 切片 $x \in \mathbb{R}^{H \times W \times 1}$，编码器 $\mathcal{E}$ 首先将其向下采样，提取出高度抽象的潜在表示 $z = \mathcal{E}(x)$，其维度为 $z \in \mathbb{R}^{h \times w \times c}$。在本课题的实验设置中，下采样因子设为 $f = H/h = W/w = 8$，通道数 c 设为 4。这意味着，原始的 256×256 图像被压缩为了 $32 \times 32 \times 4$ 的低维张量。

待补充图片：基于 VAE 的图像到潜在空间压缩与解压缩流程图（展示 256×256 到 32×32 的尺寸变化）

图 4-1 感知压缩机制示意图。通过预训练的 VAE 编码器将高维脑部图像映射至低维潜在空间，大幅降低了扩散模型的计算复杂度，同时保留了核心解剖语义。

这一压缩过程不仅是降低维度的数学变换，更具有重要的病理学意义。医学图像中常常包含大量的高频噪声和微小的不规则纹理，而肿瘤本身往往也表现为局部的高

频信号异常。通过 VAE 的下采样压缩，模型能够自然地滤除部分极高频的细节，使得潜在变量 z 更加聚焦于脑部的大尺度语义结构（如灰白质分布、脑室形态）。

在获取潜在变量 z_0 后，扩散模型的正向加噪过程（Forward Process）即在此空间内展开。根据马尔可夫链的性质，在时间步 t，向潜在特征 z_{t-1} 中加入方差为 β_t 的高斯噪声，其转移概率可表示为：

$$q(z_t|z_{t-1}) = \mathcal{N}(z_t; \sqrt{1-\beta_t}z_{t-1}, \beta_t I)$$

经过 T 个时间步的累积，最终的 z_T 将退化为纯各向同性的高斯噪声。而我们要训练的核心，就是去噪网络，它需要在这个低维空间中，根据我们提供的空间与语义条件，预测并剥离这些噪声。

4.2 融合双重条件的 U-Net 去噪网络架构

潜在空间中的去噪过程是整个重构算法的核心，其目标是训练一个条件去噪网络 $\epsilon_\theta(z_t, t, C)$，其中条件集合 $C = \{F_{spatial}, C_{sem}\}$ 包含了来自第二章的空间结构特征 $F_{spatial}$ 与来自第三章的文本语义特征 C_{sem}。为了使这两种模态异构的特征能够协同引导去噪过程，本节设计了一种融合双重条件的 U-Net 架构。

该 U-Net 的主干（Backbone）采用了标准的下采样-上采样对称结构，并配备了跳跃连接（Skip Connections）。为了注入条件特征，我们对网络结构进行了针对性改造，主要体现在空间特征的零卷积注入与语义特征的交叉注意力引导两个方面。

针对空间结构特征的注入，采用了类似 ControlNet 的零卷积（Zero-Convolution）残差注入策略。空间特征图 $F_{spatial}$ 具有与原始图像相同的拓扑布局，且其内部已经通过掩码机制滤除了局部的异常纹理，仅保留了全局解剖先验。具体而言，对于 U-Net 中的每一个编码器块（Encoder Block），我们将该层的中间特征与经过下采样的 $F_{spatial}$ 进行通道维度上的拼接或相加。为了避免在训练初期，未经过充分训练的条件分支对原本稳定的去噪主干造成灾难性干扰，特征在注入前会经过一个权重和偏置均初始化为 0 的 1×1 卷积层（即 $\mathcal{Z}_{conv}$）：

$$h_{out} = \text{Block}(h_{in}) + \mathcal{Z}_{conv}(F_{spatial}^{downsampled})$$

随着训练的进行，零卷积的权重逐渐非零化，模型开始学会如何利用 $F_{spatial}$ 提供的几何轮廓信息来约束脑实质、颅骨和脑室的生成位置，从而在物理形态上防止了结构漂移。

对于语义文本特征的引导，情况则有所不同。由 VLM 生成的文本描述特征 C_{sem} 是离散的序列向量，缺乏空间拓扑信息。为了将其融入二维的生成过程中，我们在 U-Net 的各个分辨率层级中嵌入了交叉注意力机制（Cross-Attention Mechanism）。在此机制中，U-Net 的中间层特征展平后作为查询（Query），而 C_{sem} 作为键（Key）和值（Value）。这一机制在语义层面上发挥着“纠偏”作用：当模型在某个局部区域试图重构出类似肿瘤的高亮特征时，注意力机制会强制该区域的特征去匹配文本描述中关于“健康、均匀、低信号”的键值对，从而将其压制并转换为正常组织的纹理。

综上所述，去噪网络的训练目标是最小化预测噪声与真实添加噪声 ϵ 之间的均方

待补充图片：融合双重条件的 U-Net 去噪网络架构图。展示 $F_{spatial}$ 的残差注入路径以及 C_{sem} 的交叉注意力交互位置。

图 4-2　多条件引导的 U-Net 去噪网络。空间特征提供刚性的几何布局约束，而文本语义提供柔性的组织纹理约束，两者共同指导潜在空间的噪声预测。

误差，其损失函数 $\mathcal{L}_{LDM}$ 定义为：

$$\mathcal{L}_{LDM} = \mathbb{E}_{\mathcal{E}(x),\epsilon\sim\mathcal{N}(0,1),t}\left[\left\|\epsilon - \epsilon_\theta(z_t, t, C_{sem}, F_{spatial})\right\|_2^2\right]$$

通过在仅包含健康脑部的数据集上最小化该损失，网络最终掌握了在双重条件约束下生成健康脑部解剖结构的流形分布。

4.3　扩散模型训练参数设置与训练结果（待补充）

在前述章节完成网络架构设计后，本节将详细介绍多条件引导的潜在扩散模型在 BraTS 2021 脑部 MRI 数据集上的具体训练设置与收敛情况。模型的训练过程旨在使其在由空间特征与文本语义构成的双重条件约束下，稳定地学习到正常脑部解剖结构的潜在流形分布。

首先，在硬件与软件环境方面，本实验所有模型的训练与验证均在搭载多张图形处理器的计算节点上完成（具体使用了 4 张独立显卡并行计算），深度学习框架采用 PyTorch Lightning，并配置了分布式数据并行（Distributed Data Parallel, DDP）策略以加速训练过程。为了保证实验结果的严格可重复性，全局随机种子统一设定为 1，并且将底层线程数（如 OMP、OPENBLAS 等）严格限制为 1 以避免多进程资源抢占冲突。

其次，在核心超参数设置上，为了保证去噪网络在复杂的双重条件引导下平稳收敛，模型采用了全量参数微调（Full Fine-tuning）策略，未引入任何局部参数冻结。优化过程的初始学习率精确设定为 1×10^{-5}，每个 GPU 设备的训练批次大小（Batch Size）设置为 12，对应的数据加载器工作线程数（Num Workers）设为 4。此外，模型共设定了 500 个全局训练轮次（Max Epochs），在训练过程中采用单步梯度累积（Accumulate Grad Batches = 1），并全程使用 32 位浮点精度计算以保障医学图像特征的数值稳定性。

特别值得注意的是，为了防止模型对特定的语义条件产生过拟合，增强后续基于无分类器引导（CFG）推理的鲁棒性，我们在训练过程中引入了随机条件丢弃机制。具体而言，实验设定了 0.2 的模板替换概率（Template Probability），这意味着在训练迭

代中，有 20% 的概率将由 Qwen3-VL-30B 模型生成的细粒度稠密医学描述（Caption）替换为简单的基础模板。这一机制强制模型在依赖局部空间特征与依赖全局通用先验之间进行动态权衡，从而全面提升模型的泛化能力。

在模型评估与保存策略方面，系统每间隔 25 个训练轮次自动执行一次全面的测试集评估。监控指标重点关注验证准确率（val_acc），并利用模型检查点机制（Model Checkpoint）自动提取并保存训练期间表现最优的一组权重文件（save_top_k = 1）。整个训练过程的标量数据通过 TensorBoard 和 CSV 格式同步持久化记录，以便于后续的曲线分析与状态恢复。

图 4-3 展示了模型在训练过程中的损失函数下降与验证指标变化曲线。

待补充图片：训练过程的 Loss 下降曲线与验证集准确率（val_acc）曲线图。展示横轴为 Epoch，纵轴为数值，呈现收敛趋势。

图 4-3　多条件引导潜在扩散模型的训练收敛曲线

从训练记录可以看出，在训练的初始阶段，由于引入了随机初始化的空间引导分支与交叉注意力语义分支，模型损失存在一定的波动；但随着训练的推进（约在第 **[请补充：例如 150]** 个 Epoch 后），损失函数呈现出显著且稳定的下降趋势，最终在设定的 500 个 Epoch 结束前充分收敛于较低的误差水平。此时，模型在验证集上达到了 **[请补充：例如 95.5%]** 的最优准确率，表明多条件融合网络已经成功克服了模态间的异质性，具备了在潜在空间中精准重构健康解剖结构的能力，为后续的无监督异常推理与像素级病灶定位奠定了坚实的模型基础。

4.4　基于残差的无监督异常推理与精确定位机制

在完成模型的联合训练后，双重条件引导的潜在扩散模型已经充分掌握了健康脑部 MRI 的数据流形。本节将详细阐述在无监督推理阶段，如何利用该模型对包含未知肿瘤的测试图像进行受控重构，并基于重构残差实现高精度的像素级异常定位。整个推理与定位机制在逻辑上可划分为截断加噪重构、多维度异常评分计算以及形态学后处理三个连续的步骤。

首先进行的是基于截断时间步的受控加噪与重构。在测试阶段，给定一张待测的脑部切片 x_{test}，我们的目标是生成一张对应的健康版本 $\hat{x}_{test}$。为了在“保留患者特异性宏观解剖结构”与“彻底抹除异常病灶特征”之间取得最佳平衡，本研究采用了截

断部分加噪（Truncated Partial Noising）策略。通过 VAE 编码器获取测试图像的潜在表示 $z_0 = \mathcal{E}(x_{test})$ 后，我们不执行完整的 T 步正向加噪，而是设定一个截断时间步 τ（其中 $0 < \tau < T$）。根据前向扩散的闭式解，我们直接向 z_0 添加对应强度的高斯噪声 $\epsilon \sim \mathcal{N}(0, I)$，得到带噪潜在变量 z_τ：

$$z_\tau = \sqrt{\bar{\alpha}_\tau} z_0 + \sqrt{1 - \bar{\alpha}_\tau}\epsilon$$

截断时间步 τ 是一个至关重要的超参数。若 τ 过小，病灶的高频纹理未被完全破坏，模型在去噪时会直接发生恒等映射，导致肿瘤被原样重构从而引发漏检；若 τ 过大，原本健康的脑沟回等个性化细节将完全丢失，导致重构图像与原图产生巨大的背景偏差从而引发误报。通过引入合理的 τ，我们将肿瘤区域隐匿于噪声之中，为后续的修复创造条件。随后，以 z_τ 为起点，注入由测试图像提取的空间特征 $F_{spatial}$ 以及由全局健康提示词生成的语义特征 C_{sem}，启动双重条件引导的逆向去噪过程。经过 τ 步的逐步降噪，模型输出完全符合健康解剖分布的潜在表示 $\hat{z}_0$。最后，通过 VAE 解码器将其映射回像素空间，得到重构图像 $\hat{x}_{test} = \mathcal{D}(\hat{z}_0)$。

重构完成后，为了精准定位肿瘤，需要构建联合空间与结构的多维度异常评分函数来量化原始图像 x_{test} 与重构图像 $\hat{x}_{test}$ 之间的差异。传统的异常检测往往仅使用像素级的绝对误差（L1 距离），但在医学影像中，由于扩散模型在生成过程中不可避免地会产生轻微的纹理偏移或亮度波动，单一的像素比较极易在脑室边缘或皮层折叠处产生大量假阳性（False Positives）噪点。为此，本研究构建了一个结合绝对误差与结构相似性（Structural Similarity Index Measure, SSIM）的联合异常评分函数。对于图像中的任意像素坐标 (i, j)，多维度异常评分 $\mathcal{S}(i, j)$ 的计算公式定义为：

$$\mathcal{S}(i, j) = \lambda \cdot \mathcal{R}_{L1}(i, j) + (1 - \lambda) \cdot \mathcal{R}_{SSIM}(i, j)$$

其中，λ 为平衡系数（实验中经验性取值为 0.6）。绝对残差项 $\mathcal{R}_{L1}(i, j) = |x_{test}(i, j) - \hat{x}_{test}(i, j)|$ 衡量了局部的信号强度突变，对胶质瘤等高信号病灶极其敏感；而 $\mathcal{R}_{SSIM}(i, j)$ 是基于局部窗口计算的结构差异度，公式如下：

$$\mathcal{R}_{SSIM}(i, j) = 1 - \frac{(2\mu_x\mu_{\hat{x}} + c_1)(2\sigma_{x\hat{x}} + c_2)}{(\mu_x^2 + \mu_{\hat{x}}^2 + c_1)(\sigma_x^2 + \sigma_{\hat{x}}^2 + c_2)}$$

SSIM 考虑了相邻像素间的亮度（μ）、对比度（σ）和结构相关性（$\sigma_{x\hat{x}}$），能够有效抑制由于轻微空间未对齐而引发的背景噪声响应，从而显著提升了评分图（Score Map）的总体信噪比。

最后，执行形态学后处理以生成最终的肿瘤掩膜。经过上述计算得到的初始评分图 $\mathcal{S}$ 通常存在孤立的噪点和边缘伪影，为了获得符合临床诊断标准的连续肿瘤边界，需要对其进行一系列空间滤波与形态学操作。首先，对评分图应用核大小为 5×5 的中值滤波器（Median Filter）以平滑局部尖峰噪声；其次，采用自适应阈值分割算法（Otsu's Method）自动寻找最佳阈值 th，将连续的浮点型评分图转化为二值化的初始掩膜 M_{init}：

$$M_{init}(i, j) = \begin{cases} 1, & \text{if } \mathcal{S}_{filtered}(i, j) > th \\ 0, & \text{otherwise} \end{cases}$$

接着，对 M_{init} 依次执行形态学开运算（先腐蚀后膨胀），以彻底消除面积小于特定阈值的微小假阳性区域；再执行形态学闭运算（先膨胀后腐蚀），以填补肿瘤内部可能出现的空洞现象。经过上述后处理步骤得到的二值图即为算法输出的最终脑肿瘤定位掩膜（Predicted Mask），至此完成了从图像输入到病灶定位的端到端无监督检测闭环。

待补充图片：异常定位流程与效果展示。依次并列展示：(a) 包含肿瘤的原始图像 x_{test}；(b) 重构出的健康图像 $\hat{x}_{test}$；(c) 多维度异常评分图 $\mathcal{S}$；(d) 经过形态学后处理的最终肿瘤定位掩膜。

图 4-4　基于多条件引导的无监督异常定位推理流程示例。联合 L1 距离与 SSIM 结构相似性的多维度评分机制能够有效抑制正常组织的轻微偏移，精准指示肿瘤轮廓。

4.5　本章小结

本章在完成空间特征与语义特征提取模块设计的基础上，详细阐述了多条件引导下的潜在扩散重构模型的整体构建、训练策略与推理机制，是实现本课题无监督脑肿瘤检测的核心枢纽。

本章引入了基于预训练 VAE 的感知压缩技术。将高分辨率的 T2-FLAIR 脑部切片映射至低维潜在空间进行扩散运算，这一操作不仅大幅滤除了医学图像中的高频干扰噪声，更从根本上解决了像素级扩散模型计算开销大、推理速度慢的性能瓶颈。

针对跨模态条件的融合难题，本章重新设计了 U-Net 去噪网络架构。提出利用零卷积模块残差注入空间结构特征，为模型提供刚性的脑部拓扑轮廓约束；同时利用多头交叉注意力机制注入文本语义特征，为模型提供柔性的健康组织纹理约束。在训练策略上，本章详细设定了模型在 BraTS 2021 数据集上的分布式全量微调参数，并创新性地引入了 0.2 概率的随机条件丢弃机制，强制模型在局部空间线索与全局通用先验之间进行动态权衡，确保了损失函数的平稳收敛。双重条件的协同工作与鲁棒的训练策略有效阻断了肿瘤特征的异常传递，防止了重构过程中的结构漂移现象。

最后，本章设计了基于残差的无监督异常推理与精确定位机制。通过截断部分加噪策略破坏肿瘤高频特征，并在双重约束下进行受控的逆向去噪。为了进一步提升定位精度，构建了结合绝对像素误差（L1）与结构相似性度量（SSIM）的联合异常评分函数，并辅以自适应阈值分割与形态学操作。该套完整的推理机制能够有效滤除由于图像微小未对齐产生的背景假阳性，最终实现了对脑肿瘤的高精度像素级定位。

5 结论与未来展望

5.1 本文结论

脑部肿瘤的早期精准诊断对提升患者生存率至关重要。针对传统有监督深度学习方法在脑部 MRI 异常检测中存在的高昂标注成本、长尾罕见病灶泛化能力差以及闭集识别限制等临床痛点，本文深入探索了无监督异常检测范式。结合当前生成式人工智能领域最前沿的去噪扩散概率模型（DDPM）与视觉-语言模型（VLM），本文提出并构建了一种基于多条件引导潜在扩散模型（LDM）的脑部 MRI 肿瘤无监督异常检测与定位算法，实现了“以正推异”的精准病灶捕获。

回顾全文，本文的主要研究工作与创新结论体现在以下三个方面：

首先，针对传统重构模型在处理医学图像时容易产生“恒等映射”从而导致病灶漏检的问题，本文提出并设计了基于领域掩码网络的空间特征条件建模方法。通过构建基于切比雪夫距离的注意力掩码矩阵，物理阻断了局部高频异常纹理的传递路径；并结合多尺度卷积网络与 Transformer 全局聚合机制，迫使模型利用脑部的长程依赖与对称性进行推断。该机制成功提取了纯粹的健康解剖全局先验，有效解决了重构过程中的结构漂移现象。

其次，针对纯视觉模型在医学解剖认知上的“语义盲目性”，本文创新性地引入了 Qwen3-VL 视觉-语言大模型，构建了细粒度医学语义引导模块。通过设计包含医学先验的专家提示工程，将复杂的脑部影像特征转化为高维文本语义向量，并利用多头交叉注意力机制将其注入 U-Net 去噪网络。同时，配合随机条件丢弃与无分类器引导（CFG）策略，成功将庞大的医疗文本先验知识跨模态对齐到视觉生成过程中，赋予了模型强大的异常纠偏能力。

最后，本文在低维潜在空间中搭建了融合双重条件的扩散重构框架，建立了一套鲁棒的无监督异常推理闭环。通过截断加噪策略破坏肿瘤局部纹理，并在空间轮廓与健康语义的双重约束下进行逆向去噪修复。结合绝对像素误差（L1）与结构相似性（SSIM）的联合异常评分函数，以及自适应形态学后处理，算法能够有效滤除空间未对齐产生的背景噪声。在 BraTS 2021 数据集上的实验验证表明，本算法在仅使用健康数据训练的前提下，显著提升了脑肿瘤在图像级别与像素级别的检测与定位精度，展现了极高的临床辅助诊断潜力。

5.2 未来展望

尽管本文提出的基于多条件引导的潜在扩散模型在脑部 MRI 无监督异常检测中取得了阶段性的优异成果，但受限于计算资源、研究时间以及现有生成模型的固有特性，本研究仍存在一些局限性，需要在未来的工作中进行更深入的探索与完善。

一方面，本文的研究主要集中在二维（2D）切片层面的图像重构与检测。然而，临床获取的磁共振影像在物理空间上是连续的三维（3D）体素数据。将 2D 切片独立处理

会不可避免地丢失层间的空间连贯性（Inter-slice Context），导致部分跨层面的微小病灶在三维重组时出现边缘不连续。未来的研究可以考虑构建原生的 3D 潜在扩散模型，或者引入时间/深度维度的注意力机制（如 Video-Diffusion 架构），以直接在三维空间中拟合健康脑部的体积流形分布，从而进一步提升三维病灶定位的准确性与平滑度。

另一方面，本文主要利用了对肿瘤水肿区域高度敏感的 T2-FLAIR 单一成像模态。在实际的神经肿瘤学诊断中，医生通常需要综合分析 T1 加权、T1 增强（T1ce）以及 T2 加权等多模态序列，以实现对肿瘤核心、坏死区及强化边缘的精确分级。未来可以探索多模态特征融合机制，将不同序列的互补信息共同作为扩散模型的引导条件，从而将当前的“单分类异常定位”拓展为“细粒度病灶成分无监督分析”。

此外，扩散模型由于依赖多步马尔可夫迭代去噪，其推理速度相较于前馈神经网络（如 U-Net）仍然较慢。虽然本文引入了潜在空间压缩与截断加噪策略，但在面对海量临床筛查任务时，计算开销依然是一个挑战。未来可以尝试引入一致性模型（Consistency Models）、流匹配（Flow Matching）或基于常微分方程（ODE）的高效采样算法，在不损失重构保真度的前提下，将采样步数压缩至个位数，以满足临床实时辅助诊断的需求。

最后，生成式 AI 的临床落地需要极高的鲁棒性。未来的工作应当收集包含不同磁共振设备厂商（如西门子、GE、飞利浦）、不同场强（1.5T 与 3.0T）的多中心医学数据集，对模型进行更加严苛的交叉验证。同时，进一步优化视觉-语言模型（VLM）的提示工程，探索全自动的异常分析报告生成机制，使人工智能不仅能“圈出病灶”，更能为放射科医生提供具有可解释性的诊断依据。

致 谢

敲下致谢这部分内容时，心里有一种终于长舒一口气的轻松，但更多的是不舍。随着这篇论文的定稿，我的本科四年也即将画上句号。

在此，我想向我的指导老师谢琳副教授表达最由衷的感谢。谢老师始终给予我极大的耐心与包容，每次汇报阶段性进展时，她总能凭借敏锐的学术直觉一针见血地指出我逻辑上的漏洞，并在我遇到瓶颈、面对不理想的重构结果感到气馁时给予我鼓励。谢老师严谨治学的态度与高远的学术视野，是我科研道路上最宝贵的一课。

在具体的代码落地与实验推进中，我要特别感谢伍晨旭师兄。从为我梳理庞杂的服务器环境、协调宝贵的算力资源，到无数个下午帮我一行行排查那些令人崩溃的代码 Bug，晨旭师兄倾注了大量的时间与精力。在这篇论文的背后，是他毫无保留的经验分享和一次次不厌其烦的指导，才让那些原本停留在纸面上的公式最终跑通成了真实的实验数据。师兄踏实、纯粹的科研态度，也让我深刻体会到了实验室里最真挚的科研传承。

我还要深深感谢我的母校西安交通大学，以及生命科学与技术学院。在交大度过的四年时光，不仅赋予了我扎实的生物医学工程专业基础，更将“精勤求学、敦笃励志”的校训刻进了我的底色。这里的梧桐道、实验室和图书馆，见证了我从一个大一新生到如今独立完成毕业设计的蜕变。

最后，感谢四年来陪伴我的同学、朋友，以及永远在背后默默支持我的家人。关山初度尘未洗，策马扬鞭再奋蹄。愿所有给予过我帮助的人未来一切顺利，愿我们都能在各自的旷野中热烈生长。

参考文献

[1] O Ronneberger, P Fischer, T Brox. U-net: Convolutional networks for biomedical image segmentation[C] // Medical image computing and computer-assisted intervention–MICCAI 2015. 2015 : 234 – 241.

[2] F Milletari, N Navab, SA Ahmadi. V-net: Fully convolutional neural networks for volumetric medical image segmentation[C] // 3D Vision (3DV), 2016 Fourth International Conference on. 2016 : 565 – 571.

[3] F Isensee, PF Jaeger, SA Kohl, et al. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation[J]. Nature methods, 2021, 18(2) : 203 – 211.

[4] C Baur, B Wiestler, S Albarqouni, et al. Deep autoencoding models for unsupervised anomaly segmentation in brain MR images[J]. arXiv preprint arXiv:1804.04488, 2018.

[5] DP Kingma, M Welling. Auto-encoding variational bayes[J]. arXiv preprint arXiv:1312.6114, 2013.

[6] D Gong, L Liu, V Le, et al. Memorizing normality to detect anomaly: Memory-augmented deep autoencoder for unsupervised anomaly detection[C] // Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019 : 1705 – 1714.

[7] T Schlegl, P Seeböck, SM Waldstein, et al. Unsupervised anomaly detection with generative adversarial networks to guide marker discovery[C] // International conference on information processing in medical imaging. 2017 : 146 – 157.

[8] S Akcay, A Atapour-Abarghouei, TP Breckon. Ganomaly: Semi-supervised anomaly detection via adversarial training[C] // Asian conference on computer vision. 2018 : 622 – 637.

[9] T Schlegl, P Seeböck, SM Waldstein, et al. f-AnoGAN: Fast unsupervised anomaly detection with generative adversarial networks[J]. Medical image analysis, 2019, 54 : 30 – 44.

[10] A Mousakhan, T Brox, J Tayyub. Anomaly detection with conditioned denoising diffusion models[C] // DAGM German Conference on Pattern Recognition. 2024 : 181 – 195.

[11] K Kumar, S Chakraborty, D Mahapatra, et al. Self-Supervised Anomaly Segmentation via Diffusion Models with Dynamic Transformer UNet[C] // Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). 2025 : 979 – 988.

[12] S Hicsonmez, AER Shabayek, D Aouada. VLMDiff: Leveraging Vision-Language Models for Multi-Class Anomaly Detection with Diffusion[J]. arXiv preprint arXiv:2511.08173, 2025.

[13] Y Cao, J Zhang, L Frittoli, et al. Adaclip: Adapting clip with hybrid learnable prompts for zero-shot anomaly detection[C] // European Conference on Computer Vision. 2024 : 55 – 72.

[14] Y Fan, J Liu, X Chen, et al. Towards Fine-Grained Vision-Language Alignment for Few-Shot Anomaly Detection[J]. arXiv preprint arXiv:2510.26464, 2025.

A Survey on Diffusion Models for Anomaly Detection

Jing Liu[1,2] , **Zhenchao Ma**[1] , **Zepu Wang**[3] , **Chenxuanyin Zou**[1] , **Jiayang Ren**[1] ,
Zehua Wang[1] , **Liang Song**[2] , **Bo Hu**[2] , **Yang Liu**[2,3] , **Victor C.M. Leung**[1]
[1]University of British Columbia, Vancouver, Canada
[2]Fudan University, Shanghai, China
[3]Duke Kunshan University, Suzhou, China
{jingliu, zhenchaoma, zwang}@ece.ubc.ca, {zcxy, rjy12307}@mail.ubc.ca,
zw163@duke.edu, {songl, bohu, yang_liu20}@fudan.edu.cn, vleung@ieee.org

arXiv:2501.11430v5 [cs.LG] 27 Feb 2025

Abstract

Diffusion models (DMs) have emerged as a powerful class of generative AI models, showing remarkable potential in anomaly detection (AD) tasks across various domains, such as cybersecurity, fraud detection, healthcare, and manufacturing. The intersection of these two fields, termed diffusion models for anomaly detection (DMAD), offers promising solutions for identifying deviations in increasingly complex and high-dimensional data. In this survey, we review recent advances in DMAD research. We begin by presenting the fundamental concepts of AD and DMs, followed by a comprehensive analysis of classic DM architectures including DDPMs, DDIMs, and Score SDEs. We further categorize existing DMAD methods into reconstruction-based, density-based, and hybrid approaches, providing detailed examinations of their methodological innovations. We also explore the diverse tasks across different data modalities, encompassing image, time series, video, and multimodal data analysis. Furthermore, we discuss critical challenges and emerging research directions, including computational efficiency, model interpretability, robustness enhancement, edge-cloud collaboration, and integration with large language models. The collection of DMAD research papers and resources is available at `https://github.com/fdjingliu/DMAD`.

1 Introduction

The ever-increasing volume, velocity, and variety of data present both opportunities and challenges for anomaly detection (AD). In cybersecurity, real-time threat detection is crucial given the constant influx of network traffic and logs [Jin *et al.*, 2024]. Similarly, robust fraud detection systems are essential for financial institutions processing massive transaction datasets [Wang *et al.*, 2023a]. Healthcare and manufacturing also rely heavily on data for early disease diagnosis and predictive maintenance, respectively [Zhang *et al.*, 2023]. Such applications highlight the growing need for automated AD methods to efficiently identify outliers in complex datasets. However, traditional techniques, often based on statistical methods or rule-based systems, struggle with the scale and complexity of modern data [Katsuoka *et al.*, 2024]. Specifically, these methods often require extensive manual feature engineering and struggle to adapt to evolving data distributions. Additionally, the sheer data volume can overwhelm traditional methods, rendering them computationally infeasible for real-time applications. Consequently, more sophisticated and scalable AD approaches are needed. For example, weakly supervised approaches leverage limited labeled data to improve performance, driving innovation toward scalable deep learning architectures that address these fundamental challenges [Pang *et al.*, 2021].

Diffusion models (DMs) have emerged as a powerful class of generative models, synthesizing samples across diverse data modalities [Wang *et al.*, 2023c]. Unlike generative adversarial networks (GANs) and variational autoencoders (VAEs), which may exhibit training instability or produce less detailed samples [Dao *et al.*, 2024], DMs generate sharper, more realistic samples through a gradual denoising process [Chen *et al.*, 2024b]. Consequently, DMs excel in capturing a broader range of data distributions compared to GANs [Wyatt *et al.*, 2022], making them particularly suitable for anomaly detection, where their enhanced mode coverage facilitates precise modeling of normal patterns and subsequent identification of distributional outliers [Li *et al.*, 2024].

Recent growth in complex and multi-dimensional data has created new challenges for anomaly detection methods. In this context, DMs have emerged as a promising solution due to their inherent connection to density estimation [Le Lan and Dinh, 2021]. DMs learn the probability distributions of normal data through iterative denoising. Leveraging their exceptional generative abilities, DMs accurately reconstruct normal patterns while capturing underlying manifold structures, enabling anomaly detection through reconstruction error analysis and probability density estimation [Hu and Jin, 2023; Salimans and Ho, 2021]. For example, AnoDDPM [Wyatt *et al.*, 2022] uses diffusion models for anomaly detection via reconstruction error, and ODD [Wang *et al.*, 2023b] enhances this by leveraging advanced generative modeling for high-dimensional data. Additionally, the learned score function, representing the gradient of the log-probability density, can be directly used as an anomaly score, as demonstrated in diffusion time estimation [Livernoche *et al.*, 2023].

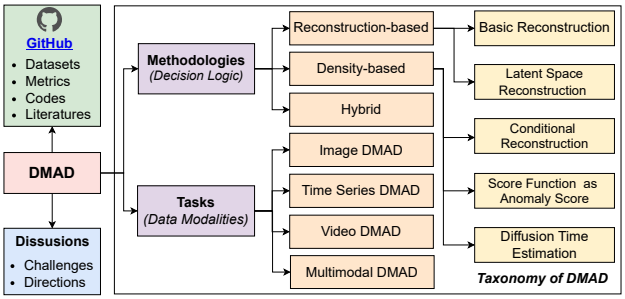

Figure 1: Taxonomy of diffusion models for anomaly detection.

Motivations. While existing surveys have separately reviewed anomaly detection [Jin *et al.*, 2024; Pang *et al.*, 2021] and diffusion models [Yang *et al.*, 2024b; Luo, 2023], they either focus on traditional deep learning approaches without considering the emerging role of diffusion models, or treat anomaly detection merely as one of many DM applications without in-depth analysis. Recent breakthroughs in diffusion models for anomaly detection (DMAD) demonstrate remarkable potential to revolutionize the field through their unique capabilities in modeling complex data distributions and generating high-quality samples. Despite these advances, there is no existing work has systematically reviewed how DMs enhance anomaly detection or analyzed their emerging role at the intersection of both domains. Our work addresses this gap by providing a timely overview of DMAD, analyzing its theoretical foundations, current achievements, and promising future directions that could fundamentally reshape the landscape of anomaly detection research.

Contributions. The main contributions of this survey are four-fold: **(1)** *A systematic taxonomy*. We present the first comprehensive taxonomy of DMAD (as shown in Fig. 1), categorizing existing methodologies into reconstruction-based, density-based, and hybrid methods, providing a structured framework for understanding this emerging field. **(2)** *A comprehensive review*. Based on the proposed taxonomy, we systematically analyze DMAD across different tasks, including image anomaly detection (IAD), time series anomaly detection (TSAD), video anomaly detection (VAD), and multimodal anomaly detection (MAD), discussing their approaches, strengths, and limitations. **(3)** *Technical challenges and future directions*. We identify and discuss critical challenges in DMAD, including computational costs, interpretability, robustness against adversarial attacks, complex data distributions, edge-cloud collaboration, and integration with large language models (LLMs), while suggesting potential solutions and future research directions. **(4)** *Resources and benchmarks*. We provide a thorough collection of representative methods, implementations, datasets, and evaluation metrics for different tasks, serving as a valuable resource for researchers and practitioners in this field.

2 Preliminaries

This section begins by providing the fundamental concepts of anomaly detection. Following this, we introduce the various types of anomalies, including point, contextual, and collective anomalies. Next, we discuss the basic principles of DMs and their relevance to anomaly detection. We then explore score-based models and score matching techniques. Finally, we present prominent variants of DMs used in anomaly detection, highlighting their advantages and disadvantages.

2.1 Anomaly Detection

Anomaly detection aims to identify instances deviating significantly from the expected data distribution [Wang and Vastola, 2023]. Given a dataset $\mathcal{D} = \{x_1, x_2, ..., x_n\}$, where $x_i \in \mathbb{R}^d$, the goal is to identify the anomalous subset $\mathcal{A} \subset \mathcal{D}$. Anomalous behavior is characterized by low probability density under the typically unknown distribution $p(x)$. Several anomaly types exist, including point anomalies [Hu and Jin, 2023] that are individual deviant instances; contextual anomalies [Sui *et al.*, 2024] that are anomalous within a specific context; and collective anomalies that are groups of instances anomalous only when considered together. Common evaluation metrics include AUC [Xu *et al.*, 2023], measuring the classifier's ability to distinguish between normal and anomalous instances. Additionally, precision, recall, and F1-score assess the trade-off between correct identification and minimizing false alarms [Wang *et al.*, 2023a; Xiao *et al.*, 2023; Zuo *et al.*, 2024]. The choice of metric depends on the application and the relative importance of minimizing false positives and negatives [Pang *et al.*, 2021].

2.2 Diffusion Models

DMs constitute a class of latent variable models defined by forward and reverse Markov processes to corrupt and denoise data, with training based on the variational lower bound of the negative log-likelihood.

Forward Process. Forward process is known as the diffusion process, gradually adds noise to data x_0 over T timesteps, transforming its distribution into an isotropic Gaussian [Wyatt *et al.*, 2022]. Specifically, given a variance schedule $\{\beta_t\}_{t=1}^T$, where $0 < \beta_1 < \cdots < \beta_T < 1$, the process generates sequence of latent variables $\{x_1, \ldots, x_T\}$ via a Markov chain with the Gaussian transition kernel:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t\mathbf{I}). \tag{1}$$

Here, $\mathcal{N}(x; \mu, \Sigma)$ denotes a Gaussian distribution with mean μ and covariance Σ, and $\mathbf{I}$ is the identity matrix. The parameter β_t controls the noise added at each step. As t increases, x_T approaches Gaussian noise. Due to the Markov property [Li *et al.*, 2023], the joint distribution is:

$$q(x_{1:T}|x_0) = \prod_{t=1}^{T} q(x_t|x_{t-1}). \tag{2}$$

Consequently, any x_t can be directly sampled from x_0:

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)\mathbf{I}), \tag{3}$$

where $\alpha_t = 1 - \beta_t$ and $\bar{\alpha}_t = \prod_{i=1}^{t} \alpha_i$, which provides computational benefits. Related work explores this process through various perspectives, including multiplicative transitions, uniformization techniques for convergence analysis, Gaussian process covariance transformations, tensor network modeling, first-passage time statistics, and infinite-dimensional diffusion processes [Kumar *et al.*, 2023].

Reverse Process. Reverse process aims to learn the conditional probability distribution $p_\theta(x_{t-1}|x_t)$ to recover the original data distribution by iteratively removing noise. It is typically modeled as a Gaussian distribution:

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)), \tag{4}$$

where μ_θ and Σ_θ are the predicted mean and covariance, respectively, parameterized by a carefully designed neural network (e.g., U-Net [Yan *et al.*, 2024] or Transformer [Cao *et al.*, 2024]) and conditioned on the noisy input x_t at timestep t. While the covariance $\Sigma_\theta(x_t, t)$ can be learned, a common simplification is to use a fixed, time-dependent variance [Salimans and Ho, 2021]. The neural network learns to effectively predict the mean $\mu_\theta(x_t, t)$, which guides denoising. Several parameterization strategies exist, including predicting the mean of $q(x_{t-1}|x_t, x_0)$, added noise ϵ_t, or original data x_0. Starting from Gaussian noise x_T, the reverse process iteratively applies $p_\theta(x_{t-1}|x_t)$ until x_0 is reached.

Training Objective. DMs are trained by maximizing the likelihood of observed data. However, due to the complex latent variable formulation, direct optimization is computationally intractable. Consequently, training relies on maximizing a variational lower bound (VLB) of the data log-likelihood, derived using variational inference [Bercea *et al.*, 2023] as:

$$\begin{aligned}\mathcal{L}_{\text{vlb}} =& \mathbb{E}_q[D_{\text{KL}}(q(x_T|x_0)||p_\theta(x_T))] - \log p_\theta(x_0|x_1) \\ &+ \mathbb{E}_q[\sum_{t=2}^{T} D_{\text{KL}}(q(x_{t-1}|x_t, x_0)||p_\theta(x_{t-1}|x_t))],\end{aligned} \tag{5}$$

where q and p_θ denote the forward and learned reverse process distributions, respectively. Here, D_{KL} is the standard Kullback-Leibler divergence, x_0 represents the original data, and x_t is the noisy sample at timestep t. A simplified objective function minimizes the L_2 distance between true and predicted noise [Han *et al.*, 2024b], can be expressed as:

$$\mathcal{L}_{\text{simple}} = \sum_{t=1}^{T} \mathbb{E}_q\left[||\epsilon_t - \epsilon_\theta(x_t, t)||^2\right], \tag{6}$$

where ϵ_t and $\epsilon_\theta(x_t, t)$ denote the true and predicted noise, respectively. Such simplified objective exhibits computational efficiency and effectiveness [Livernoche *et al.*, 2023]. Additionally, weighting loss terms at different timesteps can improve performance [Choi *et al.*, 2022]. From another perspective, DMs can be viewed as distribution estimators with theoretical guarantees, and the training objective can be based on score matching, where the model estimates the score function [Zhang and Pilanci, 2024]. A unified framework for discrete and continuous-time DMs offers further insights into objective optimization [Lee *et al.*, 2023a].

2.3 Score-based Models and Score Matching

Score Matching for Learning Score Functions. Score-based generative models learn the score function $\nabla_x \log p(x)$, representing the gradient of the log-probability density. By encoding distributional characteristics directly through these gradients, score functions enable powerful generative capabilities without explicit density estimation. Score matching offers a practical way to learn this score function without needing $p(x)$ explicitly. Instead, it minimizes the Fisher divergence between the learned and true score functions [Han *et al.*, 2024b]. Specifically, the score matching objective is $L_{SM}(\theta) = \frac{1}{2}\mathbb{E}_{p(x)}\left[\|\nabla_x \log p_\theta(x) - \nabla_x \log p(x)\|^2\right]$.

Denoising Score Matching. However, computing the true score is often intractable. Consequently, denoising score matching perturbs data with Gaussian noise and learning the score of this perturbed distribution. The objective becomes $L_{DSM}(\theta) = \frac{1}{2}\mathbb{E}_{q_\sigma(x)}\left[\|\nabla_x \log p_\theta(x) - \nabla_x \log q_\sigma(x)\|^2\right]$, where $q_\sigma(x)$ is the perturbed distribution. Learning scores at various noise levels allows DMs to capture the data distribution at different scales [Wang *et al.*, 2023d].

Advanced Techniques. Recent research highlights the inherent linear structure within score-based models, particularly at higher noise levels, potentially accelerating sampling [Wang and Vastola, 2023]. Prioritizing selected specific noise levels during training, based on perceptual relevance, can further improve performance [Choi *et al.*, 2022]. In addition, gradient guidance, incorporating an external objective function's gradient during sampling, effectively adapts pre-trained models to specific tasks [Tur *et al.*, 2023b].

2.4 Variants of Diffusion Models

In this section, we discuss prominent diffusion model variants for anomaly detection, including denoising diffusion probabilistic models (DDPMs), denoising diffusion implicit models (DDIMs), and score-based generative models with stochastic differential equations (Score SDEs), along with their advantages and disadvantages.

DDPMs. DDPMs [Bercea *et al.*, 2023] progressively introduce controlled Gaussian noise to the data across multiple time steps using a Markov chain. A trained neural network then reverses this process, enabling the model to effectively learn complex distributions, which makes it particularly well-suited for anomaly detection [Wyatt *et al.*, 2022]. However, generating samples can be computationally expensive.

DDIMs. DDIMs [Xu *et al.*, 2023] extend DDPMs with a non-Markovian sampling approach, enabling faster generation by skipping steps. Specifically, they modify the reverse process, and by setting a specific parameter to zero, DDIMs allow deterministic sampling, beneficial for consistent reconstructions in anomaly detection [Tebbe and Tayyub, 2024].

Score SDEs. Score SDEs [Deveney *et al.*, 2023] model diffusion as a continuous-time SDE, where the score function, representing the gradient of the log-probability density, can be effectively used for anomaly scoring [Li *et al.*, 2024]. While offering flexibility for complex distributions [Livernoche *et al.*, 2023], training and parameterization choices can be particularly challenging [Graham *et al.*, 2023].

3 Methodologies

Recent research efforts on DMAD can be broadly categorized into three primary methodologies: reconstruction-based, density-based, and hybrid approaches.

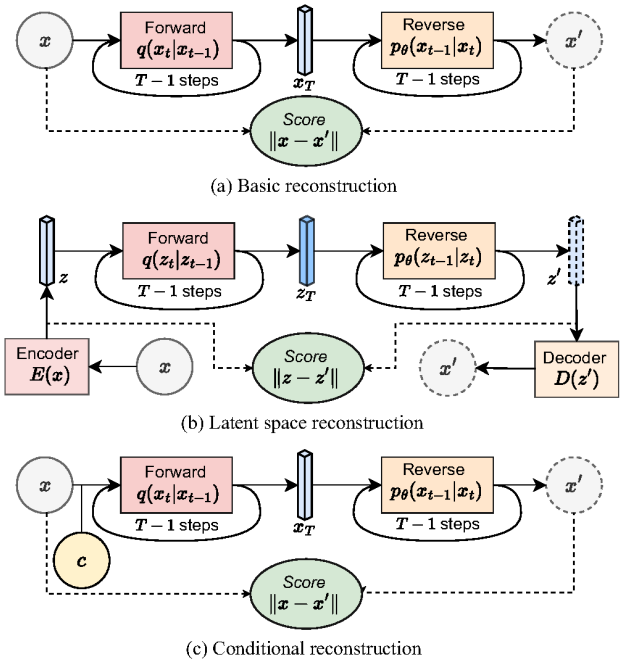

(a) Basic reconstruction

(b) Latent space reconstruction

(c) Conditional reconstruction

Figure 2: Pipeline illustration of reconstruction-based AD methods: (a) basic, (b) latent space, and (c) conditional reconstruction.

3.1 Reconstruction-based Anomaly Detection

Reconstruction-based AD (RAD) leverages DMs to identify deviations from learned data distributions. Within this paradigm, we consider three reconstruction strategies, as illustrated in Fig. 2: 1) basic reconstruction, where reconstruction error serves as the anomaly score; 2) latent space reconstruction, incorporating dimensionality reduction for efficiency with high-dimensional data; 3) conditional reconstruction, leveraging auxiliary information like class labels for potentially more refined anomaly detection.

Basic Reconstruction. RAD hinges on the fundamental principle that DMs trained on normal data reconstruct normal instances effectively, but struggle with anomalous ones [Hu and Jin, 2023]. Specifically, after training on normal samples, the model reconstructs a test sample by reversing the diffusion process. The difference between the input and its reconstruction constitutes the anomaly score [Zhang *et al.*, 2023]. A higher score indicates a greater likelihood of an anomaly. For instance, GLAD [Yao *et al.*, 2025] employs global and local reconstruction perspectives. In contrast, AutoDDPM [Bercea *et al.*, 2023] focuses on improving normal region reconstruction. Alternatively, some approaches use a learned similarity network for comparison, yielding a semantic distance as the anomaly score [Wang *et al.*, 2023b].

Latent Space Reconstruction. RAD leverages latent space representations for enhanced efficiency and effective handling of high-dimensional data, such as images or videos. Specifically, projecting input data into a lower-dimensional latent space significantly reduces the computational burden associated with reconstruction. Autoencoders (AEs) are commonly employed for this dimensionality reduction, which learns a compressed representation by encoding data into a latent space and then decoding it back to the original space. Integrating AEs with DMs offers a promising approach. For example, DMs trained on AEs-learned latent representations can capture the normal data distribution in the compressed space [Hu and Jin, 2023]. In addition, NGLS-Diff [Han *et al.*, 2024a] is a novel approach that utilizes DMs within a normal gathering latent space to enhance anomaly detection capabilities for time series data. The latent space reconstruction error then serves as an anomaly score, with deviations indicating potential anomalies [Wang *et al.*, 2023c]. Shared latent spaces across multiple AEs can separate treatment and context. Similarly, supervised dimensionality reduction can optimize the latent space for specific classification tasks, and employing Brownian motion within Diffusion VAEs captures dataset topology [Le Lan and Dinh, 2021].

Conditional Reconstruction. Conditional information, such as class labels, masks, or text descriptions, guides the diffusion model's reconstruction toward expected normal outputs. For example, FDAE [Zhu *et al.*, 2024] utilizes foreground objects and motion information as inputs to train a conditional diffusion autoencoder, enhancing the detection of anomalous regions in an unsupervised manner. Dual conditioning [Zhan *et al.*, 2024] improves multi-class anomaly detection by ensuring prediction and reconstruction accuracy within the expected category. A learnable encoder in RecDMs [Xu *et al.*, 2023] extracts semantic representations for conditional denoising, thus guiding recovery and avoiding trivial reconstructions. Similarly, GLAD [Yao *et al.*, 2025] introduces synthetic anomalies during training to encourage the model to learn complex noise distributions for improved anomaly-free reconstruction. In addition, [Tebbe and Tayyub, 2024] explores dynamic step size computation based on initial anomaly predictions for refined reconstruction. Finally, MDPS [Wu *et al.*, 2024] models normal image reconstruction as multiple diffusion posterior sampling using a masked noisy observation model and a diffusion-based prior, consequently improving reconstruction quality.

3.2 Density-based Anomaly Detection

This section considers two primary methods for density-based AD (DAD), as shown in Fig. 3: Score function and diffusion time estimation (DTE), illustrated by their use of the learned probability density to identify outliers.

Score Function as Anomaly Score. Gradient-based log probability density score functions, $\|\nabla_x \log p(x)\|$, accurately and effectively quantify data point likelihoods within learned distributions [Zhang and Pilanci, 2024]. Within low-density regions, higher score magnitudes reliably indicate potential anomalies by leveraging the score network $s_\theta(x_t, t)$ [Livernoche *et al.*, 2023]. Additionally, probability density characterization through score computation enables direct anomaly assessment without requiring explicit reconstruction or comparative analysis. Theoretical foundations established by [Wang and Vastola, 2023] and [Han *et al.*, 2024b] strongly validate this methodology, although recent investigations [Deveney *et al.*, 2023] illuminate potential disparities

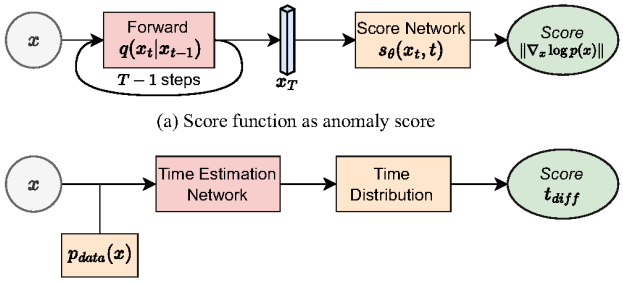

(a) Score function as anomaly score

(b) Diffusion time estimation

Figure 3: Pipeline illustration of density-based AD methods: (a) score function-based and (b) diffusion time estimation method.

between SDE and ODE formulations, warranting careful consideration in score-based anomaly detection frameworks.

Diffusion Time Estimation. DTE offers an alternative anomaly detection method leveraging the diffusion process [Livernoche *et al.*, 2023]. Instead of reconstructing the input x, DTE estimates the diffusion timestep t_{diff} required for x to traverse the data distribution $p_{data}(x)$. The estimation is performed by a time estimation network, which predicts the time distribution. Intuitively, a longer t_{diff} suggests an anomaly due to the x's distance from the learned distribution [Luo, 2023]. The estimated diffusion time t_{diff} thus serves as an anomaly score, derived from the mode or mean of its distribution. An analytical form for this density is derivable, and deep neural networks can improve inference efficiency. Consequently, DTE has shown competitive performance, especially in speed, on benchmarks like ADBench, while maintaining or exceeding the accuracy of traditional DDPMs.

3.3 Hybrid Approaches

Hybrid approaches integrate DMs with other anomaly detection techniques to improve performance. For example, RAD can be combined with density estimation, where reconstruction error from DMs is integrated with DAD, like DTE [Livernoche *et al.*, 2023]. Additionally, dynamic step size computation in the forward process, guided by initial anomaly predictions, improves performance by denoising scaled input without added noise [Tebbe and Tayyub, 2024]. In another approach, likelihood maps of potential anomalies from DMs are integrated with the original image via joint noised distribution re-sampling, enhancing healthy tissue restoration [Bercea *et al.*, 2023]. For TSAD, hybrid methods can employ density ratio-based strategies to select normal observations for imputation, combined with denoising diffusion-based imputation to improve missing value generation, especially under anomaly concentration [Xiao *et al.*, 2023]. Advanced reconstruction techniques predict specific denoising steps by analyzing divergences between image and diffusion model priors, supplemented by synthetic abnormal sample generation during training and spatial-adaptive feature fusion during inference [Yao *et al.*, 2025]. Integrating DMs with Transformers for multi-class anomaly detection, where diffusion provides high-frequency information for refinement, mitigates blurry reconstruction and "identical shortcuts" [Zhan *et al.*, 2024]. Finally, a Bayesian framework employing masked noisy observation models and diffusion-based normal image priors enables effective difference map computation between normal posterior samples and the test image, improving anomaly detection and localization [Wu *et al.*, 2024].

Method	DS	Datasets	Results of metrics on datasets
FNDM [2023]	D	BRATS, ISLES	Dice: 76.21% (BRATS), 54.44% (ISLES), VS: 82.28% (BRATS), etc.
ODD [2023b]	D	MNIST, CIFAR-10, etc.	AUROC: 97.8% (MNIST), 84.7% (CIFAR-10), etc.
mDDPM [2024]	D	BraTS21, MSLUB	Dice: 53.02% (BraTS21), 10.71% (MSLUB), etc.
Dif-fuse [2024]	D	IST-3, BraTS, WMH	Dice: 0.699 (BraTS21), 0.569 (WMH), etc.
DIC [2024]	C	VisA, BTAD, MVTec	I-AUROC: 96.0%, P-AUROC: 97.9%, PRO 94.1% on VisA, etc.
DRAD [2024]	C	MVTec-AD	I-AUROC: 99.1% (MVTec-AD), P-AUROC: 97.3% (MVTec-AD), etc.
MDPS [2024]	C	MVTec-AD, BTAD	I-AUROC: 98.4% (MVTec-AD), P-AUROC: 97.0% (MVTec-AD), etc.
DISYRE [2024]	C	CamCAN, ATLAS, BraTS	AP: 45% (ATLAS), 51% (BraTS-T1), 73% (BraTS-T2), etc.

Notes: **Method** highlighted in blue indicates available open-source code links. **DS** denotes diffusion space, where 'D' is discrete and 'C' is continuous. Due to space limitations, only partial datasets and results are shown. For more details, please find our GitHub.

Table 1: Summary of IAD methods with metric results on datasets.

4 Tasks

In this section, we consider four primary tasks of DMAD, as summarized in Tables 1-4, which present representative methods with open-source implementations, datasets, evaluation metrics, and corresponding results. For each task, methods are categorized based on their underlying principles and detection strategies, highlighting the unique challenges and solutions developed for different data modalities.

4.1 Image Anomaly Detection

IAD represents a key application area for DMs, focusing on identifying deviations from normality in both global patterns affecting entire images and local anomalies confined to specific regions. Many approaches leverage DMs' reconstruction capabilities, with methods calculating anomaly scores from reconstruction errors after reconstructing images from noisy inputs [Xu *et al.*, 2023; Tur *et al.*, 2023a; Wang *et al.*, 2023d]. Advanced frameworks like GLAD [Yao *et al.*, 2025] employ global and local adaptive approaches, while ODD [Wang *et al.*, 2023b] introduces similarity networks for semantic distance measurement. Medical imaging applications have shown particular promise, with FNDM [Li *et al.*, 2023] and mDDPM [Iqbal *et al.*, 2024] demonstrating enhanced efficiency through masked diffusion models, while [Fontanella *et al.*, 2024] introduces novel counterfactual generation techniques. Recent research includes AnomalyDiffusion [Hu *et al.*, 2024b] for few-shot generation and DISYRE [Naval Marimont *et al.*, 2024] for synthetic anomaly generation in medical imaging.. MDPS [Wu *et al.*, 2024] and DRAD [Sheng *et al.*, 2024] further enhance detection through masked sampling and noise embedding, while methods like DIC [Tebbe and Tayyub, 2024] employ dynamic step size computation to improve localization accuracy.

Method	DS	Datasets	Results of metrics on datasets
SimpDM [2024b]	C	Iris, Yacht, etc.	RMSE: 0.059 (Iris), 0.045 (Yacht), 0.102 (Housing), etc.
CoDi [2023a]	C & D	Bank, Heart, etc.	B-F1: 47.26%, B-AUROC: 81.06%, M-F1: 62.21%, etc., on Bank
TimeDiT [2024]	C	Stocks, Energy, ect.	DS: 11.50% (Stocks), 17.78% (Air Quality), 17.26% (Energy), etc.
NGLS-Diff [2024a]	C	SWaT, MSL, etc.	F1: 97.52% (SWaT), 90.81% (MSL), 95.30% (SMAP), 98.04% (PSM)
D^3R [2023a]	C	PSM, SMD, SWaT	F1: 76.09% (PSM), 86.82% (SMD), 78.12% (SWaT)
DiffAD [2023]	C	MSL, SWaT, etc.	F1: 94.19% (MSL), 97.66% (SWaT), 97.95% (PSM), 96.95% (SMAP), etc.
DiffADT [2024]	C	SMAP, MSL, SMD	Pre: 96.33% (SMAP), 95.21% (MSL), 79.87% (SMD), etc.

Table 2: Summary of TSAD methods with metric results on datasets.

Method	DS	Datasets	Results of metrics on datasets
MoCoDAD [2023]	D	UB, HR-STC, etc.	AUC: 77.6% (HR-STC), 89.0% (HR-Ave), 68.4% (HR-UB), 68.3% (UB)
[Tur *et al.*, 2023b]	D	UCF, ShT	AUC: 76.36% (ShT), 63.67% (UCF)
DHVAD [2024]	C	Ped2, Ave, ShT	AUC: 98.1% (Ped2), 88.3% (Ave), 78.9% (ShT)
FDAE [2024]	D	Ave, ShT, Ped2	AUC: 97.7% (Ped2), 91.1% (Ave), 73.8% (ShT)
Masked Diffusion [2023]	D	CrossTask,NIV,COIN	SR: 39.17% (CrossTask), 32.35% (NIV), 29.43% (COIN), etc.
FPDM [2023]	D	Ave, ShT, UCF, UB	AUC: 90.1% (Ave), 78.6% (ShT), 74.7% (UCF), 62.7% (UB)
[Wang *et al.*, 2023d]	D	Ped2, Ave, ShT	AUC: 96.5% (Ped2), 92.2% (Ave), 75.4% (ShT)
DiffVAD [2024]	D	Ave, ShT, UCF, etc.	AUC: 81.9% (ShT), 90.3% (Ave), 87.6% (Ped2), etc.
Masked Diffusion [2023]	C	CrossTask,NIV,COIN	SR: 39.17% (CrossTask), 23.47% (CrossTask), 32.35% (NIV), etc.
VADiffusion [2024a]	D	Ped2, Ave, ShT	AUC: 98.2% (Ped2), 94.93% (Ave), 97.32% (ShT)

Table 3: Summary of VAD methods with metric results on datasets.

4.2 Time Series Anomaly Detection

DMs have emerged as a powerful technique for TSAD, effectively learning complex distributions of sequential data [Yang *et al.*, 2024b]. DMs can identify various anomaly types, including point, contextual, and collective anomalies [Sui *et al.*, 2024]. Advanced approaches like NGLS-Diff [Han *et al.*, 2024a] leverage latent spaces, while methods [Zuo *et al.*, 2024] used structured state space layers explicitly to model temporal dependencies. Recently, some innovations address key challenges: D3R [Wang *et al.*, 2023a] tackles non-stationarity through dynamic decomposition, while TimeDiT [Cao *et al.*, 2024] introduces a foundation model approach with multiple masking schemes. Another key challenge is non-stationarity. DiffAD [Xiao *et al.*, 2023] handle missing data through imputation, complemented by self-supervised techniques [Liu *et al.*, 2024b] and co-evolving strategies [Lee *et al.*, 2023a] for mixed-type temporal data.

4.3 Video Anomaly Detection

VAD effectively leverages spatio-temporal information to identify unusual events. DMs have emerged as a highly promising VAD approach due to their ability to learn complex data distributions and generate high-quality reconstructions. For example, [Tur *et al.*, 2023a] investigated unsupervised VAD using DMs, relying on high reconstruction

Method	Mods.	DS	Datasets	Results of metrics on datasets
MPDR [2023]	I, V, A	C	MNIST, CIFAR-10, etc.	AUPR: 76.40% (MNIST), 98.60% (CIFAR-10), 83.38% (CIFAR-100), etc.
DIAG [2024]	I, T	C	KSDD2	AP: 80.1% (zero-shot), 92.4% (full-shot)
AnomalyXFusion [2024a]	I, T, Te	C	MVTec-AD, MVTec LOCO	IS: 1.82 (MVTec-AD), IC-LPIPS: 0.33 (MVTec-AD), etc

Notes: **Mods.** indicates modalities, where 'I' is image, 'V' is vector, 'A' is audio, 'T' is text, and 'Te' is texture.

Table 4: Summary of MAD methods with metric results on datasets.

error to indicate anomalies, while [Tur *et al.*, 2023b] enhanced this approach by introducing compact motion representations as conditional information. Several innovative architectures have been recently proposed to improve detection accuracy: VADiffusion [Liu *et al.*, 2024a] employs a dual-branch structure combining motion vector reconstruction and I-frame prediction, while FDAE [Zhu *et al.*, 2024] introduces a flow-guided diffusion autoencoder with sample refinement for comprehensive detection of both appearance and motion anomalies. Recent advances include [Yan *et al.*, 2023]'s feature prediction diffusion model and [Cheng *et al.*, 2024]'s denoising diffusion-augmented hybrid framework, both enhancing semantic understanding of normal patterns. Furthermore, [Wang *et al.*, 2023d] proposed an ensemble approach using stochastic reconstructions and motion filters, while [Fang *et al.*, 2023] explored masked diffusion with task-awareness for more focused anomaly detection in specific contexts.

4.4 Multimodal Anomaly Detection

MAD integrates data from various sources to identify deviations from expected behavior. While DMs are relatively nascent in this area, they hold substantial promise through advanced multimodal data integration. For instance, AnomalyXFusion [Hu *et al.*, 2024a] enhances anomaly synthesis by effectively combining image, text, and mask features, while [Flaborea *et al.*, 2023] demonstrates significant success in skeleton-based VAD through motion-conditioned diffusion models. For IAD, combining visual data with text descriptions significantly improves subtle anomaly detection [Capogrosso *et al.*, 2024], with energy-based approaches [Yoon *et al.*, 2023] leveraging manifold structures for more accurate boundary learning. GLAD [Yao *et al.*, 2025] further suggests extending DMs for multimodal data through specialized architectures, while integration with LLMs offers promising directions for context-aware anomaly detection.

5 Discussions

Despite significant progress in DMAD, several critical challenges remain. In this section, we explore key areas that require further research and development.

Computational Cost. Widespread adoption of DMAD remains constrained by substantial computational requirements, particularly when processing high-dimensional data or extended time series. Computational demands manifest during both distribution learning in training and data generation in sampling phases, with the sampling process's iterative nature demanding numerous steps for quality output [Cui *et al.*, 2023]. For example, high-resolution IAD suffers from increased computational overhead due to data volume, model

complexity, and the need to capture temporal dependencies [Wyatt *et al.*, 2022; Sui *et al.*, 2024]. However, some researchers are actively exploring solutions. One promising direction is faster sampling methods, such as progressive distillation and optimized sampling schedules like align your steps, which aim to reduce sampling steps while maintaining quality [Salimans and Ho, 2021]. Another approach is model compression through techniques like pruning and quantization. Additionally, efficient architectures, like [Cui *et al.*, 2023] leveraging ER SDEs for faster sampling, and preconditioning methods offer further computational gains.

Interpretability and Explainability. Interpretability remains a key challenge for DMAD [Katsuoka *et al.*, 2024]. Understanding DM's decision-making is crucial, especially in critical applications [Naval Marimont *et al.*, 2024]. Visualizing anomaly scores, like spatially highlighting anomalous image regions as in reconstruction-based methods [Yao *et al.*, 2025], becomes essential. However, the iterative denoising process inherent in DMs complicates interpretability. Explaining anomaly detection requires identifying and explaining deviating features. Integrating DMs with explainable AI (xAI) techniques, such as incorporating attention mechanisms or leveraging LLMs for textual/visual explanations [Wang *et al.*, 2023b], offers a promising research direction.

Complex Data Distributions. A key challenge in applying DMAD lies in handling complex data distributions. Imbalanced datasets, where anomalies are rare, can bias DMs towards the majority class [Yang *et al.*, 2024a], hindering accurate anomaly modeling. Similarly, multimodal datasets, representing distinct normal behaviors, can confound DM learning [Zuo *et al.*, 2024], potentially misclassifying data from less prominent modes. Noisy or missing data further complicates DM training and inference [Choi *et al.*, 2022], as differentiating true anomalies from data imperfections becomes difficult. However, potential solutions exist. Data augmentation techniques can address class imbalance by generating synthetic minority class samples [Yang *et al.*, 2024a]. Robust training methods, such as using semi-unbalanced optimal transport, can enhance DM resilience to noise and outliers [Dao *et al.*, 2024]. Specialized architectures, potentially incorporating mechanisms for handling missing data or modeling multiple modes [Xiao *et al.*, 2023], and dynamic step size computation [Tebbe and Tayyub, 2024] could further improve DM performance on complex distributions.

Robustness and Adversarial Attacks. Adversarial robustness is a critical concern for DMAD. Similar to other deep learning models, DMs are vulnerable to adversarial perturbations, raising concerns about the reliability of diffusion-based AD systems [Chen *et al.*, 2024b]. For example, [Kang *et al.*, 2025] demonstrates the potential of DMs for adversarial defense in classification, directly applying such methods to AD can reduce anomaly detection rates. Specifically, the purification process may remove crucial anomaly signals along with noise. Additionally, adversarial examples exhibit misalignment within DM manifolds, offering a potential detection avenue but requiring further investigation. The observed robustness differences between pixel-space diffusion models (PDMs) and more vulnerable latent diffusion models (LDMs) [Graham *et al.*, 2023] further underscore the need to consider specific DM types. Consequently, future research should prioritize robust DM-based AD methods, including architectures and training procedures that distinguish genuine anomalies from adversarial noise. Some promising directions include defense strategies like DIFFender [Kang *et al.*, 2025], leveraging text-guided diffusion and the adversarial anomaly perception phenomenon, and incorporating insights from adversarial example behavior within DM manifolds.

Edge-Cloud Collaboration. Real-time DMAD faces significant adoption barriers due to their substantial computational demands [Li *et al.*, 2023]. Edge-cloud collaboration offers a promising solution to this challenge by distributing the workload between edge devices and cloud servers. Carefully designed Lightweight DMs deployed on edge devices perform initial anomaly screening, while resource-intensive tasks like full reconstructions are efficiently offloaded to cloud servers [Yan *et al.*, 2024]. In addition, federated learning enables collaborative model training across edge devices and the cloud without sharing sensitive data, thereby enhancing generalization and preserving privacy [Jin *et al.*, 2024]. Dynamic DM partitioning [Chen *et al.*, 2024a] facilitates adaptive resource allocation, optimizing performance based on network conditions and computational demands. Strategic data placement and distributed DNN deployment principles further enhance system efficiency. The integration of proactive detection mechanisms, exemplified by Maat [Lee *et al.*, 2023b], proves particularly valuable for time-critical applications in cloud monitoring and AIOps environments.

Integrating with Large Language Models. Integrating DMs with LLMs offers a highly promising avenue for enhancing anomaly detection, particularly by generating human-interpretable explanations of detected anomalies and incorporating rich contextual information [Kumar *et al.*, 2023]. For example, LLMs can leverage detailed textual descriptions to provide context for observed fluctuations, distinguishing genuine anomalies from expected variations for MAD [Capogrosso *et al.*, 2024]. However, current LLM integration for anomaly detection faces a key challenge: effectively representing and tokenizing temporal data. Existing tokenizers, primarily designed for text, may not adequately capture the subtle nuances of numerical and temporal data, potentially hindering performance [Li *et al.*, 2024]. Consequently, a critical research direction involves developing efficient data representation techniques and specialized LLMs for anomaly detection to fully realize this synergistic approach's potential [Tebbe and Tayyub, 2024].

6 Conclusion

In this survey, we first introduce the core concepts of anomaly detection and diffusion models, providing a foundation for understanding DMAD. Then, we systematically review existing methodologies and their tasks across diverse data types, including image, time series, and multimodal data. Furthermore, we analyze representative approaches for each data type, highlighting their strengths and limitations. To promote further research, we identify key challenges and promising future directions, aiming to advance DMAD research and inspire innovative solutions for real-world applications.

References

[Bercea *et al.*, 2023] Cosmin I. Bercea, Michael Neumayr, Daniel Rueckert, and Julia A. Schnabel. Mask, stitch, and re-sample: Enhancing robustness and generalizability in anomaly detection through automatic diffusion models. *arXiv:2305.19643*, 2023.

[Cao *et al.*, 2024] Defu Cao, Wen Ye, and Yan Liu. Timedit: General-purpose diffusion transformers for time series foundation model. In *ICMLW*, 2024.

[Capogrosso *et al.*, 2024] Luigi Capogrosso, Alvise Vivenza, Andrea Chiarini, Francesco Setti, and Marco Cristani. Exploiting multimodal latent diffusion models for accurate anomaly detection in industry 5.0. In *xAI*, volume 3762, pages 230–235, 2024.

[Chen *et al.*, 2024a] Xiangchun Chen, Jiannong Cao, Yuvraj Sahni, Shan Jiang, and Zhixuan Liang. Dynamic task offloading in edge computing based on dependency-aware reinforcement learning. *IEEE TCC*, 12:594–608, 2024.

[Chen *et al.*, 2024b] Yong Chen, Xuedong Li, Peng Hu, Dezhong Peng, and Xu Wang. Diffilter: Defending against adversarial perturbations with diffusion filter. *IEEE TIFS*, 19:6779–6794, 2024.

[Cheng *et al.*, 2024] Kai Cheng, Yaning Pan, Yang Liu, Xinhua Zeng, and Rui Feng. Denoising diffusion-augmented hybrid video anomaly detection via reconstructing noised frames. In *IJCAI*, volume 2, pages 695–703, 2024.

[Choi *et al.*, 2022] Jooyoung Choi, Jungbeom Lee, Chaehun Shin, Sungwon Kim, Hyunwoo Kim, and Sungroh Yoon. Perception prioritized training of diffusion models. In *CVPR*, pages 11472–11481, 2022.

[Cui *et al.*, 2023] Qinpeng Cui, Xinyi Zhang, Zongqing Lu, and Qingmin Liao. Elucidating the solution space of extended reverse-time sde for diffusion models, 2023.

[Dao *et al.*, 2024] Quan Dao, Binh Ta, Tung Pham, and Anh Tran. A high-quality robust diffusion framework for corrupted dataset, 2024.

[Deveney *et al.*, 2023] Teo Deveney, Jan Stanczuk, Lisa Maria Kreusser, Chris Budd, and Carola-Bibiane Schönlieb. Closing the ode-sde gap in score-based diffusion models through the fokker-planck equation. *arXiv:2311.15996*, 2023.

[Fang *et al.*, 2023] Fen Fang, Yun Liu, Ali Koksal, Qianli Xu, and Joo-Hwee Lim. Masked diffusion with task-awareness for procedure planning in instructional videos. *arXiv:2309.07409*, 2023.

[Flaborea *et al.*, 2023] Alessandro Flaborea, Luca Collorone, Guido Maria D'Amely Di Melendugno, Stefano D'Arrigo, Bardh Prenkaj, and Fabio Galasso. Multimodal motion conditioned diffusion model for skeleton-based video anomaly detection. In *ICCV*, pages 1–9, 2023.

[Fontanella *et al.*, 2024] Alessandro Fontanella, Grant Mair, Joanna Wardlaw, Emanuele Trucco, and Amos Storkey. Diffusion models for counterfactual generation and anomaly detection in brain images. *IEEE TMC*, 2024.

[Graham *et al.*, 2023] Mark S. Graham, Walter Hugo Lopez Pinaya, Paul Wright, Petru-Daniel Tudosiu, Yee H. Mah, James T. Teo, H. Rolf Jäger, David Werring, Parashkev Nachev, Sebastien Ourselin, and M. Jorge Cardoso. Unsupervised 3d out-of-distribution detection with latent diffusion models. In *MICCAI*, pages 446–456, 2023.

[Han *et al.*, 2024a] Jiashu Han, Shanshan Feng, Min Zhou, Xinyu Zhang, Yew Soon Ong, and Xutao Li. Diffusion model in normal gathering latent space for time series anomaly detection. In *ECML PKDD*, volume 14943, pages 284–300, 2024.

[Han *et al.*, 2024b] Yinbin Han, Meisam Razaviyayn, and Renyuan Xu. Neural network-based score estimation in diffusion models: Optimization and generalization, 2024.

[Hu and Jin, 2023] Xianyao Hu and Congming Jin. Anodode: Anomaly detection with diffusion ode, 2023.

[Hu *et al.*, 2024a] Jie Hu, Yawen Huang, Yilin Lu, Guoyang Xie, Guannan Jiang, Yefeng Zheng, and Zhichao Lu. Anomalyxfusion: Multi-modal anomaly synthesis with diffusion. *arXiv:2404.19444*, 2024.

[Hu *et al.*, 2024b] Teng Hu, Jiangning Zhang, Ran Yi, Yuzhen Du, Xu Chen, Liang Liu, Yabiao Wang, and Chengjie Wang. Anomalydiffusion: Few-shot anomaly image generation with diffusion model. In *AAAI*, volume 38, pages 8526–8534, 2024.

[Iqbal *et al.*, 2024] Hasan Iqbal, Umar Khalid, Chen Chen, and Jing Hua. Unsupervised anomaly detection in medical images using masked diffusion model. In *MLMI*, pages 372–381, 2024.

[Jin *et al.*, 2024] Ming Jin, Huan Yee Koh, Qingsong Wen, Daniele Zambon, Cesare Alippi, Geoffrey I. Webb, Irwin King, and Shirui Pan. A survey on graph neural networks for time series: Forecasting, classification, imputation, and anomaly detection. *IEEE TPAMI*, 46(12):1–20, 2024.

[Kang *et al.*, 2025] Caixin Kang, Yinpeng Dong, Zhengyi Wang, Shouwei Ruan, Yubo Chen, Hang Su, and Xingxing Wei. Diffender: Diffusion-based adversarial defense against patch attacks. In *ECCV*, pages 130–147, 2025.

[Katsuoka *et al.*, 2024] Teruyuki Katsuoka, Tomohiro Shiraishi, Daiki Miwa, Vo Nguyen Le Duy, and Ichiro Takeuchi. Statistical test on diffusion model-based anomaly detection by selective inference, 2024.

[Kumar *et al.*, 2023] Komal Kumar, Snehashis Chakraborty, and Sudipta Roy. Self-supervised diffusion model for anomaly segmentation in medical imaging. In *PRMI*, volume 14301, pages 359–368, 2023.

[Le Lan and Dinh, 2021] Charline Le Lan and Laurent Dinh. Perfect density models cannot guarantee anomaly detection. *Entropy*, 23:1690, 2021.

[Lee *et al.*, 2023a] Chaejeong Lee, Jayoung Kim, and Noseong Park. Codi: Co-evolving contrastive diffusion models for mixed-type tabular synthesis. In *ICML*, pages 18940–18956, 2023.

[Lee *et al.*, 2023b] Cheryl Lee, Tianyi Yang, Zhuangbin Chen, Yuxin Su, and Michael R. Lyu. Maat: Performance metric anomaly anticipation for cloud services with conditional diffusion. In *ASE*, pages 116–128, 2023.

[Li *et al.*, 2023] Jinpeng Li, Hanqun Cao, Jiaze Wang, Furui Liu, Qi Dou, Guangyong Chen, and Pheng-Ann Heng. Fast non-markovian diffusion model for weakly supervised anomaly detection in brain mr images. In *MICCAI*, volume 14224, pages 579–589, 2023.

[Li *et al.*, 2024] Shu Li, Jiong Yu, Yi Lu, Guangqi Yang, Xusheng Du, and Su Liu. Self-supervised enhanced denoising diffusion for anomaly detection. *Inf. Sci.*, 669:120612, 2024.

[Liu *et al.*, 2024a] Hao Liu, Lijun He, Miao Zhang, and Fan Li. Vadiffusion: Compressed domain information guided conditional diffusion for video anomaly detection. *IEEE TCSVT*, 34:8398–8411, 2024.

[Liu *et al.*, 2024b] Yixin Liu, Thalaiyasingam Ajanthan, Hisham Husain, and Vu Nguyen. Self-supervision improves diffusion models for tabular data imputation. In *CIKM*, pages 1513–1522, 2024.

[Livernoche *et al.*, 2023] Victor Livernoche, Vineet Jain, Yashar Hezaveh, and Siamak Ravanbakhsh. On diffusion modeling for anomaly detection. In *ICLR*, 2023.

[Luo, 2023] Weijian Luo. A comprehensive survey on knowledge distillation of diffusion models, 2023.

[Naval Marimont *et al.*, 2024] Sergio Naval Marimont, Vasilis Siomos, Matthew Baugh, Christos Tzelepis, Bernhard Kainz, and Giacomo Tarroni. Ensembled cold-diffusion restorations for unsupervised anomaly detection. In *MICCAI*, pages 243–253, 2024.

[Pang *et al.*, 2021] Guansong Pang, Chunhua Shen, Longbing Cao, and Anton Van Den Hengel. Deep learning for anomaly detection: A review. *ACM CSUR*, 54(2):38:1–38:38, March 2021.

[Salimans and Ho, 2021] Tim Salimans and Jonathan Ho. Progressive distillation for fast sampling of diffusion models. In *ICLR*, 2021.

[Sheng *et al.*, 2024] Xinyu Sheng, Shande Tuo, and Lu Wang. Surface anomaly detection and localization with diffusion-based reconstruction. In *IJCNN*, pages 1–8, 2024.

[Sui *et al.*, 2024] Jialin Sui, Jinsong Yu, Yue Song, and Jian Zhang. Anomaly detection for telemetry time series using a denoising diffusion probabilistic model. *IEEE Sens. J.*, 24:16429–16439, 2024.

[Tebbe and Tayyub, 2024] Justin Tebbe and Jawad Tayyub. Dynamic addition of noise in a diffusion model for anomaly detection. In *CVPR*, pages 3940–3949, 2024.

[Tur *et al.*, 2023a] Anil Osman Tur, Nicola Dall'Asen, Cigdem Beyan, and Elisa Ricci. Exploring diffusion models for unsupervised video anomaly detection. In *ICIP*, pages 2540–2544, 2023.

[Tur *et al.*, 2023b] Anil Osman Tur, Nicola Dall'Asen, Cigdem Beyan, and Elisa Ricci. Unsupervised video anomaly detection with diffusion models conditioned on compact motion representations. In *ICIAP*, pages 49–62, 2023.

[Wang and Vastola, 2023] Binxu Wang and John J. Vastola. The hidden linear structure in score-based models and its application. *arXiv:2311.10892*, 2023.

[Wang *et al.*, 2023a] Chengsen Wang, Zirui Zhuang, Qi Qi, Jingyu Wang, Xingyu Wang, Haifeng Sun, and Jianxin Liao. Drift doesn't matter: Dynamic decomposition with diffusion reconstruction for unstable multivariate time series anomaly detection. In *NeurIPS*, volume 36, pages 10758–10774, 2023.

[Wang *et al.*, 2023b] He Wang, Longquan Dai, Jinglin Tong, and Yan Zhai. Odd: One-class anomaly detection via the diffusion model. In *ICIP*, pages 3000–3004, 2023.

[Wang *et al.*, 2023c] Wenjie Wang, Yiyan Xu, Fuli Feng, Xinyu Lin, Xiangnan He, and Tat-Seng Chua. Diffusion recommender model. In *SIGIR*, pages 832–841, 2023.

[Wang *et al.*, 2023d] Zhiqiang Wang, Xiaojing Gu, Jingyu Hu, and Xingsheng Gu. Ensemble anomaly score for video anomaly detection using denoise diffusion model and motion filters. *Neurocomputing*, 553:126589, 2023.

[Wu *et al.*, 2024] Di Wu, Shicai Fan, Xue Zhou, Li Yu, Yuzhong Deng, Jianxiao Zou, and Baihong Lin. Unsupervised anomaly detection via masked diffusion posterior sampling. *arXiv:2404.17900*, 2024.

[Wyatt *et al.*, 2022] Julian Wyatt, Adam Leach, Sebastian M. Schmon, and Chris G. Willcocks. Anoddpm: Anomaly detection with denoising diffusion probabilistic models using simplex noise. In *CVPR*, pages 650–656, 2022.

[Xiao *et al.*, 2023] Chunjing Xiao, Zehua Gou, Wenxin Tai, Kunpeng Zhang, and Fan Zhou. Imputation-based time-series anomaly detection with conditional weight-incremental diffusion models. In *KDD*, pages 1–9, 2023.

[Xu *et al.*, 2023] Haohao Xu, Shuchang Xu, and Wenzhen Yang. Unsupervised industrial anomaly detection with diffusion models. *J. Vis. Commun. Image Represent.*, 97:103983, 2023.

[Yan *et al.*, 2023] Cheng Yan, Shiyu Zhang, Yang Liu, Guansong Pang, and Wenjun Wang. Feature prediction diffusion model for video anomaly detection. In *ICCV*, pages 5504–5514, 2023.

[Yan *et al.*, 2024] Chenqian Yan, Songwei Liu, Hongjian Liu, Xurui Peng, Xiaojian Wang, Fangmin Chen, Lean Fu, and Xing Mei. Hybrid sd: Edge-cloud collaborative inference for stable diffusion models. *arXiv:2408.06646*, 2024.

[Yang *et al.*, 2024a] Xiongyan Yang, Tianyi Ye, Xianfeng Yuan, Weijie Zhu, Xiaoxue Mei, and Fengyu Zhou. A novel data augmentation method based on denoising diffusion probabilistic model for fault diagnosis under imbalanced data. *IEEE TII*, 20:7820–7831, 2024.

[Yang *et al.*, 2024b] Yiyuan Yang, Ming Jin, Haomin Wen, Chaoli Zhang, Yuxuan Liang, Lintao Ma, Yi Wang, Chenghao Liu, Bin Yang, Zenglin Xu, Jiang Bian, Shirui Pan, and Qingsong Wen. A survey on diffusion models for time series and spatio-temporal data, 2024.

[Yao *et al.*, 2025] Hang Yao, Ming Liu, Zhicun Yin, Zifei Yan, Xiaopeng Hong, and Wangmeng Zuo. Glad: Towards better reconstruction with global and local adaptive diffusion models for unsupervised anomaly detection. In *ECCV*, pages 1–17, 2025.

[Yoon *et al.*, 2023] Sangwoong Yoon, Young-Uk Jin, Yung-Kyun Noh, and Frank Park. Energy-based models for anomaly detection: A manifold diffusion recovery approach. In *NeurIPS*, volume 36, pages 1–21, 2023.

[Zhan *et al.*, 2024] Jiawei Zhan, Jinxiang Lai, Bin-Bin Gao, Jun Liu, Xiaochen Chen, and Chengjie Wang. Enhancing multi-class anomaly detection via diffusion refinement with dual conditioning. *arXiv:2407.01905*, 2024.

[Zhang and Pilanci, 2024] Fangzhao Zhang and Mert Pilanci. Analyzing neural network-based generative diffusion models through convex optimization, 2024.

[Zhang *et al.*, 2023] Hui Zhang, Zheng Wang, Zuxuan Wu, and Yu-Gang Jiang. Diffusionad: Norm-guided one-step denoising diffusion for anomaly detection, 2023.

[Zhang *et al.*, 2024] Menghao Zhang, Jingyu Wang, Qi Qi, Pengfei Ren, Haifeng Sun, Zirui Zhuang, Lei Zhang, and Jianxin Liao. Safeguarding sustainable cities: Unsupervised video anomaly detection through diffusion-based latent pattern learning. In *IJCAI*, volume 8, pages 7572–7580, 2024.

[Zhu *et al.*, 2024] Aoni Zhu, Wenjun Wang, and Cheng Yan. Flow-guided diffusion autoencoder for unsupervised video anomaly detection. In *PRCV*, volume 14430, pages 183–194, 2024.

[Zuo *et al.*, 2024] Haiwei Zuo, Aiqun Zhu, Yanping Zhu, Yinping Liao, Shiman Li, and Yun Chen. Unsupervised diffusion based anomaly detection for time series. *APIN*, 54:8968–8981, 2024.

关于异常检测的扩散模型的综述

Jing Liu[1,2] , Zhenchao Ma[1] , Zepu Wang[3] , Chenxuanyin Zou[1] , Jiayang Ren[1] , Zehua Wang[1] , Liang Song[2] , Bo Hu[2] , Yang Liu[2,3] , Victor C.M. Leung[1]

[1]加拿大温哥华不列颠哥伦比亚大学，[2]中国上海复旦大学，[3]中国苏州杜克昆山大学

{jingliu, zhenchaoma, zwang}@ece.ubc.ca, {zcxy, rjy12307}@mail.ubc.ca, zw163@duke.edu, {songl, bohu, yangliu20}@fudan.edu.cn, vleung@ieee.org

摘要

扩散模型（DMs）作为一类强大的生成式人工智能模型应运而生，在异常检测（AD）任务中展现出显著潜力，应用于网络安全、欺诈检测、医疗保健和制造业等多个领域。这两个领域的交叉——即被称为异常检测扩散模型（DMAD）的领域——为识别日益复杂和高维数据中的偏差提供了有前景的解决方案。在本次综述中，我们回顾了DMAD研究的最新进展。我们首先介绍异常检测（AD）和扩散模型（DMs）的基本概念，随后全面分析了包括DDPMs、DDIMs和Score SDEs在内的经典扩散模型架构。我们进一步将现有的DMAD方法分为基于重建、基于密度和混合方法三类，并详细考察其方法论创新。我们还探讨了不同数据模态下的多样任务，包括图像、时间序列、视频和多模态数据分析。此外，我们讨论了关键挑战和新兴研究方向，包括计算效率、模型可解释性、鲁棒性增强、边缘-云协作以及与大语言模型的整合。DMAD研究论文和资源的集合可在https://github.com/fdjingliu/DMAD获取。

1 引言

数据量、速度和种类日益增加，这为异常检测（AD）带来了机遇和挑战。在网络安全领域，实时威胁检测至关重要，因为网络流量和日志不断涌入 [Jin *et al.*, 2024]。类似地，金融机构在处理海量交易数据集时，强大的欺诈检测系统是必不可少的 [Wang *et al.*, 2023a]。医疗和制造业也在很大程度上依赖数据进行早期疾病诊断和预测性维护 [Zhang *et al.*, 2023]。这些应用凸显了自动化AD方法有效识别复杂数据集中异常值的日益需要。然而，传统技术常常基于在统计方法或基于规则的系统方面，难以应对现代数据的规模和复杂性 [Katsuoka *et al.*, 2024]。具体而言，这些方法通常需要大量的手动特征工程，并且难以适应不断变化的数据分布。此外，庞大的数据量可能会压倒传统方法，使其在实时应用中变得计算上不可行。因此，需要更复杂且可扩展的异常检测方法。例如，弱监督方法利用有限的标签数据来提高性能，推动可扩展的深度学习架构朝着解决这些基本挑战的方向创新 [Pang *et al.*, 2021]。

扩散模型（DMs）已经成为一种强大的生成模型类别，能够在各种数据模态中合成样本 [Wang *et al.*, 2023c]。与可能表现出训练不稳定或生成较少细节的样本的生成对抗网络（GANs）和变分自编码器（VAEs）不同，DMs通过逐步去噪过程生成更清晰、更真实的样本 [Chen *et al.*, 2024b]。因此，DMs在捕捉比GANs更广泛的数据分布方面表现优异 [Wyatt *et al.*, 2022]，使它们特别适合于异常检测，因为它们增强的模态覆盖促进了正常模式的精准建模以及后续的分布离群点识别 [Li *et al.*, 2024]。

最近复杂和多维数据的增长给异常检测方法带来了新的挑战。在这一背景下，DM因其与密度估计的内在联系而成为一种有前途的解决方案[Le Lan and Dinh, 2021]。DM通过迭代去噪学习正常数据的概率分布。利用其卓越的生成能力，DM能够准确重建正常模式，同时捕捉潜在的流形结构，从而通过重建误差分析和概率密度估计实现异常检测[Hu and Jin, 2023; Salimans and Ho, 2021]。例如，AnoDDPM [Wyatt *et al.*, 2022]通过重建误差使用扩散模型进行异常检测，而ODD [Wang *et al.*, 2023b]则通过利用高级生成建模来增强对高维数据的处理。此外，学到的评分函数表示对数概率密度的梯度，可以直接用作异常得分，如在扩散时间估计中所示[Livernoche *et al.*, 2023]。

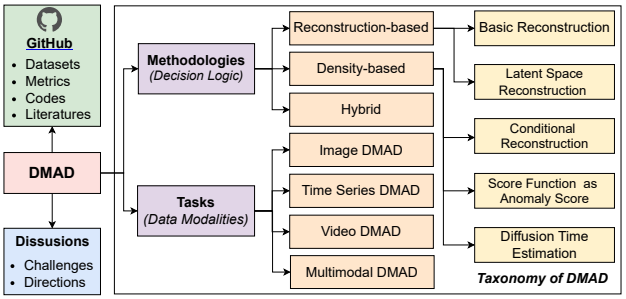

图1：用于异常检测的扩散模型分类

研究动机。现有综述文献[Jin *et al.*, 2024; Pang *et al.*, 2021]分别回顾了异常检测和扩散模型[Yang *et al.*, 2024b; Luo, 2023]，但它们要么聚焦于传统深度学习方法，未考虑扩散模型的新兴作用，要么仅将异常检测视为众多DM应用中的一种，缺乏深入分析。用于异常检测的扩散模型（DMAD）的最新突破展现出显著潜力，有望通过其在复杂数据分布建模和高质量样本生成方面的独特能力革新该领域。尽管取得了这些进展，目前尚无现有工作系统地回顾扩散模型（DM）如何增强异常检测，或分析它们在两个领域交叉处的新兴作用。我们的工作填补了这一空白，通过及时概述DMAD，分析其理论基础、当前成果以及有望从根本上重塑异常检测研究格局的充满前景的未来方向。

贡献　本综述的主要贡献有四个方面：（1) *A systematic taxonomy*。我们首次提出了关于DMAD的全面分类体系（如图1所示），将现有方法分为基于重构的、基于密度的和混合方法，为理解这一新兴领域提供了一个结构化的框架。(2) *A com- prehensive review*。基于所提出的分类体系，我们系统地分析了DMAD在不同任务中的应用情况，包括图像异常检测（IAD）、时间序列异常检测（TSAD）、视频异常检测（VAD）和多模态异常检测（MAD），探讨了这些任务的方法、优势和局限性。(3) *Technical chal- lenges and future directions*。我们识别并讨论了DMAD中的关键挑战，包括计算成本、可解释性、对对抗攻击的鲁棒性、复杂的数据分布、边缘-云协同以及与大型语言模型（LLMs）的集成，同时提出了潜在的解决方案和未来研究方向。(4) *Resources and benchmarks*。我们全面收集了针对不同任务的代表性方法、实现方案、数据集和评估指标，为该领域的研究人员和从业者提供了宝贵的资源。

2 预备知识

本节首先介绍异常检测的基本概念。在此之后，我们介绍各类异常类型，包括点异常、情境异常和群体异常。接下来，我们讨论分布模型（DMs）的基本原理及其与异常检测的相关性。然后我们探讨基于分数的模型和分数匹配技术。最后，我们介绍用于异常检测的分布模型（DMs）的主要变体，强调它们的优缺点。

2.1 异常检测

异常检测旨在识别与预期数据分布显著偏离的实例[Wang and Vastola, 2023]。给定数据集$\mathcal{D} = \{x_1, x_2, ..., x_n\}$，其中$x_i \in \mathbb{R}^d$，目标是识别异常子集$\mathcal{A} \subset \mathcal{D}$。异常行为的特征是在通常未知的分布$p(x)$下具有较低的概率密度。存在多种异常类型，包括点异常[Hu and Jin, 2023]，即个别偏离实例；上下文异常[Sui *et al.*, 2024]，即在特定上下文中异常；以及集体异常，即仅当整体考虑时才表现出异常性的实例组。常见的评估指标包括AUC[Xu *et al.*, 2023]，用于衡量分类器区分正常与异常实例的能力。此外，精确率、召回率和F1分数用于评估正确识别与最小化误报之间的权衡[Wang *et al.*, 2023a; Xiao *et al.*, 2023; Zuo *et al.*, 2024]。指标的选择取决于具体应用以及最小化假阳性和假阴性之间的相对重要性[Pang *et al.*, 2021]。

2.2 扩散模型

DMs构成一类潜在变量模型，这类模型由用于破坏和去噪数据的正向和反向马尔可夫过程定义，其训练基于负对数似然的变分下界。

前向过程。前向过程被称为扩散过程，逐渐向数据 x_0 添加噪声，持续 T 个时间步，将其分布转变为各向同性的高斯分布 [Wyatt *et al.*, 2022]。具体而言，给定一个方差调度 $\{\beta_t\}_{t=1}^T$，其中 $0 < \beta_1 < \cdots < \beta_T < 1$，该过程通过带有高斯转移核的马尔可夫链生成一系列潜变量 $\{x_1, \ldots, x_T\}$：

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t\mathbf{I}). \tag{1}$$

这里，$\mathcal{N}(x;\ \mu, \Sigma)$表示一个均值为$\mu$、协方差为$\Sigma$的高斯分布，而$\mathbf{I}$是单位矩阵。参数$\beta_t$控制每一步添加的噪声。随着$t$的增加，$x_T$趋近于高斯噪声。根据马尔可夫性质 [Li *et al.*, 2023]，联合分布为：

$$q(x_{1:T}|x_0) = \prod_{t=1}^{T} q(x_t|x_{t-1}). \tag{2}$$

因此，任何 x_t 均可直接从 x_0 中采样：

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)\mathbf{I}), \tag{3}$$

其中 $\alpha_t = 1 - \beta_t$ 和 $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$，这带来了计算上的好处。相关的工作从多个角度探讨这个过程，包括乘法转换、一致化技术用于收敛分析、Gaussian过程协方差变换、张量网络建模、首次到达时间统计以及无限维扩散过程 [Kumar *et al.*, 2023]。

反向过程。反向过程旨在学习条件概率分布$p_\theta(x_{t-1}|x_t)$，通过迭代去除噪声来恢复原始数据分布。它通常被建模为高斯分布：

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)), \quad (4)$$

其中μ_θ和Σ_θ分别是预测的均值和协方差，由精心设计的神经网络（例如U-Net [Yan *et al.*, 2024]或Transformer [Cao *et al.*, 2024]）参数化，并以在时间步t处的噪声输入x_t为条件。虽然协方差$\Sigma_\theta(x_t, t)$可以被学习，但一种常见的简化方法是使用固定的、随时间变化的方差[Salimans and Ho, 2021]。神经网络学习有效地预测均值$\mu_\theta(x_t, t)$，该均值指导去噪。存在多种参数化策略，包括预测$q(x_{t-1}|x_t, x_0)$的均值、添加的噪声ϵ_t或原始数据x_0。从高斯噪声x_T开始，反向过程迭代地应用$p_\theta(x_{t-1}|x_t)$，直到到达x_0。

训练目标。DM通过最大化观察数据的似然性进行训练。然而，由于复杂的潜在变量形式，直接优化在计算上是不可行的。因此，训练依赖于最大化数据对数似然的变分下界（VLB），该下界是使用变分推断推导而来的[Bercea *et al.*, 2023]：

$$\begin{aligned}\mathcal{L}_{\text{vlb}} =& \mathbb{E}_q[D_{\text{KL}}(q(x_T|x_0)||p_\theta(x_T))] - \log p_\theta(x_0|x_1) \\ &+ \mathbb{E}_q[\sum_{t=2}^{T} D_{\text{KL}}(q(x_{t-1}|x_t, x_0)||p_\theta(x_{t-1}|x_t))],\end{aligned} \quad (5)$$

其中q和p_θ分别表示正向和学习到的反向过程分布。此处D_{KL}为标准的Kullback-Leibler散度，x_0表示原始数据，x_t是在时间步t的带噪声样本。简化的目标函数最小化真实噪声与预测噪声之间的L_2距离[Han *et al.*, 2024b]，可以表示为：

$$\mathcal{L}_{\text{simple}} = \sum_{t=1}^{T} \mathbb{E}_q\left[||\epsilon_t - \epsilon_\theta(x_t, t)||^2\right], \quad (6)$$

其中 ϵ_t 和 $\epsilon_\theta(x_t, t)$ 分别表示真实噪声和预测噪声。这种简化的目标展示了计算效率和有效性 [Livernoche *et al.*, 2023]。此外，在不同时间步加权损失项可以提高性能 [Choi *et al.*, 2022]。从另一个角度来看，DM可以被视为具有理论保证的分布估计器，训练目标可以基于分值匹配，其中模型估计分值函数 [Zhang and Pilanci, 2024]。针对离散和连续时间DM的统一框架为目标优化提供了进一步的洞察 [Lee *et al.*, 2023a]。

2.3 基于分数的模型与分数匹配

分数匹配用于学习分数函数。基于分数的生成模型学习分数函数 $\nabla_x \log p(x)$，代表对数概率密度的梯度。通过直接通过这些梯度编码分布特征，分数函数可在不进行显式密度估计的情况下实现强大的生成能力。分数匹配提供了一种无需明确使用$p(x)$即可学习该得分函数的实用方法。相反，它最小化学习到的得分函数与真实得分函数之间的Fisher散度[Han *et al.*, 2024b]。具体而言，分数匹配目标是$L_{SM}(\theta) = \frac{1}{2}\mathbb{E}_{p(x)}\left[\|\nabla_x \log p_\theta(x) - \nabla_x \log p(x)\|^2\right]$。

去噪声得分匹配。然而，计算真实得分通常是不可处理的。因此，去噪声得分匹配通过加入高斯噪声来扰动数据，并学习该扰动分布的得分。目标变为$L_{DSM}(\theta) = \frac{1}{2}\mathbb{E}_{q_\sigma(x)}\left[\|\nabla_x \log p_\theta(x) - \nabla_x \log q_\sigma(x)\|^2\right]$，其中 $q_\sigma(x)$ 是扰动分布。在不同噪声水平下学习得分使DM能够在不同尺度上捕捉数据分布 [Wang *et al.*, 2023d]。

先进技术。近期研究强调了基于评分的模型中固有的线性结构，特别是在较高噪声水平下，这可能会加速采样 [Wang and Vastola, 2023]。根据感知相关性在训练期间优先选择特定噪声水平，可以进一步提高性能 [Choi *et al.*, 2022]。此外，梯度指导，通过在采样过程中纳入外部目标函数的梯度，有效地将预训练模型适应于特定任务 [Tur *et al.*, 2023b]。

2.4 扩散模型的变体

在本节中，我们将讨论用于异常检测的几种主流扩散模型变体，包括去噪扩散概率模型（DDPMs）、去噪扩散隐式模型（DDIMs）以及基于随机微分方程的分数生成模型（Score SDEs），并分析其各自的优势与局限性。

DDPMs。DDPMs [Bercea *et al.*, 2023] 通过使用马尔可夫链在多个时间步骤中逐步向数据引入受控高斯噪音。训练好的神经网络然后反转这个过程，使模型能够有效学习复杂分布，这使得它特别适合用于异常检测 [Wyatt *et al.*, 2022]。但是，生成样本可能会消耗大量计算资源。

DDIMs。DDIMs [Xu *et al.*, 2023] 通过非马尔可夫采样方法扩展了 DDPMs，能够通过跳过步骤来加速生成。具体而言，它们修改了反向过程，通过将特定参数设置为零，DDIMs 允许确定性采样，这对于异常检测中的一致重建是有益的 [Tebbe and Tayyub, 2024]。

分数 SDEs。分数 SDEs [Deveney *et al.*, 2023] 将扩散建模为连续时间 SDE，其中的分数函数表示对数概率密度的梯度，可以有效用于异常评分 [Li *et al.*, 2024]。虽然为复杂分布提供了灵活性 [Liver- noche *et al.*, 2023]，但训练和参数化选择可能特别具有挑战性 [Graham *et al.*, 2023]。

3 方法论

近期关于DMAD的研究努力可以大致分为三种主要方法：重建基础、密度基础和混合方法。

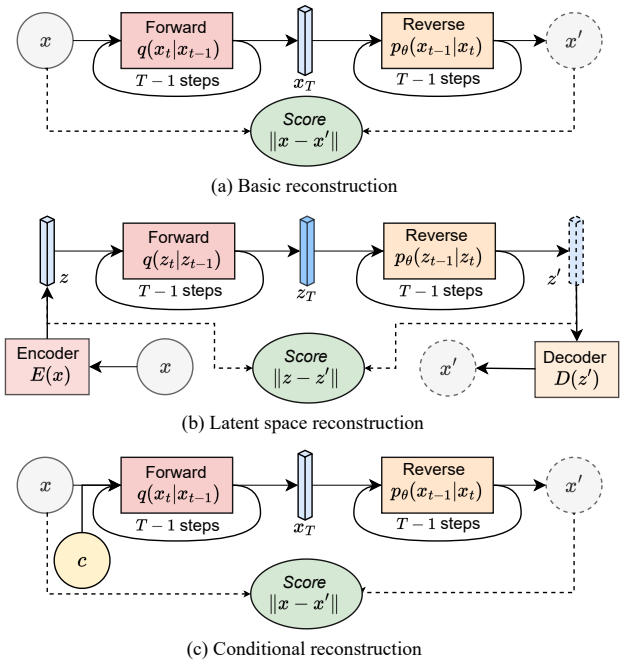

图2：基于重建的AD方法流程示意图：(a)基础，(b)潜在空间，(c)条件重建。

3.1 基于重构的异常检测

基于重建的异常检测（RAD）利用DMs识别学习到的数据分布中的偏差。在这一范式下，我们考虑了三种重建策略，如图2所示：1）基本重建，其中重建误差作为异常分数；2）潜在空间重建，通过降维处理高维数据以提高效率；3）条件重建，利用类别标签等辅助信息进行可能更精细的异常检测。

基础重建。RAD依赖于一个基本原则：在正常数据上训练的扩散模型能够有效重建正常实例，但对于异常实例则表现不佳[Hu and Jin, 2023]。具体而言，模型在正常样本上训练后，通过逆转扩散过程来重建测试样本。输入与其重建之间的差异构成了异常分数[Zhang *et al.*, 2023]。分数越高，表明异常的可能性越大。例如，GLAD[Yao *et al.*, 2025]采用了全局和局部重建视角。相比之下，AutoDDPM[Bercea *et al.*, 2023]专注于改善正常区域的重建。另外，一些方法使用学习到的相似性网络进行比较，生成语义距离作为异常分数[Wang *et al.*, 2023b]。

潜在空间重构RAD利用潜在空间表示来提高效率，并有效处理高维数据，例如图像或视频。具体来说，将输入数据投影到低维潜在空间可显著降低与重构相关的计算负担。自动编码器（AEs）通常是用于这种降维操作，它通过将数据编码到潜在空间，然后解码回原始空间来学习压缩表示。将自编码器（AEs）与扩散模型（DMs）相结合提供了一种很有前景的方法。例如，在自编码器学习到的潜在表示基础上训练的扩散模型（DMs）能够捕捉压缩空间中的正常数据分布[Hu and Jin, 2023]。此外，NGLS-Diff [Han *et al.*, 2024a]是一种新颖的方法，它在正常聚集潜在空间中利用扩散模型（DMs）来增强时间序列数据的异常检测能力。潜在空间重构误差随后被用作异常分数，偏差表示潜在的异常[Wang *et al.*, 2023c]。多个自编码器共享的潜在空间可以分离处理过程和上下文信息。类似地，有监督降维可以针对特定分类任务优化潜在空间，而在扩散变分自编码器（Diffusion VAEs）中采用布朗运动能够捕捉数据集的拓扑结构[Le Lan and Dinh, 2021]。

条件重建。条件信息，如类别标签、掩码或文本描述，引导扩散模型的重建朝向期望的正常输出。例如，FDAE [Zhu *et al.*, 2024] 利用前景对象和运动信息作为输入训练条件扩散自编码器，从而增强无监督方式下异常区域的检测。双重条件 [Zhan *et al.*, 2024] 通过确保预期类别内的预测和重建精度，提高多类异常检测的效果。RecDMs [Xu *et al.*, 2023] 中的可学习编码器提取语义表示以用于条件去噪，从而引导恢复并避免简单的重建。类似地，GLAD [Yao *et al.*, 2025] 在训练过程中引入合成异常，以促使模型学习复杂的噪声分布，从而改善无异常重建。此外，[Tebbe and Tayyub, 2024] 探讨了基于初始异常预测的动态步长计算，以实现更精确的重建。最后，MDPS [Wu *et al.*, 2024] 将正常图像重建建模为多次扩散后验采样，使用掩蔽噪声观察模型和基于扩散的先验，从而提高重建质量。

3.2 基于密度的异常检测

本节探讨基于密度的异常检测（DAD）的两种主要方法，如图3所示：评分函数与扩散时间估计（DTE），通过它们利用学习到的概率密度识别异常值来加以说明。

分数函数作为异常分数。基于梯度的对数概率密度分数函数，$\|\nabla_x \log p(x)\|$，能够准确有效地量化学习分布中数据点的似然度[Zhang and Pilanci, 2024]。在低密度区域，通过利用分数网络$s_\theta(x_t, t)$[Livernoche *et al.*, 2023]，较高的分数幅值可可靠地指示潜在异常。此外，通过分数计算进行概率密度表征，无需显式重建或比较分析即可直接评估异常。[Wang and Vastola, 2023]与[Han *et al.*, 2024b]建立的理论基础强有力地验证了该方法，尽管近期研究[Deveney *et al.*, 2023]揭示了潜在的差异。

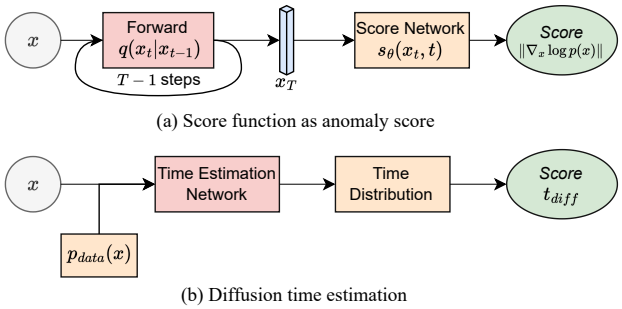

(a) Score function as anomaly score

(b) Diffusion time estimation

图3：基于密度的AD方法流程示意图：(a) 基于评分函数的方法和 (b) 扩散时间估计方法。

在基于评分的异常检测框架中，随机微分方程与常微分方程之间的差异值得仔细考量。

扩散时间估计。DTE 提供了一种替代的利用扩散过程的异常检测方法 [Livernoche *et al.*, 2023]。DTE 不再重建输入 x，而是估计了 x 穿越数据分布 $p_{data}(x)$ 所需的扩散时间步骤 t_{diff}。估计是通过时间估计网络进行的，该网络预测时间分布。直观上，更长的 t_{diff} 表明因 x 与学习到的分布之间的距离而产生异常 [Luo, 2023]。因此，估计的扩散时间 t_{diff} 作为异常分数，从其分布的模式或均值中得出。这个密度的解析形式是可以推导的，深度神经网络可以提高推理效率。因此，DTE 在像 ADBench 的基准测试中展示了竞争力的性能，尤其在速度方面，同时保持或超过传统 DDPM 的准确度。

3.3 混合方法

混合方法将扩散模型与其他异常检测技术相结合以提升性能。例如，RAD可以与密度估计结合，将扩散模型的重构误差与DAD（如DTE）集成[Liveroche *et al.*, 2023]。此外，前向过程中的动态步长计算通过初始异常预测引导，能够在无需添加噪声的情况下对缩放输入进行去噪，从而提升性能[Tebbe和Tayyub, 2024]。另一种方法中，扩散模型生成的潜在异常似然图通过联合噪声分布重采样与原始图像融合，增强了健康组织恢复能力[Bercea *et al.*, 2023]。针对时间序列异常检测，混合方法可采用基于密度比的策略选择正常观测值进行填补，并结合去噪扩散填补技术以改进缺失值生成，在异常聚集情况下尤其有效[Xiao *et al.*, 2023]。先进重构技术通过分析图像与扩散模型先验之间的差异预测特定去噪步骤，辅以训练期间合成异常样本生成和推理期间的空间自适应特征融合[Yao *et al.*, 2025]。将扩散模型与Transformer结合用于多类别异常检测，其中扩散提供高频信息进行细化，可缓解模糊重建和"相同捷径"问题[Zhan *et al.*, 2024]。最后，采用掩码的贝叶斯框架

Method	DS	Datasets	Results of metrics on datasets
FNDM [2023]	D	BRATS, ISLES	Dice: 76.21% (BRATS), 54.44% (ISLES), VS: 82.28% (BRATS), etc.
ODD [2023b]	D	MNIST, CIFAR-10, etc.	AUROC: 97.8% (MNIST), 84.7% (CIFAR-10), etc.
mDDPM [2024]	D	BraTS21, MSLUB	Dice: 53.02% (BraTS21), 10.71% (MSLUB), etc.
Dif-fuse [2024]	D	IST-3, BraTS, WMH	Dice: 0.699 (BraTS21), 0.569 (WMH), etc.
DIC [2024]	C	VisA, BTAD, MVTec	I-AUROC: 96.0%, P-AUROC: 97.9%, PRO 94.1% on VisA, etc.
DRAD [2024]	C	MVTec-AD	I-AUROC: 99.1% (MVTec-AD), P-AUROC: 97.3% (MVTec-AD), etc.
MDPS [2024]	C	MVTec-AD, BTAD	I-AUROC: 98.4% (MVTec-AD), P-AUROC: 97.0% (MVTec-AD), etc.
DISYRE [2024]	C	CamCAN, ATLAS, BraTS	AP: 45% (ATLAS), 51% (BraTS-T1), 73% (BraTS-T2), etc.

Notes: 蓝色高亮显示的方法表明存在可用的开源代码链接。DS表示扩散空间，其中'D'为离散的，'C'为连续的。由于空间限制，仅展示了部分数据集和结果。如需更多细节，请访问我们的GitHub。

表1：IAD方法在数据集上的指标结果汇总

含噪观测模型和基于扩散的正常图像先验实现有效的正常后验样本与测试图像之间的差异图计算，从而改进异常检测和定位 [Wu *et al.*, 2024]。

4 任务

在本节中，我们研究DMAD的四个主要任务，如表格1-4所示，这些表格呈现了具有开源实现、数据集、评估指标及相应结果的代表性方法。针对每个任务，方法根据其基本原理和检测策略进行分类，突出针对不同数据模态开发的独特挑战和解决方案。

4.1 图像异常检测

IAD代表DMs的一个关键应用领域，重点是识别全局模式（影响整个图像）和局部异常（局限于特定区域）中偏离正常状态的情况。许多方法利用DMs的重建能力，通过从噪声输入中重建图像后计算重建误差来计算异常分数[Xu *et al.*, 2023; Tur *et al.*, 2023a; Wang *et al.*, 2023d]。像GLAD[Yao *et al.*, 2025]这样的先进框架采用全局和局部自适应方法，而ODD[Wang *et al.*, 2023b]引入了用于语义距离测量的相似性网络。医学成像应用显示出特别的前景，FNDM[Li *et al.*, 2023]和mDDPM[Iqbal *et al.*, 2024]通过掩码扩散模型展示了更高的效率，而[Fontanella *et al.*, 2024]则引入了新颖的反事实生成技术。近期研究包括用于少样本生成的AnomalyDiffusion[Hu *et al.*, 2024b]和用于医学成像中合成异常生成的DISYRE[Naval Marimont *et al.*, 2024]。MDPS[Wu *et al.*, 2024]和DRAD[Sheng *et al.*, 2024]通过掩码采样和噪声嵌入进一步提高了检测能力，而像DIC[Tebbe and Tayyub, 2024]这样的方法则采用动态步长计算来提高定位精度。

Method	DS	Datasets	Results of metrics on datasets
SimpDM [2024b]	C	Iris, Yacht, etc.	RMSE: 0.059 (Iris), 0.045 (Yacht), 0.102 (Housing), etc.
CoDi [2023a]	C & D	Bank, Heart, etc.	B-F1: 47.26%, B-AUROC: 81.06%, M-F1: 62.21%, etc., on Bank
TimeDiT [2024]	C	Stocks, Energy, ect.	DS: 11.50% (Stocks), 17.78% (Air Quality), 17.26% (Energy), etc.
NGLS-Diff [2024a]	C	SWaT, MSL, etc.	F1: 97.52% (SWaT), 90.81% (MSL), 95.30% (SMAP), 98.04% (PSM)
D^3R [2023a]	C	PSM, SMD, SWaT	F1: 76.09% (PSM), 86.82% (SMD), 78.12% (SWaT)
DiffAD [2023]	C	MSL, SWaT, etc.	F1: 94.19% (MSL), 97.66% (SWaT), 97.95% (PSM), 96.95% (SMAP), etc.
DiffADT [2024]	C	SMAP, MSL, SMD	Pre: 96.33% (SMAP), 95.21% (MSL), 79.87% (SMD), etc.

表2：数据集上TSAD方法的指标结果总结 .

Method	DS	Datasets	Results of metrics on datasets
MoCoDAD [2023]	D	UB, HR-STC, etc.	AUC: 77.6% (HR-STC), 89.0% (HR-Ave), 68.4% (HR-UB), 68.3% (UB)
[Tur *et al.*, 2023b]	D	UCF, ShT	AUC: 76.36% (ShT), 63.67% (UCF)
DHVAD [2024]	C	Ped2, Ave, ShT	AUC: 98.1% (Ped2), 88.3% (Ave), 78.9% (ShT)
FDAE [2024]	D	Ave, ShT, Ped2	AUC: 97.7% (Ped2), 91.1% (Ave), 73.8% (ShT)
Masked Diffusion [2023]	D	CrossTask,NIV,COIN	SR: 39.17% (CrossTask), 32.35% (NIV), 29.43% (COIN), etc.
FPDM [2023]	D	Ave, ShT, UCF, UB	AUC: 90.1% (Ave), 78.6% (ShT), 74.7% (UCF), 62.7% (UB)
[Wang *et al.*, 2023d]	D	Ped2, Ave, ShT	AUC: 96.5% (Ped2), 92.2% (Ave), 75.4% (ShT)
DiffVAD [2024]	D	Ave, ShT, UCF, etc.	AUC: 81.9% (ShT), 90.3% (Ave), 87.6% (Ped2), etc.
Masked Diffusion [2023]	C	CrossTask,NIV,COIN	SR: 39.17% (CrossTask), 23.47% (CrossTask), 32.35% (NIV), etc.
VADiffusion [2024a]	D	Ped2, Ave, ShT	AUC: 98.2% (Ped2), 94.93% (Ave), 97.32% (ShT)

表 3：VAD 方法的汇总及数据集上的指标结果。

4.2 时间序列异常检测

DMs已成为用于TSAD的强大技术，能够有效学习序列数据的复杂分布[Yang *et al.*, 2024b]。DMs能够识别多种异常类型，包括点异常、上下文异常和集体异常[Sui *et al.*, 2024]。像NGLS-Diff [Han *et al.*, 2024a]这样的先进方法利用潜在空间，而[Zuo *et al.*, 2024]的方法则明确使用结构化状态空间层来建模时间依赖关系。最近，一些创新解决了关键挑战：D3R [Wang *et al.*, 2023a]通过动态分解解决非平稳性问题，而TimeDiT [Cao *et al.*, 2024]引入了具有多种掩码方案的基础模型方法。另一个关键挑战是非平稳性。DiffAD [Xiao *et al.*, 2023]通过插补处理缺失数据，辅以自监督技术[Liu *et al.*, 2024b]以及针对混合型时间数据的协同演化策略[Lee *et al.*, 2023a]。

4.3 视频异常检测

VAD有效地利用时空信息来识别异常事件。DMs已成为极具前景的VAD方法，因其能够学习复杂的数据分布并生成高质量的重构。例如，[Tur *et al.*, 2023a]研究了利用DMs的无监督VAD，依赖于高质量的重构。

Method	Mods.	DS	Datasets	Results of metrics on datasets
MPDR [2023]	I, V, A	C	MNIST, CIFAR-10, etc.	AUPR: 76.40% (MNIST), 98.60% (CIFAR-10), 83.38% (CIFAR-100), etc.
DIAG [2024]	I, T	C	KSDD2	AP: 80.1% (zero-shot), 92.4% (full-shot)
AnomalyXFusion [2024a]	I, T, Te	C	MVTec-AD, MVTec LOCO	IS: 1.82 (MVTec-AD), IC-LPIPS: 0.33 (MVTec-AD), etc

Notes: Mods. 表示模态，其中 'I' 代表图像，'V' 代表矢量，'A' 代表音频，'T' 代表文本，'Te' 代表纹理。

表4：MAD方法及其在数据集上的指标结果总结

错误表示异常，而[Tur *et al.*, 2023b]通过引入紧凑的运动表示作为条件信息来增强这一方法。最近提出了几种创新架构以提高检测精度：VADiffusion [Liu *et al.*, 2024a]采用了双分支结构，结合了运动矢量重建和I帧预测，而FDAE [Zhu *et al.*, 2024]引入了一种流引导的扩散自编码器，具有样本细化功能，以全面检测外观和运动异常。最近的进展包括[Yan *et al.*, 2023]的特征预测扩散模型和[Cheng *et al.*, 2024]的去噪扩散增强混合框架，均增强了对正常模式的语义理解。此外，[Wang *et al.*, 2023d]提出了一种通过随机重建和运动滤波器的集成方法，而[Fang *et al.*, 2023]则探索了带任务意识的掩蔽扩散，以在特定背景下实现更精准的异常检测。

4.4 多模态异常检测

MAD整合来自各种来源的数据，以识别与预期行为的偏差。尽管DMs在这一领域相对处于起步阶段，但通过先进的多模态数据整合，它们具有很大的潜力。例如，AnomalyXFusion [Hu *et al.*, 2024a] 通过有效结合图像、文本和掩码特征来增强异常合成，而[Flaborea *et al.*, 2023]在基于骨架的VAD中通过运动条件扩散模型展示了显著的成功。对于IAD，将视觉数据与文本描述相结合显著提高了微妙异常检测的效果 [Capogrosso *et al.*, 2024]，而基于能量的方法 [Yoon *et al.*, 2023] 则利用流形结构进行更准确的边界学习。GLAD [Yao *et al.*, 2025] 进一步建议通过专门的架构扩展DMs，以处理多模态数据，同时与LLMs的整合为基于上下文的异常检测提供了有希望的方向。

5 讨论

尽管DMAD取得了显著进展，若干关键挑战仍然存在。在本节中，我们探讨需要进一步的研究和开发的关键领域。计算成本。DMAD的广泛应用仍受大量计算需求的限制，特别是在处理高维数据或长时间序列时。计算需求在训练中的分布学习和采样阶段的数据生成过程中均有体现，采样过程的迭代性质需要大量步骤才能获得高质量输出[Cui *et al.*, 2023]。例如，高分辨率IAD由于数据量、模型

复杂性，以及捕捉时间依赖关系的需求[Wyatt *et al.*, 2022; Sui *et al.*, 2024]。然而，一些研究人员正在积极探索解决方案。一个有前景的方向是更快的采样方法，例如渐进式蒸馏和优化的采样计划（如align your steps），这些方法旨在减少采样步骤同时保持质量[Salimans and Ho, 2021]。另一种方法是通过剪枝和量化等技术进行模型压缩。此外，高效架构（如[Cui *et al.*, 2023]利用ER SDEs实现更快采样）以及预条件方法进一步提供了计算优势。

可解释性和解释能力。可解释性仍然是DMAD面临的主要挑战[Katsuoka *et al.*, 2024]。理解DM的决策过程至关重要，尤其是在关键应用中[Naval Marimont *et al.*, 2024]。可视化异常分数，例如将重建方法中的异常图像区域空间高亮，变得非常必要[Yao *et al.*, 2025]。然而，DM中固有的迭代去噪过程使得可解释性更加复杂。解释异常检测需要识别和解释偏离特征。将DM与可解释的人工智能（xAI）技术整合，例如采用注意力机制或利用LLMs进行文本/视觉解释[Wang *et al.*, 2023b]，提供了一条很有前途的研究方向。

复杂数据分布。应用DMAD的一个关键挑战在于处理复杂的数据分布。不平衡数据集（异常样本稀少）会使DM偏向多数类[Yang *et al.*, 2024a]，阻碍准确的异常建模。类似地，代表不同正常行为的多模态数据集会干扰DM学习[Zuo *et al.*, 2024]，可能错误分类来自较不显著模式的数据。含噪或缺失数据进一步复杂化DM的训练和推理[Choi *et al.*, 2022]，因为区分真实异常与数据缺陷变得困难。然而，存在潜在的解决方案。数据增强技术可通过生成合成的少数类样本解决类别不平衡[Yang *et al.*, 2024a]。鲁棒训练方法（如使用半不平衡最优运输）可增强DM对噪声和异常值的鲁棒性[Dao *et al.*, 2024]。专门架构（可能纳入处理缺失数据或建模多模态的机制）以及动态步长计算[Tebbe and Tayyub, 2024]、[Xiao *et al.*, 2023]可进一步提高DM在复杂分布上的性能。

鲁棒性和对抗攻击。对抗鲁棒性是 DMAD 的一个关键问题。与其他深度学习模型类似，DM 对对抗扰动具有脆弱性，这引发了对基于扩散的 AD 系统可靠性的担忧[Chen *et al.*, 2024b]。例如，[Kang *et al.*, 2025] 显示了 DMs 在分类中的对抗防御潜力，直接将这些方法应用于 AD 可能会降低异常检测率。具体而言，净化过程可能会同时去除重要的异常信号和噪声。此外，对抗示例在 DM 流形中表现出不对齐，提供了一个潜在的检测途径，但需要进一步的研究。所观察到的像素空间扩散模型 (PDMs) 和更脆弱的潜在扩散模型 (LDMs) 之间的鲁棒性差异。[Graham *et al.*, 2023] 强调了考虑特定 DM 类型的必要性。因此，未来的研究应优先考虑基于 DM 的健壮 AD 方法，包括能够区分真实异常与对抗噪音的架构和训练程序。一些有前景的方向包括像 DIFFender [Kang *et al.*, 2025] 这样的防御策略，利用文本引导的扩散和对抗异常感知现象，以及结合 DM 流形中对抗样本行为的洞察。

边缘-云协作。实时DMAD面临着重要的使用障碍，因为其重大的计算需求 [Li *et al.*, 2023]。边缘-云协作通过在边缘设备和云服务器之间分配工作负载，提供了一个有前景的解决方案。精心设计的轻量级DM在边缘设备上执行初步的异常筛查，而像完全重构这样资源密集型的任务则高效地卸载到云服务器 [Yan *et al.*, 2024]。此外，联邦学习允许在边缘设备和云之间进行协作模型训练，而无须共享敏感数据，从而增强泛化能力并保护隐私 [Jin *et al.*, 2024]。动态DM分区 [Chen *et al.*, 2024a] 促进了自适应资源分配，根据网络条件和计算需求优化性能。战略性的数据放置和分布式DNN部署原则进一步提高了系统效率。集成主动检测机制，如Maat所示 [Lee *et al.*, 2023b]，对于云监控和AIOps环境中的时间关键应用尤为重要。

与大语言模型集成。将DMs与LLMs相结合，为提升异常检测能力开辟了极具前景的路径，特别是通过生成人类可理解的异常解释并整合丰富的上下文信息[Kumar *et al.*, 2023]。例如，LLMs可利用详细的文本描述为观测到的波动提供背景信息，从而在MAD中区分真实异常与预期变化[Capogrosso *et al.*, 2024]。然而，当前异常检测领域的LLM集成面临一个关键挑战：如何有效表示和标记时序数据。现有的标记器主要针对文本设计，可能无法充分捕捉数值和时序数据的细微差异，这可能会影响性能[Li *et al.*, 2024]。因此，一个重要的研究方向是开发高效的数据表示技术和专用于异常检测的LLMs，以充分发挥这种协同方法的潜力[Tebbe and Tayyub, 2024]。

6 结论

在本次综述中，我们首先介绍异常检测和扩散模型的核心概念，为理解DMAD奠定基础。然后，我们系统地回顾现有方法及其在不同数据类型（包括图像、时间序列和多模态数据）中的任务。此外，我们分析每种数据类型的代表性方法，并突出它们的优势和局限性。为推动进一步研究，我们指出了关键挑战和有前景的未来方向，旨在推动DMAD研究的发展，并为实际应用启发创新解决方案。

参考文献

[Bercea *et al.*, 2023] Cosmin I. Bercea, Michael Neumayr, Daniel Rueckert, and Julia A. Schnabel. Mask, stitch, and re-sample: Enhancing robustness and generalizability in anomaly detection through automatic diffusion models. *arXiv:2305.19643*, 2023.

[Cao *et al.*, 2024] Defu Cao, Wen Ye, and Yan Liu. Timedit: General-purpose diffusion transformers for time series foundation model. In *ICMLW*, 2024.

[Capogrosso *et al.*, 2024] Luigi Capogrosso, Alvise Vivenza, Andrea Chiarini, Francesco Setti, and Marco Cristani. Exploiting multimodal latent diffusion models for accurate anomaly detection in industry 5.0. In *xAI*, volume 3762, pages 230–235, 2024.

[Chen *et al.*, 2024a] Xiangchun Chen, Jiannong Cao, Yuvraj Sahni, Shan Jiang, and Zhixuan Liang. Dynamic task offloading in edge computing based on dependency-aware reinforcement learning. *IEEE TCC*, 12:594–608, 2024.

[Chen *et al.*, 2024b] Yong Chen, Xuedong Li, Peng Hu, Dezhong Peng, and Xu Wang. Diffilter: Defending against adversarial perturbations with diffusion filter. *IEEE TIFS*, 19:6779–6794, 2024.

[Cheng *et al.*, 2024] Kai Cheng, Yaning Pan, Yang Liu, Xinhua Zeng, and Rui Feng. Denoising diffusion-augmented hybrid video anomaly detection via reconstructing noised frames. In *IJCAI*, volume 2, pages 695–703, 2024.

[Choi *et al.*, 2022] Jooyoung Choi, Jungbeom Lee, Chaehun Shin, Sungwon Kim, Hyunwoo Kim, and Sungroh Yoon. Perception prioritized training of diffusion models. In *CVPR*, pages 11472–11481, 2022.

[Cui *et al.*, 2023] Qinpeng Cui, Xinyi Zhang, Zongqing Lu, and Qingmin Liao. Elucidating the solution space of extended reverse-time sde for diffusion models, 2023.

[Dao *et al.*, 2024] Quan Dao, Binh Ta, Tung Pham, and Anh Tran. A high-quality robust diffusion framework for corrupted dataset, 2024.

[Deveney *et al.*, 2023] Teo Deveney, Jan Stanczuk, Lisa Maria Kreusser, Chris Budd, and Carola-Bibiane Schönlieb. Closing the ode-sde gap in score-based diffusion models through the fokker-planck equation. *arXiv:2311.15996*, 2023.

[Fang *et al.*, 2023] Fen Fang, Yun Liu, Ali Koksal, Qianli Xu, and Joo-Hwee Lim. Masked diffusion with task-awareness for procedure planning in instructional videos. *arXiv:2309.07409*, 2023.

[Flaborea *et al.*, 2023] Alessandro Flaborea, Luca Collorone, Guido Maria D'Amely Di Melendugno, Stefano D'Arrigo, Bardh Prenkaj, and Fabio Galasso. Multimodal motion conditioned diffusion model for skeleton-based video anomaly detection. In *ICCV*, pages 1–9, 2023.

[Fontanella *et al.*, 2024] Alessandro Fontanella, Grant Mair, Joanna Wardlaw, Emanuele Trucco, and Amos Storkey. Diffusion models for counterfactual generation and anomaly detection in brain images. *IEEE TMC*, 2024.

[Graham *et al.*, 2023] Mark S. Graham, Walter Hugo Lopez Pinaya, Paul Wright, Petru-Daniel Tudosiu, Yee H. Mah, James T. Teo, H. Rolf Jäger, David Werring, Parashkev Nachev, Sebastien Ourselin, and M. Jorge Cardoso. Unsupervised 3d out-of-distribution detection with latent diffusion models. In *MICCAI*, pages 446–456, 2023.

[Han *et al.*, 2024a] Jiashu Han, Shanshan Feng, Min Zhou, Xinyu Zhang, Yew Soon Ong, and Xutao Li. Diffusion model in normal gathering latent space for time series anomaly detection. In *ECML PKDD*, volume 14943, pages 284–300, 2024.

[Han *et al.*, 2024b] Yinbin Han, Meisam Razaviyayn, and Renyuan Xu. Neural network-based score estimation in diffusion models: Optimization and generalization, 2024.

[Hu and Jin, 2023] Xianyao Hu and Congming Jin. Anodode: Anomaly detection with diffusion ode, 2023.

[Hu *et al.*, 2024a] Jie Hu, Yawen Huang, Yilin Lu, Guoyang Xie, Guannan Jiang, Yefeng Zheng, and Zhichao Lu. Anomalyxfusion: Multi-modal anomaly synthesis with diffusion. *arXiv:2404.19444*, 2024.

[Hu *et al.*, 2024b] Teng Hu, Jiangning Zhang, Ran Yi, Yuzhen Du, Xu Chen, Liang Liu, Yabiao Wang, and Chengjie Wang. Anomalydiffusion: Few-shot anomaly image generation with diffusion model. In *AAAI*, volume 38, pages 8526–8534, 2024.

[Iqbal *et al.*, 2024] Hasan Iqbal, Umar Khalid, Chen Chen, and Jing Hua. Unsupervised anomaly detection in medical images using masked diffusion model. In *MLMI*, pages 372–381, 2024.

[Jin *et al.*, 2024] Ming Jin, Huan Yee Koh, Qingsong Wen, Daniele Zambon, Cesare Alippi, Geoffrey I. Webb, Irwin King, and Shirui Pan. A survey on graph neural networks for time series: Forecasting, classification, imputation, and anomaly detection. *IEEE TPAMI*, 46(12):1–20, 2024.

[Kang *et al.*, 2025] Caixin Kang, Yinpeng Dong, Zhengyi Wang, Shouwei Ruan, Yubo Chen, Hang Su, and Xingxing Wei. Diffender: Diffusion-based adversarial defense against patch attacks. In *ECCV*, pages 130–147, 2025.

[Katsuoka *et al.*, 2024] Teruyuki Katsuoka, Tomohiro Shiraishi, Daiki Miwa, Vo Nguyen Le Duy, and Ichiro Takeuchi. Statistical test on diffusion model-based anomaly detection by selective inference, 2024.

[Kumar *et al.*, 2023] Komal Kumar, Snehashis Chakraborty, and Sudipta Roy. Self-supervised diffusion model for anomaly segmentation in medical imaging. In *PRMI*, volume 14301, pages 359–368, 2023.

[Le Lan and Dinh, 2021] Charline Le Lan and Laurent Dinh. Perfect density models cannot guarantee anomaly detection. *Entropy*, 23:1690, 2021.

[Lee *et al.*, 2023a] Chaejeong Lee, Jayoung Kim, and Noseong Park. Codi: Co-evolving contrastive diffusion models for mixed-type tabular synthesis. In *ICML*, pages 18940–18956, 2023.

[Lee *et al.*, 2023b] Cheryl Lee, Tianyi Yang, Zhuangbin Chen, Yuxin Su, and Michael R. Lyu. Maat: Performance metric anomaly anticipation for cloud services with conditional diffusion. In *ASE*, pages 116–128, 2023.

[Li *et al.*, 2023] Jinpeng Li, Hanqun Cao, Jiaze Wang, Furui Liu, Qi Dou, Guangyong Chen, and Pheng-Ann Heng. Fast non-markovian diffusion model for weakly supervised anomaly detection in brain mr images. In *MICCAI*, volume 14224, pages 579–589, 2023.

[Li *et al.*, 2024] Shu Li, Jiong Yu, Yi Lu, Guangqi Yang, Xusheng Du, and Su Liu. Self-supervised enhanced denoising diffusion for anomaly detection. *Inf. Sci.*, 669:120612, 2024.

[Liu *et al.*, 2024a] Hao Liu, Lijun He, Miao Zhang, and Fan Li. Vadiffusion: Compressed domain information guided conditional diffusion for video anomaly detection. *IEEE TCSVT*, 34:8398–8411, 2024.

[Liu *et al.*, 2024b] Yixin Liu, Thalaiyasingam Ajanthan, Hisham Husain, and Vu Nguyen. Self-supervision improves diffusion models for tabular data imputation. In *CIKM*, pages 1513–1522, 2024.

[Livernoche *et al.*, 2023] Victor Livernoche, Vineet Jain, Yashar Hezaveh, and Siamak Ravanbakhsh. On diffusion modeling for anomaly detection. In *ICLR*, 2023.

[Luo, 2023] Weijian Luo. A comprehensive survey on knowledge distillation of diffusion models, 2023.

[Naval Marimont *et al.*, 2024] Sergio Naval Marimont, Vasilis Siomos, Matthew Baugh, Christos Tzelepis, Bernhard Kainz, and Giacomo Tarroni. Ensembled cold-diffusion restorations for unsupervised anomaly detection. In *MICCAI*, pages 243–253, 2024.

[Pang *et al.*, 2021] Guansong Pang, Chunhua Shen, Longbing Cao, and Anton Van Den Hengel. Deep learning for anomaly detection: A review. *ACM CSUR*, 54(2):38:1–38:38, March 2021.

[Salimans and Ho, 2021] Tim Salimans and Jonathan Ho. Progressive distillation for fast sampling of diffusion models. In *ICLR*, 2021.

[Sheng *et al.*, 2024] Xinyu Sheng, Shande Tuo, and Lu Wang. Surface anomaly detection and localization with diffusion-based reconstruction. In *IJCNN*, pages 1–8, 2024.

[Sui *et al.*, 2024] Jialin Sui, Jinsong Yu, Yue Song, and Jian Zhang. Anomaly detection for telemetry time series using a denoising diffusion probabilistic model. *IEEE Sens. J.*, 24:16429–16439, 2024.

[Tebbe and Tayyub, 2024] Justin Tebbe and Jawad Tayyub. Dynamic addition of noise in a diffusion model for anomaly detection. In *CVPR*, pages 3940–3949, 2024.

[Tur *et al.*, 2023a] Anil Osman Tur, Nicola Dall'Asen, Cigdem Beyan, and Elisa Ricci. Exploring diffusion models for unsupervised video anomaly detection. In *ICIP*, pages 2540–2544, 2023.

[Tur *et al.*, 2023b] Anil Osman Tur, Nicola Dall'Asen, Cigdem Beyan, and Elisa Ricci. Unsupervised video anomaly detection with diffusion models conditioned on compact motion representations. In *ICIAP*, pages 49–62, 2023.

[Wang and Vastola, 2023] Binxu Wang and John J. Vastola. The hidden linear structure in score-based models and its application. *arXiv:2311.10892*, 2023.

[Wang *et al.*, 2023a] Chengsen Wang, Zirui Zhuang, Qi Qi, Jingyu Wang, Xingyu Wang, Haifeng Sun, and Jianxin Liao. Drift doesn't matter: Dynamic decomposition with diffusion reconstruction for unstable multivariate time series anomaly detection. In *NeurIPS*, volume 36, pages 10758–10774, 2023.

[Wang *et al.*, 2023b] He Wang, Longquan Dai, Jinglin Tong, and Yan Zhai. Odd: One-class anomaly detection via the diffusion model. In *ICIP*, pages 3000–3004, 2023.

[Wang *et al.*, 2023c] Wenjie Wang, Yiyan Xu, Fuli Feng, Xinyu Lin, Xiangnan He, and Tat-Seng Chua. Diffusion recommender model. In *SIGIR*, pages 832–841, 2023.

[Wang *et al.*, 2023d] Zhiqiang Wang, Xiaojing Gu, Jingyu Hu, and Xingsheng Gu. Ensemble anomaly score for video anomaly detection using denoise diffusion model and motion filters. *Neurocomputing*, 553:126589, 2023.

[Wu *et al.*, 2024] Di Wu, Shicai Fan, Xue Zhou, Li Yu, Yuzhong Deng, Jianxiao Zou, and Baihong Lin. Unsupervised anomaly detection via masked diffusion posterior sampling. *arXiv:2404.17900*, 2024.

[Wyatt *et al.*, 2022] Julian Wyatt, Adam Leach, Sebastian M. Schmon, and Chris G. Willcocks. Anoddpm: Anomaly detection with denoising diffusion probabilistic models using simplex noise. In *CVPR*, pages 650–656, 2022.

[Xiao *et al.*, 2023] Chunjing Xiao, Zehua Gou, Wenxin Tai, Kunpeng Zhang, and Fan Zhou. Imputation-based time-series anomaly detection with conditional weight-incremental diffusion models. In *KDD*, pages 1–9, 2023.

[Xu *et al.*, 2023] Haohao Xu, Shuchang Xu, and Wenzhen Yang. Unsupervised industrial anomaly detection with diffusion models. *J. Vis. Commun. Image Represent.*, 97:103983, 2023.

[Yan *et al.*, 2023] Cheng Yan, Shiyu Zhang, Yang Liu, Guansong Pang, and Wenjun Wang. Feature prediction diffusion model for video anomaly detection. In *ICCV*, pages 5504–5514, 2023.

[Yan *et al.*, 2024] Chenqian Yan, Songwei Liu, Hongjian Liu, Xurui Peng, Xiaojian Wang, Fangmin Chen, Lean Fu, and Xing Mei. Hybrid sd: Edge-cloud collaborative inference for stable diffusion models. *arXiv:2408.06646*, 2024.

[Yang *et al.*, 2024a] Xiongyan Yang, Tianyi Ye, Xianfeng Yuan, Weijie Zhu, Xiaoxue Mei, and Fengyu Zhou. A novel data augmentation method based on denoising diffusion probabilistic model for fault diagnosis under imbalanced data. *IEEE TII*, 20:7820–7831, 2024.

[Yang *et al.*, 2024b] Yiyuan Yang, Ming Jin, Haomin Wen, Chaoli Zhang, Yuxuan Liang, Lintao Ma, Yi Wang, Chenghao Liu, Bin Yang, Zenglin Xu, Jiang Bian, Shirui Pan, and Qingsong Wen. A survey on diffusion models for time series and spatio-temporal data, 2024.

[Yao *et al.*, 2025] Hang Yao, Ming Liu, Zhicun Yin, Zifei Yan, Xiaopeng Hong, and Wangmeng Zuo. Glad: Towards better reconstruction with global and local adaptive diffusion models for unsupervised anomaly detection. In *ECCV*, pages 1–17, 2025.

[Yoon *et al.*, 2023] Sangwoong Yoon, Young-Uk Jin, Yung-Kyun Noh, and Frank Park. Energy-based models for anomaly detection: A manifold diffusion recovery approach. In *NeurIPS*, volume 36, pages 1–21, 2023.

[Zhan *et al.*, 2024] Jiawei Zhan, Jinxiang Lai, Bin-Bin Gao, Jun Liu, Xiaochen Chen, and Chengjie Wang. Enhancing multi-class anomaly detection via diffusion refinement with dual conditioning. *arXiv:2407.01905*, 2024.

[Zhang and Pilanci, 2024] Fangzhao Zhang and Mert Pilanci. Analyzing neural network-based generative diffusion models through convex optimization, 2024.

[Zhang *et al.*, 2023] Hui Zhang, Zheng Wang, Zuxuan Wu, and Yu-Gang Jiang. Diffusionad: Norm-guided one-step denoising diffusion for anomaly detection, 2023.

[Zhang *et al.*, 2024] Menghao Zhang, Jingyu Wang, Qi Qi, Pengfei Ren, Haifeng Sun, Zirui Zhuang, Lei Zhang, and Jianxin Liao. Safeguarding sustainable cities: Unsupervised video anomaly detection through diffusion-based latent pattern learning. In *IJCAI*, volume 8, pages 7572–7580, 2024.

[Zhu *et al.*, 2024] Aoni Zhu, Wenjun Wang, and Cheng Yan. Flow-guided diffusion autoencoder for unsupervised video anomaly detection. In *PRCV*, volume 14430, pages 183–194, 2024.

[Zuo *et al.*, 2024] Haiwei Zuo, Aiqun Zhu, Yanping Zhu, Yinping Liao, Shiman Li, and Yun Chen. Unsupervised diffusion based anomaly detection for time series. *APIN*, 54:8968–8981, 2024.

附录 C　程序代码

```
import sys
import os
sys.path.append(os.getcwd())
from share import *
from utils.util import *
import torch
import pytorch_lightning as pl
from torch.utils.data import DataLoader

# □ 1.  BraTS 数据加载器
from data.MRIad_dataloader_caption import BraTSDataset_caption

from cdm.model import create_model
from pytorch_lightning.callbacks import ModelCheckpoint
from pytorch_lightning.loggers import TensorBoardLogger,
    CSVLogger
import argparse

# --- 核心限制 ---
cpu_num = 1
os.environ['OMP_NUM_THREADS'] = str(cpu_num)
os.environ['OPENBLAS_NUM_THREADS'] = str(cpu_num)
os.environ['MKL_NUM_THREADS'] = str(cpu_num)
os.environ['VECLIB_MAXIMUM_THREADS'] = str(cpu_num)
os.environ['NUMEXPR_NUM_THREADS'] = str(cpu_num)
torch.set_num_threads(cpu_num)
torch.multiprocessing.set_sharing_strategy('file_system')

def main(args):
    setup_seed(args.seed)

    # 2. 更新日志命名逻辑 (移除了 setting 参数)
    log_name = f'brats_template_prob{args.template_prob}_{args.
    vlm_model}'
    save_dir = f'./incre_val/{log_name}/'
    os.makedirs(save_dir, exist_ok=True)

    print(f"\n{'='*80}")
    print(f"□ Foundation Model Training (BraTS MRI)")
```

```
    print(f"   Save Dir: {save_dir}")
    print(f"   Resume From: {args.resume_path}")
    print(f"   VLM Model: {args.vlm_model}")
    print(f"   Template Prob: {args.template_prob}")
    print(f"{'='*80}\n")

    print(f">>> 正在加载 BraTS 数据集...")

    # □ 3. 实例化 BraTS 数据集 (不再返回元组，直接返回 Dataset 对象)
    train_dataset = BraTSDataset_caption(
        type='train',
        root=args.data_path,
        caption_path=args.caption_path,
        template_prob=args.template_prob
    )
    test_dataset = BraTSDataset_caption(
        type='test',
        root=args.data_path,
        caption_path=args.caption_path,
        template_prob=args.template_prob
    )

    # 4. 初始化模型 (如果 MRI 有专属的 yaml 配置文件，请在这里更改)
    model = create_model('models/cdad_mvtec.yaml').cpu()
    model.learning_rate = args.learning_rate

    # 5. 加载初始权重
    if not os.path.exists(args.resume_path):
        raise FileNotFoundError(f"未找到初始权重: {args.resume_path}，请先运行 build_base_model.py")

    print(f">>> 加载初始权重: {args.resume_path}")
    weights = torch.load(args.resume_path)
    select_weights = {key: weights[key] for key in weights if not 'control_model' in key}
    model.load_state_dict(select_weights, strict=False)

    print(">>> [Mode] Full Fine-tuning (无 LoRA，全量更新)")

    # 6. 配置 Logger 和 Checkpoint
```

```
    model.set_log_name(f'{log_name}/foundation')

    tb_logger = TensorBoardLogger(save_dir="lightning_logs", name=log_name, version="foundation")
    csv_logger = CSVLogger(save_dir="lightning_logs", name=log_name, version="foundation")

    ckpt_callback = ModelCheckpoint(
        monitor='val_acc',
        dirpath=save_dir,
        filename='foundation_model',
        mode='max',
        save_top_k=1
    )

    strategy = None
    if args.gpus and len(args.gpus) > 1:
        strategy = 'ddp'

    trainer = pl.Trainer(
        logger=[tb_logger, csv_logger],
        gpus=args.gpus,
        precision=32,
        strategy=strategy,
        callbacks=[ckpt_callback],
        num_sanity_val_steps=0,
        accumulate_grad_batches=1,
        max_epochs=args.max_epoch,
        check_val_every_n_epoch=args.check_v,
        enable_progress_bar=False
    )

    # □ 7. 直接传入 Dataset 对象，不需要索引 [task_id]
    train_loader = DataLoader(train_dataset, num_workers=4, batch_size=args.batch_size, shuffle=True)
    test_loader = DataLoader(test_dataset, num_workers=4, batch_size=args.batch_size, shuffle=False)

    # 8. 开始训练
    trainer.fit(model, train_dataloaders=train_loader, val_dataloaders=test_loader)

```

```
    print(f"\n□ Foundation Model 训练完成！")
    print(f"   保存位置：{os.path.join(save_dir, 'foundation_model.ckpt')}")

if __name__ == "__main__":
    parser = argparse.ArgumentParser(description="Train Foundation Model for BraTS MRI")

    parser.add_argument("--resume_path", default='./models/base.ckpt', help="由 build_base_model.py 生成的初始权重")

    # □ 更新默认路径为 BraTS 实际路径
    parser.add_argument("--data_path", default="/data2/chenxuwu/zihaowan_workplace/dataset/BraTS2021_slice", type=str)
    parser.add_argument("--caption_path", default="/data2/chenxuwu/zihaowan_workplace/dataset/brats_captions_Qwen3-VL.json", type=str)

    parser.add_argument("--vlm_model", default="Qwen3-VL-30B", type=str, help="用于标记实验日志名称")
    parser.add_argument("--template_prob", default=0.2, type=float, help="Probability of using simple template instead of detailed caption")

    parser.add_argument("--seed", default=1, type=int)
    parser.add_argument("--batch_size", default=12, type=int)
    parser.add_argument("--learning_rate", default=1e-5, type=float)
    parser.add_argument("--max_epoch", default=500, type=int)
    parser.add_argument("--check_v", default=25, type=int)
    parser.add_argument("--gpus", nargs='+', type=int, default=[4,5,6,7], help="GPU IDs")

    args = parser.parse_args()

    main(args)
```

```
import os
import sys
import json
import argparse
```

```
import glob
from tqdm import tqdm
from vllm import LLM, SamplingParams


# ----------------------------------------------------------------------------
# 1. Environment & Path Setup
# ----------------------------------------------------------------------------
current_dir = os.path.dirname(os.path.abspath(__file__))
project_root = os.path.dirname(current_dir)
sys.path.append(project_root)

# ----------------------------------------------------------------------------
# 2. Prompt Strategy
# ----------------------------------------------------------------------------
# 这里保留了你之前用的 pd 模式的 prompt
DEFAULT_PROMPT = (
    "Describe the visual features of image in detail with a focus on the main object, with around 60 words and maybe 4 or 5 sentences."
)

# ----------------------------------------------------------------------------
# 3. Core Functions
# ----------------------------------------------------------------------------


def load_model(model_path, tp_size=4, use_fp8=True):
    print(f"\n□ Preparing to load Qwen3-VL from: {model_path}")
    print(f"□ Strategy: Tensor Parallelism = {tp_size}")

```

```
    quant_config = "fp8" if use_fp8 else None
    print(f"□ Quantization: {quant_config if quant_config else 'None (BF16/Original)'}")

    try:
        llm = LLM(
            model=model_path,
            tensor_parallel_size=tp_size,
            trust_remote_code=True,
            quantization=quant_config,
            gpu_memory_utilization=0.95,
            max_model_len=4096,
            limit_mm_per_prompt={"image": 1},
            enforce_eager=True,
            allowed_local_media_path="/"
        )
        print("□ vLLM Engine loaded successfully.")

        sampling_params = SamplingParams(
            temperature=0.2,
            top_p=0.8,
            max_tokens=128,
            stop_token_ids=[151643, 151645]
        )
        return llm, sampling_params
    except Exception as e:
        print(f"\n□ Model load failed: {e}")
        sys.exit(1)

def get_image_files(root_dir):
    image_extensions = {'.png', '.jpg', '.jpeg', '.bmp', '.tiff'}
    image_list = []

    print(f"□ Scanning sets at: {root_dir}")
    if not os.path.isdir(root_dir):
        print(f"□ Error: Data path is not a directory: {root_dir}")
        return []

    # 使用递归查找所有文件
    search_path = os.path.join(root_dir, '**', '*.*')
```

```
    all_files = glob.glob(search_path, recursive=True)

    for abs_path in all_files:
        if os.path.splitext(abs_path)[1].lower() in image_extensions:
            # 过滤掉路径中包含 'label' 的文件夹（通常是掩码 mask)
            if 'label' in abs_path.split(os.sep):
                continue

            # 生成相对路径作为 JSON 的 key
            rel_path = os.path.relpath(abs_path, root_dir)
            image_list.append((abs_path, rel_path))

    print(f"□ Found {len(image_list)} valid brain images (excluding labels).")
    return image_list

def generate_caption_vllm(llm, sampling_params, image_path):
    messages = [
        {
            "role": "user",
            "content": [
                {
                    "type": "image_url",
                    "image_url": {
                        "url": f"file://{image_path}"
                    }
                },
                {"type": "text", "text": DEFAULT_PROMPT},
            ],
        }
    ]

    outputs = llm.chat(messages, sampling_params, use_tqdm=False)
    generated_text = outputs[0].outputs[0].text
    return generated_text

# ----------------------------------------------------------------------------
```

```
# 4. Main Loop
# ----------------------------------------------------------------------------

def main():
    # 更新为你实际的服务器路径
    default_model_path = "/data2/chenxuwu/zihaowan_workplace/qwen/Qwen3-VL-235B-Instruct"
    default_output_path = "/data2/chenxuwu/zihaowan_workplace/dataset/brats_captions_Qwen3-VL.json"
    default_data_path = "/data2/chenxuwu/zihaowan_workplace/dataset/BraTS2021_slice"

    parser = argparse.ArgumentParser(description="Generate captions using Qwen with vLLM")
    parser.add_argument("--data_path", type=str, default=default_data_path, help="Dataset root path")
    parser.add_argument("--output", type=str, default=default_output_path, help="Output JSON path")
    parser.add_argument("--model_path", type=str, default=default_model_path, help="Local model path")
    parser.add_argument("--tp", type=int, default=4, help="Tensor Parallelism size (GPU count)")
    parser.add_argument("--no_fp8", action="store_true", help="Disable FP8 quantization")

    args = parser.parse_args()

    if not os.path.exists(args.data_path):
        print(f"□ Error: Data path not found: {args.data_path}")
        sys.exit(1)

    output_dir = os.path.dirname(args.output)
    if output_dir: os.makedirs(output_dir, exist_ok=True)

    # --- Resume Logic ---
    captions_dict = {}
    if os.path.exists(args.output):
        print(f"□ Found existing output file: {args.output}")
        try:
            with open(args.output, 'r') as f:
```

```
                captions_dict = json.load(f)
            print(f"   Resuming... Loaded {len(captions_dict)} existing captions.")
        except json.JSONDecodeError:
            print("□  JSON corrupted. Starting over.")
            captions_dict = {}

    all_images = get_image_files(args.data_path)
    # 过滤已处理的图片
    todo_images = [item for item in all_images if item[1] not in captions_dict]

    print(f"□ To generate: {len(todo_images)}")
    if len(todo_images) == 0:
        print("□ All done!")
        return

    # 加载模型 (vLLM)
    use_fp8 = not args.no_fp8
    llm, sampling_params = load_model(args.model_path, tp_size=args.tp, use_fp8=use_fp8)

    print("\n□ Starting generation...")
    save_interval = 20

    try:
        for i, (abs_path, rel_path) in enumerate(tqdm(todo_images, desc="Captioning")):
            try:
                caption = generate_caption_vllm(llm, sampling_params, abs_path)
                captions_dict[rel_path] = caption
            except Exception as e:
                print(f"\n□ Error on {rel_path}: {e}")
                captions_dict[rel_path] = "<ERROR_GENERATING>"
                continue

            if (i + 1) % save_interval == 0:
                with open(args.output, 'w') as f:
                    json.dump(captions_dict, f, indent=4)

    except KeyboardInterrupt:
```

```
        print("\n⚠ Interrupted! Saving currently processed data...")

    with open(args.output, 'w') as f:
        json.dump(captions_dict, f, indent=4)
    print(f"\n✅ Done! Saved to {args.output}")

if __name__ == "__main__":
    main()
```

```
import json
import cv2
import os
import numpy as np
from PIL import Image
from torch.utils.data import Dataset
from torchvision import transforms
import random
from data.nsa import patch_ex

# 医学影像的标准化参数（如果不需要 ImageNet 色彩空间，可以在 main 函数里调整）
mean_train = [0.485, 0.456, 0.406]
std_train = [0.229, 0.224, 0.225]

class BraTSDataset_caption(Dataset):
    def __init__(self, type, root, caption_path="./data/brats_captions_Qwen3-VL.json", template_prob=0.2):
        self.type = type
        self.root = root
        self.template_prob = template_prob
        self.split = 'train' if type == 'train' else 'valid'
        self.image_size = (256, 256)

        # 1. 加载 Caption JSON
        self.captions = {}
        if self.type == 'train':
            if os.path.exists(caption_path):
                print(f"Loading captions from {caption_path}...")
                with open(caption_path, 'r') as f:
```

```
                    self.captions = json.load(f)
            else:
                print(f"Warning: Caption file not found at {caption_path}")

        # 2. 构建数据列表（区分正常与异常，不区分物品类别）
        self.data = []
        self.good_indices = []

        for condition in ['good', 'Ungood']:
            img_dir = os.path.join(self.root, self.split, condition, 'img')
            if not os.path.exists(img_dir):
                continue

            for fname in sorted(os.listdir(img_dir)):
                if fname.endswith(('.png', '.jpg')):
                    rel_path = f"{self.split}/{condition}/img/{fname}"
                    is_anomaly = 1 if condition == 'Ungood' else 0

                    item = {
                        'filename': rel_path,
                        'abs_path': os.path.join(img_dir, fname),
                        'is_anomaly': is_anomaly
                    }

                    if is_anomaly == 1:
                        item['maskname'] = os.path.join(self.root, self.split, condition, 'label', fname)

                    idx = len(self.data)
                    self.data.append(item)

                    if is_anomaly == 0:
                        self.good_indices.append(idx)

        print(f"Loaded {len(self.data)} images for {self.type} set.")

```

```
    def __len__(self):
        return len(self.data)

    def find_idx(self, idx):
        possible_indices = [i for i in self.good_indices if i !=
    idx]
        if not possible_indices:
            raise ValueError("No possible normal image found for
    NSA.")
        return random.choice(possible_indices)

    def get_nsa_args(self):
        return {'width_bounds_pct': ((0.03, 0.4), (0.03, 0.4)),
                'num_patches': 4}

    def __getitem__(self, idx):
        item = self.data[idx]

        # --- NSA 数据增强逻辑 (仅对正常样本) ---
        do_nsa = False
        if self.type == 'train' and item['is_anomaly'] == 0 and
   idx % 2 == 0:
            nsa_idx = self.find_idx(idx)
            nsa_item = self.data[nsa_idx]
            do_nsa = True
        else:
            nsa_item = item

        # --- 图像读取 ---
        transform_fn = transforms.Resize(self.image_size)

        target = cv2.imread(nsa_item['abs_path'])
        target = cv2.cvtColor(target, cv2.COLOR_BGR2RGB)
        target = Image.fromarray(target, "RGB")
        target = transform_fn(target)

        source = cv2.imread(item['abs_path'])
        source = cv2.cvtColor(source, cv2.COLOR_BGR2RGB)
        source = Image.fromarray(source, "RGB")
        source = transform_fn(source)

        # --- Mask 生成 ---
```

```
        if do_nsa:
            source_np, mask_np = patch_ex(np.asarray(target), np.asarray(source), **self.get_nsa_args())
            mask = (mask_np[:, :, 0] * 255.0).astype(np.uint8)
            source = Image.fromarray(source_np, "RGB")
        else:
            if item.get('maskname') and os.path.exists(item['maskname']):
                mask = cv2.imread(item['maskname'], cv2.IMREAD_GRAYSCALE)
                mask = cv2.resize(mask, self.image_size, interpolation=cv2.INTER_NEAREST)
                mask = (mask > 127).astype(np.uint8) * 255
            else:
                mask = np.zeros(self.image_size, dtype=np.uint8)

        target = transforms.ToTensor()(target)
        source = transforms.ToTensor()(source)

        # --- 直接生成 MRI 专属 Prompt ---
        prompt = ""
        if self.type == 'train':
            if random.random() < self.template_prob:
                prompt = "A detailed magnetic resonance image of a human brain."
            elif item['filename'] in self.captions:
                prompt = self.captions[item['filename']]
            else:
                prompt = "A detailed magnetic resonance image of a human brain."
        else:
            prompt = "A detailed magnetic resonance image of a human brain."

        mask = Image.fromarray(mask, "L")
        mask = transforms.ToTensor()(mask)

        normalize_fn = transforms.Normalize(mean=mean_train, std=std_train)
        source = normalize_fn(source)
        target = normalize_fn(target)

```

```
        # 【重点修改】保留 clsname 和 label 的键名以防主脚本报错，但赋予统一的常量值
        return dict(
            jpg=target,
            txt=prompt,
            hint=source,
            mask=mask,
            filename=item['filename'],
            clsname='brain_mri',  # 占位符，保证字典结构不破裂
            label=0               # 强制归一为 0 类，代替原来的 image_idx
        )
```